

Técnicas Experimentais em Agronomia

Inês Cristina de Batista Fonseca

Guilherme Biz

Sumário

1	Plano de ensino	5
2	Contexto Histórico da Estatística Experimental	8
3	Introdução	10
3.1	Áreas da Estatística	10
3.2	Conceitos importantes	11
3.2.1	Censo ou amostragem	12
3.3	Técnicas de amostragem	13
3.3.1	Amostragem Simples ao Acaso – Probabilística	13
3.3.2	Amostragem Sistemática – Probabilística	13
3.3.3	Amostragem Estratificada – Probabilística	14
3.3.4	Amostragem por Conveniência – Não probabilística	14
3.3.5	Amostragem Intencional – Não probabilística	15
3.3.6	Amostragem por Quota – Não probabilística	15
3.3.7	Dimensionamento da amostra	16
3.3.8	Determinação do tamanho amostral para variáveis qualitativas	16
3.3.9	Determinação do tamanho amostral para variáveis quantitativas	17
3.4	Introdução ao R	17
3.4.1	Download do R	18
3.4.2	RStudio	18
4	Estatística Descritiva	20
4.1	Introdução	20
4.2	Representação Tabular e Gráfica	24
4.2.1	Distribuições de frequências de variáveis qualitativas e representações gráficas	25
4.2.2	Distribuições de frequências de variáveis quantitativas discretas e representações gráficas	28
4.2.3	Distribuições de frequências de variáveis quantitativas contínuas e representações gráficas	30
4.3	Medidas Descritivas	34
4.3.1	Medidas de Posição	34
4.3.2	Medidas de Dispersão	42
4.3.3	Assimetria	63

5	Variáveis Aleatórias	66
5.1	Distribuição de probabilidade de variáveis aleatórias discretas	66
5.2	Alguns modelos probabilísticos para variáveis aleatórias discretas	68
5.2.1	Distribuição de Bernoulli	69
5.2.2	Distribuição Binomial	70
5.2.3	Distribuição de Poisson	71
5.3	Distribuição de probabilidade de variáveis aleatórias contínuas	72
5.3.1	Distribuição Normal	74
6	Distribuições Amostrais	80
6.1	Distribuição amostral da média	82
7	Estimação dos parâmetros	85
7.1	Estimação Pontual	85
7.2	Estimação por Intervalo	87
7.2.1	Intervalo de Confiança para a Média (σ conhecido ou n grande)	88
7.2.2	Intervalo de Confiança para a Média (σ desconhecido)	89
7.2.3	Intervalo de confiança para diferença entre duas médias	91
7.3	Intervalo de confiança para proporção	99
7.3.1	Intervalo de confiança para uma proporção	100
7.3.2	Intervalo de confiança para a diferença entre duas proporções	102
8	Testes de Hipóteses	106
8.1	Teste de hipótese para a média (σ^2 conhecida)	107
8.1.1	Exemplo	108
8.2	Teste de hipótese para a média (σ desconhecida)	113
8.2.1	Exemplo	114
8.3	Teste de hipótese para proporção	117
8.3.1	Exemplo	118
8.4	Inferência para duas médias	119
8.5	Teste para duas médias - Amostras pareadas	120
8.5.1	Exemplo	121
8.6	Teste para duas Médias - Amostras independentes	123
8.6.1	Teste para duas Médias - Variâncias Iguais	124
8.6.2	Exemplo	124
8.6.3	Teste para duas médias com variâncias desiguais	126
8.6.4	Exemplo	127
8.7	Teste para duas proporções	129
8.7.1	Exemplo	129
8.8	Teste para igualdade de duas variâncias	131
8.8.1	Exemplo	132

9	Planejamento de Experimentos	136
9.1	Introdução à experimentação.	136
9.2	Princípios básicos da experimentação	138
9.2.1	Princípio da Repetição	139
9.2.2	Princípio da Casualização	140
9.2.3	Princípio do Controle Local	140
9.2.4	Condução do experimento	141
9.2.5	Planejamento do Experimento	141
9.2.6	Análise dos dados experimentais	143
9.3	Principais delineamentos Experimentais	143
9.3.1	Delineamento Inteiramente Casualizado (DIC)	143
9.3.2	Delineamento Casualizado em Blocos (DBC)	145
9.3.3	Delineamento em Quadrado Latino (DQL)	146
9.3.4	Experimentos Fatoriais	148
9.3.5	Experimentos em Parcelas Subdivididas	150
	References	153

1 Plano de ensino

1. Identificação

Disciplina: Técnicas Experimentais em Agronomia (2AGR245)

Curso: Pós-graduação em Agronomia

Ano Letivo: 2026 - 1º Semestre - **Carga horária:** 120 horas (8 horas/semana)

Horário das Aulas: 8h30 às 18h nas Quintas-feiras

Local: Anfiteatro da Pós-Graduação do CCA

Professores:

- Prof^ª. Dr.^ª Inês Cristina de Batista Fonseca - inescbf@uel.br
- Prof. Dr. Guilherme Biz - gbiz@uel.br

2. Ementa

Estatística Descritiva. Distribuição Normal. Estimação. Teste de Hipóteses. Planejamento Estatístico de Experimentos em Agronomia. Análise de variância e testes de comparação de médias. Delineamentos experimentais em pesquisas em Agronomia. Regressão e Correlação.

3. Formas e critérios de Avaliação

Duas avaliações sendo a média final por média aritmética simples.

4. Cronograma das Atividades

Dias	Assunto	
	Manhã	Tarde
19/03	Apresentação da disciplina. Introdução à Estatística. Conceitos básicos e noções de amostragem.	Introdução ao software R e ao ambiente RStudio.
26/03	Estatística Descritiva: construção e interpretação de tabelas e gráficos. Medidas descritivas de posição e dispersão.	Aplicações em Estatística Descritiva utilizando o software R.
09/04	Variáveis aleatórias contínuas e distribuição Normal.	Aplicações e uso do software R.

Dias	Assunto	
	Manhã	Tarde
16/04	Introdução à Inferência Estatística: estimativas pontuais e intervalares.	Aplicações com o uso do software R.
23/04	Testes de hipóteses estatísticas: conceitos fundamentais, procedimentos e interpretação dos resultados.	Aplicações com o uso do software R.
30/04	Avaliação sobre os conteúdos de introdução à Estatística, Estatística Descritiva, distribuição Normal, estimação e testes de hipóteses.	
07/05	Devolutiva e discussão da avaliação. Introdução ao Planejamento Estatístico de Experimentos Agronômicos. Delineamento Inteiramente Casualizado: modelo matemático, hipóteses básicas para a validade da ANOVA e obtenção da análise de variância.	Aplicações utilizando o software R.
14/05	Aplicações do Delineamento Inteiramente Casualizado. Testes de comparações múltiplas.	Uso do software R.
21/05	Delineamento Casualizado em Blocos: conceitos, modelo estatístico e análise.	Aplicações com o uso do software R.
28/05	Experimentos fatoriais com dois fatores: conceitos, modelagem estatística e análise de variância.	Uso do software R.
11/06	Experimentos fatoriais com três ou mais fatores: modelagem estatística, análise e interpretação dos resultados.	Uso do software R.
18/06	Experimentos em parcelas subdivididas: estrutura do delineamento, modelo estatístico e análise.	Uso do software R.
25/06	Análise de regressão utilizando polinômios ortogonais.	Aplicações com o uso do software R.
02/07	Análise conjunta de grupos de experimentos.	Aplicações e interpretação dos resultados com o uso do software R.
09/07	Avaliação sobre os conteúdos de Estatística Experimental.	

5. Bibliografia

ANDRADE, D. O.; OGLIARI, P. J. Estatística para as Ciências Agrárias e Biológicas: com Noções de Experimentação. 3ª ed. - Florianópolis: Ed da UFSC, 2017. 475p.

BANZATTO, D. A.; KRONKA, S. N. Experimentação Agrícola. 4. ed. Jaboticabal: FUNEP, 2013.

BARBIN, D. Planejamento e Análise Estatística de Experimentos Agronômicos. 2. ed. rev. ampl. - Londrina: Mecnas, 2013. 214p.

BUSSAB, W. O.; MORETTIN, P.A. Estatística Básica. 10^a ed. São Paulo: Saraiva, 2023. 624p.

FERREIRA, DANIEL F. Estatística Básica. 2^a ed. Lavras: Ed. UFLA, 2009.

FERREIRA, P.V. Estatística experimental aplicada à agronomia. 3^a ed. Maceió: EDUFAL, 2000. 419p.

FONSECA, J.S.; MARTINS, G.A. Curso de estatística. 6^a ed. São Paulo: Atlas, 1996. 320p.

GOMES, F. P. Curso de Estatística Experimental. 15. ed. Piracicaba: FEALQ, 2009.

MONTGOMERY, D. C.; RUNGER, G. C. Estatística Aplicada e Probabilidade para Engenheiros. 7. ed. Rio de Janeiro: LTC, 2024.

MORETTIN, P.A.; BUSSAB, W. O. Estatística Básica. 10. ed. São Paulo: SaraivaUni, 2023.

VIEIRA, S.; HOFFMANN, R. Estatística Experimental. São Paulo: Atlas, 1999.

2 Contexto Histórico da Estatística Experimental

Técnicas Experimentais em Agronomia é uma disciplina voltada à aplicação da Estatística em experimentos agronômicos. Seu objetivo é desenvolver nos estudantes a capacidade de planejar experimentos, definir delineamentos adequados, analisar corretamente os dados e interpretar os resultados de forma consistente.

Antes de entrar diretamente em métodos e modelos, vale fazer uma pergunta mais ampla: de onde vem a Estatística? Como ela se estruturou como área do conhecimento? E, principalmente, como passou a ocupar um papel central na experimentação agrônoma?

Entender esse percurso ajuda a situar a disciplina dentro de um processo maior de desenvolvimento científico. A Estatística não nasceu como a conhecemos hoje. Ela evoluiu de registros administrativos para se tornar uma ciência formal da variabilidade, da inferência e da tomada de decisão sob incerteza.

A origem da Estatística está ligada à organização do Estado. O termo deriva do latim *status* e do alemão *Statistik*, utilizado no século XVIII para descrever as condições políticas e econômicas dos países europeus (Stigler, 1986). Muito antes disso, civilizações como Egito, Babilônia, China e Roma já realizavam censos e registros de produção com fins administrativos e tributários. Porém, nesse momento, ainda não havia uma estrutura matemática que permitisse analisar a incerteza ou modelar a variabilidade.

A mudança começa no século XVII, com o surgimento da Teoria das Probabilidades. A correspondência entre Blaise Pascal e Pierre de Fermat, em 1654, ao discutirem problemas de jogos de azar, estabelece as bases do cálculo de probabilidades (Hacking, 1975). Pouco depois, John Graunt analisa tábuas de mortalidade em Londres e mostra que fenômenos coletivos apresentam padrões regulares.

No século XVIII, Jacob Bernoulli formaliza a Lei dos Grandes Números, Thomas Bayes apresenta o teorema que leva seu nome, e Pierre-Simon Laplace sistematiza a inferência probabilística. A partir daí, a Estatística deixa de ser apenas registro e passa a ser também modelo matemático da incerteza.

No século XIX, a noção de variabilidade ganha destaque. Carl Friedrich Gauss desenvolve o método dos mínimos quadrados e consolida o uso da distribuição normal na teoria dos erros. Adolphe Quetelet amplia a aplicação da Estatística ao estudar fenômenos sociais e biológicos, reforçando a ideia de que a variabilidade é parte natural dos fenômenos observados.

É no século XX, entretanto, que a Estatística assume o formato que mais nos interessa nesta disciplina. Karl Pearson desenvolve ferramentas como o coeficiente de correlação e o teste qui-quadrado, estruturando métodos formais de análise de associação. Mas a grande virada para a experimentação ocorre com Ronald Aylmer Fisher.

Trabalhando na *Rothamsted Experimental Station*, Fisher enfrentava um problema muito prático: como comparar tratamentos agrícolas em condições naturalmente heterogêneas? A resposta não foi apenas matemática, mas metodológica. Ele introduziu três princípios fundamentais do delineamento experimental:

- **Randomização:** para garantir validade da inferência;
- **Repetição:** para permitir a estimação do erro experimental;
- **Controle local:** para reduzir a variabilidade não controlada.

A partir daí, a Estatística Experimental passa a se diferenciar claramente da Estatística meramente observacional. Não se trata apenas de analisar dados já existentes, mas de **planejar previamente como os dados serão gerados**. A variabilidade deixa de ser um “problema” e passa a ser parte estruturante do modelo, algo que pode ser quantificado e controlado.

Na Agronomia, essa mudança foi decisiva. O solo não é homogêneo, o clima varia, há interação entre genótipo e ambiente, e os sistemas de manejo introduzem múltiplas fontes de variação. Sem delineamento experimental, as comparações entre tratamentos ficam comprometidas. A Estatística Experimental surge, portanto, como instrumento para garantir precisão, validade interna e reprodutibilidade dos resultados.

Posteriormente, Jerzy Neyman e Egon Pearson formalizam a teoria de testes de hipóteses, consolidando o arcabouço da inferência frequentista que sustenta grande parte das análises utilizadas até hoje.

Com o avanço computacional na segunda metade do século XX, a Estatística amplia ainda mais seu alcance. Simulações, reamostragem e métodos bayesianos passam a integrar a prática científica. Atualmente, a Estatística é também um dos pilares de Ciência de Dados, mas sua base continua sendo a mesma: modelar a variabilidade e tomar decisões sob incerteza.

Assim, ao longo de sua trajetória, a Estatística evoluiu de registros administrativos para uma ciência formal da variabilidade. No contexto da Agronomia, essa evolução se materializa na Estatística Experimental, que estrutura o planejamento, a análise e a interpretação de experimentos. É esse corpo metodológico que fundamenta as Técnicas Experimentais e sustenta a produção de conhecimento científico confiável nas Ciências Agrárias.

3 Introdução

A Estatística é uma ciência que se preocupa com o planejamento da pesquisa, envolvendo desde a forma de coleta das observações, obtidas por meio de experimentos ou levantamentos, até a maneira como esses dados são organizados, descritos e resumidos. Além disso, a Estatística fornece ferramentas para inferir sobre uma característica de interesse do pesquisador, permitindo tirar conclusões a partir das informações observadas.


Como já destacava H. G. Well (1993), “o pensamento estatístico será um dia tão necessário para o cidadão quanto a habilidade de ler e escrever”. Essa afirmação reforça a importância da Estatística não apenas na pesquisa científica, mas também na formação crítica do indivíduo.

As análises estatísticas dependem diretamente da forma como os dados são coletados. Por isso, o planejamento estatístico da pesquisa é fundamental, pois define o esquema sob o qual os dados serão obtidos. Um experimento mal planejado pode comprometer toda a análise posterior, independentemente do método estatístico utilizado. Na área de Agronomia, por exemplo, a definição do delineamento experimental, do número de repetições e da forma de controle da variabilidade são aspectos essenciais para que os resultados tenham validade científica.

De maneira geral, a Estatística pode ser dividida em duas grandes áreas: Estatística Descritiva e Inferência Estatística. A Estatística Descritiva envolve a organização e apresentação dos dados por meio de tabelas, gráficos e medidas numéricas, como medidas de posição e dispersão. Já a Inferência Estatística está relacionada à amostragem e aos métodos que permitem generalizar resultados para uma população, incluindo estimação por ponto e por intervalo, testes de hipóteses, correlação e regressão, além de métodos paramétricos e não paramétricos, regressão linear simples e múltipla e modelos lineares generalizados, como a regressão logística.

3.1 Áreas da Estatística

O esquema a seguir apresenta, de forma resumida, a estrutura da Estatística e suas principais subdivisões. Ele mostra como a Estatística Descritiva e a Inferência Estatística se organizam e como os diferentes conteúdos da disciplina se conectam entre si.



3.2 Conceitos importantes

Alguns conceitos são fundamentais para o entendimento da Estatística e serão utilizados ao longo de toda a disciplina.

- **População:** é o conjunto de todos os elementos que se deseja estudar e que possuam pelo menos uma característica em comum. Em experimentação agrônoma, pode representar, por exemplo, todas as possíveis parcelas cultivadas sob determinadas condições.
 - **Parâmetro:** é uma medida numérica que descreve uma característica de uma população, como a média real de produtividade ou a variância entre unidades experimentais.
- **Amostra:** é um subconjunto da população, selecionado para representar o todo. Na prática experimental, são as unidades efetivamente avaliadas no campo ou no laboratório.
 - **Estatística:** é uma medida numérica que descreve uma característica de uma amostra e que é utilizada para estimar o parâmetro populacional.
- **Variável** é um atributo, mensurável ou não, que está sujeito à variação quantitativa ou qualitativa no interior de uma população ou amostra. Em um experimento agrônomo, por exemplo, a produtividade, a altura de plantas ou a presença de determinada doença podem ser consideradas variáveis.

As variáveis podem ser classificadas em **qualitativas** e **quantitativas**, dependendo da natureza dos valores que assumem.

As variáveis **qualitativas** são aquelas que expressam atributos ou categorias, não sendo representadas por valores numéricos com significado quantitativo. Elas podem ser classificadas em **nominais** ou **ordinais**. As variáveis qualitativas **nominais** são aquelas cujas categorias não apresentam uma ordem natural entre si, como, por exemplo, espécie de cultura, tipo de solo ou cultivar. Já as variáveis qualitativas **ordinais** são aquelas cujas categorias apresentam uma ordenação ou hierarquia, embora não seja possível quantificar a diferença entre elas. Exemplos incluem níveis de severidade de doença (baixa, média e alta) ou classes de qualidade.

As variáveis quantitativas, por sua vez, são aquelas expressas por valores numéricos que representam quantidades mensuráveis. Elas podem ser classificadas em **discretas** ou **contínuas**. As variáveis quantitativas **discretas** assumem valores isolados, geralmente resultantes de contagem, como número de plantas por parcela ou número de frutos por planta. Já as variáveis quantitativas **contínuas** podem assumir qualquer valor dentro de um intervalo, sendo obtidas por meio de mensuração, como produtividade, altura de plantas ou teor de umidade.

- **Dados** são as informações observadas ou registradas relativas às variáveis, caracterizando os elementos que constituem a população ou a amostra em estudo. São, portanto, os valores efetivamente coletados durante a realização do experimento ou levantamento.

3.2.1 Censo ou amostragem

Em um estudo estatístico, o pesquisador pode optar por realizar um censo ou utilizar amostragem. A escolha entre essas duas abordagens depende, principalmente, dos objetivos do estudo, dos recursos disponíveis e das características da população.

Amostragem é o procedimento utilizado para selecionar a amostra, isto é, o conjunto de regras e etapas que definem como os elementos da população serão escolhidos. Um plano de amostragem bem estruturado é fundamental para garantir que a amostra seja representativa e que as inferências realizadas tenham validade.

Censo é a tentativa de observar ou medir todos os elementos da população. Nesse caso, não há seleção de parte dos elementos, pois busca-se obter informações completas sobre o universo em estudo.

Na prática, entretanto, a amostragem apresenta diversas vantagens em relação ao censo. Entre elas, destaca-se o custo reduzido, já que não é necessário avaliar todos os elementos da população. Além disso, há economia de tempo, o que permite que os resultados sejam obtidos com maior rapidez. Outro ponto importante é a possibilidade de aprofundamento na pesquisa, pois, ao trabalhar com um número menor de unidades, o pesquisador pode coletar informações mais detalhadas e realizar análises mais específicas.

3.3 Técnicas de amostragem

As técnicas de amostragem podem ser classificadas, de forma geral, em probabilísticas e não probabilísticas. Nas amostragens probabilísticas, todos os elementos da população possuem uma probabilidade conhecida e diferente de zero de serem selecionados. Esse tipo de procedimento permite o uso da Inferência Estatística, pois a seleção é realizada com base em mecanismos aleatórios, possibilitando estimar erros amostrais e construir intervalos de confiança.

Já nas amostragens não probabilísticas, a seleção dos elementos não é feita com base em probabilidades conhecidas, mas sim por critérios de conveniência, julgamento do pesquisador ou facilidade de acesso. Embora possam ser úteis em estudos exploratórios ou situações específicas, essas técnicas não garantem representatividade estatística e limitam a generalização dos resultados para a população.

3.3.1 Amostragem Simples ao Acaso – Probabilística

A amostragem simples ao acaso é um método probabilístico de seleção, no qual são escolhidos, sem reposição, n elementos de uma população, de forma que todos os elementos tenham a mesma probabilidade de serem incluídos na amostra. Nesse procedimento, a escolha é feita de maneira inteiramente aleatória, garantindo que não haja favorecimento de qualquer unidade da população.

Esse tipo de amostragem é indicado quando a população pode ser considerada homogênea em relação à característica de interesse, ou seja, quando não há subgrupos com comportamentos muito distintos. Nessas condições, a amostra tende a representar adequadamente a população, permitindo inferências com maior segurança.

Na área agrônômica, por exemplo, suponha que se deseje estimar a produtividade média de uma lavoura de soja considerada uniforme quanto ao manejo e às condições de solo. Se a área for relativamente homogênea, pode-se numerar todas as parcelas possíveis e selecionar aleatoriamente n delas para avaliação da produtividade. Como cada parcela tem a mesma chance de ser escolhida, a amostra tende a representar bem a lavoura como um todo.

Outro exemplo seria a seleção aleatória de plantas dentro de uma parcela experimental para medir altura ou número de vagens. Desde que as plantas estejam sob condições semelhantes, a escolha aleatória garante imparcialidade na seleção.

3.3.2 Amostragem Sistemática – Probabilística

A amostragem sistemática é um método probabilístico em que os elementos da população são selecionados segundo um critério sistemático previamente definido. Para realizar a seleção, divide-se o tamanho da população N pelo tamanho da amostra n , obtendo-se o valor do intervalo ou “salto” $s = \frac{N}{n}$. Em seguida, sorteia-se aleatoriamente um número entre 1 e s , que

determinará o primeiro elemento da amostra. A partir desse ponto, os demais elementos são selecionados somando-se sucessivamente o valor de s à posição inicialmente sorteada.

Os elementos selecionados na amostragem sistemática são:

$$i, i + s, i + 2s, i + 3s, \dots, i + (n - 1)s$$

Esse tipo de amostragem é indicado quando a população se encontra naturalmente ordenada, como em fichários, cadastros ou listas organizadas. Deve-se ter cuidado para que a ordenação não esteja relacionada à variável de interesse.

Exemplo: Em uma área cultivada com milho, pode-se selecionar uma planta a cada 10 plantas ao longo de uma linha de plantio, após o sorteio da primeira posição. Assim, mantém-se um critério sistemático de seleção ao longo da lavoura.

3.3.3 Amostragem Estratificada – Probabilística

A amostragem estratificada é utilizada quando a população apresenta heterogeneidade. Nesse tipo de amostragem, a população é inicialmente dividida em grupos mais homogêneos, denominados **estratos**. Em seguida, dentro de cada estrato, os elementos da amostra são selecionados por meio de sorteio.

Dessa forma, cada estrato da população fica representado na amostra, o que contribui para obter estimativas mais precisas das características de interesse.

Utilização: esse tipo de amostragem é indicado quando a população é heterogênea, mas pode ser dividida em grupos internamente homogêneos.

Exemplo: Considere uma área agrícola cultivada com soja que apresenta diferentes tipos de solo. A área pode ser dividida em estratos de acordo com o tipo de solo (por exemplo, solo argiloso, médio e arenoso). Em seguida, realiza-se o sorteio de pontos de amostragem dentro de cada estrato para coletar amostras de solo ou avaliar a produtividade. Dessa forma, cada tipo de solo será representado na amostra, permitindo uma avaliação mais adequada da área estudada.

3.3.4 Amostragem por Conveniência – Não probabilística

A amostragem por conveniência é um tipo de amostragem não probabilística em que os elementos da amostra são selecionados de acordo com a facilidade de acesso às informações pelo pesquisador. Nesse caso, os indivíduos são escolhidos por estarem mais disponíveis ou próximos, sem que todos os elementos da população tenham a mesma probabilidade de serem selecionados.

Esse tipo de amostragem é bastante utilizado em pesquisas exploratórias, especialmente na área de marketing.

Importante: como a seleção dos elementos não ocorre de forma aleatória, é necessário que o pesquisador tenha senso crítico ao interpretar os resultados, pois esse procedimento pode introduzir vieses e comprometer a representatividade da amostra.

Exemplo: Um pesquisador deseja avaliar a opinião de produtores sobre o uso de um novo fertilizante. Em vez de selecionar produtores aleatoriamente em toda a região, ele entrevista apenas os produtores presentes em um evento agrícola ou feira do setor. Nesse caso, a amostra foi obtida por conveniência, pois foram escolhidos os indivíduos mais fáceis de acessar.

3.3.5 Amostragem Intencional – Não probabilística

A amostragem intencional é um tipo de amostragem não probabilística em que os elementos da amostra são escolhidos deliberadamente pelo pesquisador, com base em seu conhecimento sobre a população e nos objetivos do estudo. Assim, são selecionados indivíduos que o pesquisador considera mais representativos ou mais informativos para a pesquisa.

Esse tipo de amostragem é comum quando se deseja obter informações específicas de determinados grupos ou indivíduos com características particulares.

Exemplo: Um pesquisador deseja avaliar práticas de manejo utilizadas por produtores com alta produtividade de milho em determinada região. Em vez de selecionar produtores aleatoriamente, ele escolhe intencionalmente aqueles reconhecidos por apresentarem altos níveis de produtividade. Dessa forma, a amostra é formada por produtores que possuem maior experiência ou desempenho na atividade estudada.

3.3.6 Amostragem por Quota – Não probabilística

A amostragem por quota é um tipo de amostragem não probabilística que, em uma fase inicial, se assemelha à amostragem estratificada proporcional. Nesse procedimento, a população é dividida em grupos de acordo com determinadas características e estabelece-se uma **quota de elementos** a ser selecionada em cada grupo, proporcional ao seu tamanho na população.

Entretanto, diferentemente da amostragem estratificada probabilística, a seleção dos indivíduos dentro de cada grupo não é realizada por sorteio, mas sim pela escolha do pesquisador ou entrevistador.

Esse tipo de amostragem é bastante utilizado em **pesquisas de opinião e estudos de mercado**, tendo sido amplamente empregado em **pesquisas eleitorais**, embora atualmente muitos institutos utilizem métodos probabilísticos mais rigorosos.

Importante: por não envolver seleção aleatória dos indivíduos dentro de cada grupo, a amostragem por quota pode sofrer influência de tendências, preferências e outros fatores subjetivos do pesquisador ou entrevistador, o que pode introduzir vieses nos resultados.

Exemplo: Um pesquisador deseja avaliar a opinião de produtores rurais sobre o uso de sementes transgênicas em uma determinada região. Sabendo que na região existem 60% de pequenos produtores e 40% de grandes produtores, ele define que a amostra deverá seguir essa mesma proporção. Assim, entrevista produtores até completar a quota estabelecida para cada grupo. Nesse caso, as proporções dos grupos são respeitadas, porém os produtores entrevistados não são selecionados de forma aleatória.

3.3.7 Dimensionamento da amostra

A determinação do tamanho da amostra depende de alguns fatores:

1. **Tamanho da população:** finita (N) ou infinita.
2. **Variância ou percentual:** dependendo do tipo de variável estudada, utiliza-se a variância (para variáveis quantitativas) ou a proporção/percentual (para variáveis qualitativas).
3. **Nível de confiança:** probabilidade de acerto associada à estimativa, geralmente 95% ou 99%.
4. **Informações na literatura:** valores prévios da proporção (π) ou da variância (σ^2), obtidos em estudos anteriores.
5. **Erro de amostragem ou precisão (ϵ):** margem de erro admitida para a estimativa.

3.3.8 Determinação do tamanho amostral para variáveis qualitativas

Quando se dispõe de **variáveis qualitativas**, utiliza-se a seguinte fórmula para população considerada infinita:

$$n_0 = \frac{z^2 \pi (1 - \pi)}{\epsilon^2}$$

em que:

- ϵ = erro de precisão (margem de erro);
- π = proporção obtida em trabalhos anteriores;
- z = valor da distribuição normal associado ao nível de confiança;
- n_0 = tamanho inicial da amostra.

3.3.9 Determinação do tamanho amostral para variáveis quantitativas

Quando se dispõe de **variáveis quantitativas**, utiliza-se a seguinte fórmula para população considerada infinita:

$$n_0 = \frac{z^2 \sigma^2}{\epsilon^2}$$

em que:

- σ^2 = variância da variável de interesse, obtida em trabalhos anteriores ou em estudos piloto;
- z = valor da distribuição normal associado ao nível de confiança;
- ϵ = erro de precisão;
- n_0 = tamanho inicial da amostra.

Observação: nos dois casos, quando a população é **finita**, deve-se aplicar a correção:

$$n = \frac{n_0}{1 + \frac{n_0}{N}}$$

em que N representa o tamanho da população.

3.4 Introdução ao R

O **R** é um software livre utilizado para análise estatística e produção de gráficos. Por ser um Software Livre, seu código-fonte está disponível publicamente e atualmente é gerenciado por um grupo de desenvolvedores chamado R Core Development Team.

Informações sobre os colaboradores do projeto podem ser encontradas em:

<https://www.r-project.org/contributors.html>

Uma das vantagens de possuir código aberto é que eventuais falhas podem ser detectadas e corrigidas rapidamente, e novas atualizações podem ser disponibilizadas em poucos dias.

O R é fornecido originalmente como um programa com interface de linha de comando, que é preferida por usuários mais experientes, pois permite maior controle sobre as análises e maior flexibilidade na execução dos cálculos.

O aprendizado da interface de linha de comando costuma ser mais demorado do que o uso de interfaces gráficas. Entretanto, esse esforço é geralmente recompensado, pois permite:

- melhor compreensão do plano de análise;
- comandos que podem ser facilmente salvos e reutilizados;

- maior rastreabilidade das etapas realizadas na análise.

A interface com o usuário é uma das principais diferenças entre o **R**, o **S-PLUS** e outros programas de análise estatística. Existem diversas iniciativas de interfaces gráficas para o R, mas muitas delas são voltadas principalmente para usuários iniciantes e não oferecem todas as funcionalidades disponíveis na linguagem.

3.4.1 Download do R

Para instalar o R, siga os passos abaixo:

1. Acesse o site: <https://www.r-project.org>
2. Clique em CRAN (Comprehensive R Archive Network).
3. Escolha um servidor para download. Atualmente existem servidores também no Brasil.
4. Escolha a versão compatível com o seu sistema operacional.

Por exemplo, para Windows:

- Clique em **Download R for Windows**.
- Clique em **Install R for the first time**.
- Clique em **Download R (versão atual) for Windows**.

3.4.2 RStudio

O **RStudio** é um ambiente de desenvolvimento integrado (IDE) que facilita o uso do R, fornecendo interface gráfica, editor de scripts, visualização de objetos e ferramentas para organização dos projetos.

Para fazer o download do RStudio acesse:

<https://posit.co/download/rstudio-desktop/>

Outra opção é utilizar a versão online, disponível em:

<https://posit.cloud>

3.4.2.1 Informações Básicas do R

Alguns comandos úteis no R são:

- Informações sobre a licença do R

```
license()
```

- Como citar o R em trabalho científicos

```
citation()
```

- Demonstrações de uso do R

```
demo()
```

- Solicitar ajuda sobre uma função

```
help()  
help.start()
```

4 Estatística Descritiva

4.1 Introdução

Em experimentos agronômicos é comum coletar diferentes tipos de informações, como produtividade, altura de plantas, número de vagens ou características dos cultivares avaliados. Essas informações precisam ser organizadas e analisadas de forma adequada para que seja possível compreender o comportamento das variáveis estudadas e interpretar os resultados obtidos no experimento.

A Estatística fornece ferramentas que permitem organizar, resumir, analisar e interpretar dados, auxiliando o pesquisador na obtenção de conclusões a partir das informações coletadas.

Áreas da Estatística

De forma geral, a Estatística pode ser dividida em duas grandes áreas: **estatística descritiva** e **estatística indutiva**.

A **estatística descritiva** tem como objetivo organizar, descrever e resumir um conjunto de dados, permitindo uma visualização mais clara das informações coletadas. Para isso, utiliza ferramentas como tabelas, gráficos e medidas numéricas, que ajudam a sintetizar as principais características dos dados.

A **estatística indutiva**, também chamada de **estatística inferencial**, está relacionada à análise e interpretação dos dados. Seu objetivo é permitir que sejam feitas conclusões sobre uma população com base em informações obtidas a partir de uma amostra dessa população.

Variáveis e Dados

Para a realização de análises estatísticas é importante compreender alguns conceitos básicos.

Uma **variável** é uma característica ou atributo observado em cada elemento de uma população ou amostra, que pode assumir diferentes valores ou categorias. Essa variação pode ocorrer entre os indivíduos avaliados em um experimento ou levantamento de dados.

Os **dados** correspondem aos valores observados ou medidos para cada variável. Em outras palavras, são as informações obtidas durante a coleta de dados e que descrevem as características dos elementos que compõem a população ou a amostra em estudo.

Tipos de Variáveis

As variáveis observadas em um estudo podem ser classificadas em **qualitativas** ou **quantitativas**, dependendo da forma como seus valores são expressos.

As **variáveis qualitativas** descrevem características ou categorias dos indivíduos e não são expressas numericamente. Elas podem ser divididas em dois tipos. As **variáveis qualitativas nominais** representam categorias sem uma ordem natural entre elas, como gênero, estado civil ou tipo de grão (dentado, semidentado e semiduro). Já as **variáveis qualitativas ordinais** apresentam categorias que possuem uma ordenação lógica, como grau de escolaridade ou níveis de resistência à ferrugem ($r > mr > ms > s$).

As **variáveis quantitativas**, por sua vez, são expressas por valores numéricos e representam quantidades mensuráveis. Essas variáveis podem ser classificadas em **discretas** ou **contínuas**. As **variáveis quantitativas discretas** assumem valores inteiros resultantes de contagens, como número de filhos, número de grãos por viagem ou número de vagens por planta. Já as **variáveis quantitativas contínuas** podem assumir qualquer valor dentro de um intervalo, sendo obtidas por meio de medições, como peso, altura da planta ou altura da espiga.

Conjunto de Dados

A seguir é apresentado um conjunto de dados que será utilizado nos exemplos ao longo desta apostila. Esses dados foram adaptados do livro *Estatística para as Ciências Agrárias e Biológicas: com Noções de Experimentação* (ANDRADE (2017)) e são utilizados aqui para fins didáticos. O arquivo também pode ser acessado e baixado pelo link [Conjunto de dados do experimento com milho](#)

Nesse conjunto de dados é possível identificar diferentes tipos de variáveis, tanto qualitativas quanto quantitativas, que serão utilizadas para ilustrar as técnicas de estatística descritiva apresentadas nas próximas seções.

Tabela 4.1: Resultados de um experimento de competição de híbridos de milho para a região de Chapecó, SC - safra: 1987/1988

Híbridos	Rendimento médio (kg/ha)	Ciclo (dias)	Altura planta (cm)	Altura espiga (cm)	Tipo de grão	Resistência à ferrugem ¹
1	6388	65	242	103	dentado	r
2	6166	65	258	134	semidentado	r
3	6047	65	240	104	semidentado	s
4	5889	66	243	108	semidentado	s
5	5823	69	257	128	dentado	ms
6	5513	68	241	108	semidentado	s
7	5202	64	235	108	dentado	r
8	5172	68	240	103	dentado	s
9	5166	69	253	123	dentado	ms
10	4975	70	250	117	semidentado	ms
11	4778	70	242	114	dentado	mr
12	4680	66	245	111	semiduro	ms
13	4660	69	239	110	semiduro	mr
14	5403	73	264	138	dentado	ms
15	5117	76	282	149	dentado	mr
16	5063	72	274	151	dentado	r
17	4993	71	279	134	semidentado	r
18	4980	72	274	140	dentado	ms
19	4770	73	244	140	dentado	r
20	4685	71	265	139	semiduro	mr
21	4614	73	248	110	semidentado	r
22	4552	73	265	128	semidentado	r
23	3973	74	261	124	semidentado	mr
24	4550	71	259	129	semiduro	s
25	5056	64	252	104	semiduro	mr
26	4500	70	271	109	dentado	ms
27	4760	68	243	137	semiduro	r
28	5110	66	252	141	semidentado	ms
29	4960	70	262	120	dentado	ms
30	4769	73	260	118	dentado	r
31	4849	74	250	119	semidentado	s
32	5230	71	255	138	semiduro	s

Fonte: Andrade, D. F.; Ogliari, P. J. Estatística para as ciências agrárias e biológicas: com noções de experimentação. 3º ed. - Florianópolis: Ed. da UFSC, 2017.

¹r=resistente; mr=moderadamente resistente; ms=moderadamente susceptível; s=susceptível

Importando os dados no software R

```
dados=read.table(  
  "https://pessoal.uel.br/biz/wp-content/uploads/2025/06/dados_milho.txt",  
  head=T)  
head(dados)
```

	Hibrido	Rendimento	Ciclo	Altura_planta	Altura_espiga	Grao	Resistencia
1	1	6388	65	242	103	dentado	r
2	2	6166	65	258	134	semidentado	r
3	3	6047	65	240	104	semidentado	s
4	4	5889	66	243	108	semidentado	s
5	5	5823	69	257	128	dentado	ms
6	6	5513	68	241	108	semidentado	s

Dados Brutos e Rol

Após a obtenção dos dados em uma pesquisa ou experimento, a primeira etapa da análise estatística consiste em organizar essas informações. Inicialmente, os dados são registrados exatamente como foram observados, sendo denominados dados brutos.

Dados brutos são os dados obtidos diretamente da pesquisa, sem terem passado por qualquer processo de organização, síntese ou análise. Nessa forma, os valores aparecem na mesma ordem em que foram coletados.

Uma maneira simples de organizar os dados é colocá-los em ordem crescente, formando o chamado rol.

Rol é o conjunto de dados disposto em ordem crescente (ou decrescente), o que facilita a visualização da distribuição dos valores e constitui o primeiro passo para outras formas de organização dos dados.

A seguir são apresentados os valores da variável altura de espiga, inicialmente na forma de dados brutos e, posteriormente, organizados em rol.

Dados brutos

Rol

Tabela 4.2: Alturas de espigas (cm) de híbridos de milho para a região de Chapecó, SC - safra: 1987/1988

103	128	123	110	134	110	104	120
134	108	117	138	140	128	109	118
104	108	114	149	140	124	137	119
108	103	111	151	139	129	141	138

Tabela 4.3: Rol das Alturas de espigas (cm) de híbridos de milho para a região de Chapecó, SC - safra: 1987/1988

103	103	104	104	108	108	108	109
110	110	111	114	117	118	119	120
123	124	128	128	129	134	134	137
138	138	139	140	140	141	149	151

4.2 Representação Tabular e Gráfica

Uma forma bastante utilizada para organizar e apresentar dados é por meio de tabelas, pois elas permitem visualizar as informações de maneira estruturada e facilitar a interpretação dos resultados.

De modo geral, uma tabela é composta pelos seguintes elementos:

- **Título:** indica a natureza do fenômeno estudado, as variáveis analisadas, bem como o local e o período de referência dos dados.
- **Corpo:** corresponde ao conjunto de linhas e colunas que contém os dados apresentados na tabela.
- **Cabeçalho:** identifica o conteúdo de cada coluna.
- **Coluna indicadora:** identifica o conteúdo de cada linha.

A organização dos dados em tabelas constitui um passo importante na análise estatística. Entretanto, quando o conjunto de dados é grande, torna-se difícil interpretar os valores apenas observando os dados individuais. Nesses casos, é comum resumir as informações por meio de tabelas de distribuição de frequências, que apresentam o número de ocorrências de cada valor ou classe de valores da variável analisada.

4.2.1 Distribuições de frequências de variáveis qualitativas e representações gráficas

Após a organização inicial dos dados em tabelas, uma forma bastante utilizada de resumir e interpretar as informações é por meio das tabelas de distribuição de frequências.

Uma tabela de distribuição de frequências estabelece a correspondência entre as categorias ou valores de uma variável e o número de vezes em que essas categorias ocorrem no conjunto de dados. Dessa forma, é possível observar como os dados estão distribuídos entre as diferentes categorias da variável analisada.

Para variáveis qualitativas, como é o caso da resistência à ferrugem dos híbridos de milho, as categorias representam diferentes classificações do fenômeno observado. A partir dessas categorias podem ser calculadas:

- a **frequência absoluta** (n_i), que corresponde ao número de observações em cada categoria;
- a **frequência relativa** (f_i), que representa a proporção de observações em relação ao total;
- a **porcentagem**, que expressa a frequência relativa em termos percentuais;
- a **porcentagem acumulada**, que indica a soma progressiva das porcentagens.

A Tabela 4.4 a seguir apresenta a distribuição de frequências da variável *resistência à ferrugem* para 32 híbridos de milho recomendados para a região de Chapecó, SC, na safra 1987/1988.

Tabela 4.4: Distribuição de Frequências da resistência à ferrugem de 32 híbridos de milho recomendados para a região de Chapecó, safra 1987/88.

Resistência à ferrugem	Frequência absoluta (n_i)	Frequência relativa (f_i)	Porcentagem (%)	Porcentagem acumulada
r	10	0,3125	31,25	31,25
mr	6	0,1875	18,75	50,00
ms	9	0,2813	28,13	78,13
s	7	0,2187	21,87	100,00
Total	32	1	100	-

Essa distribuição pode ser obtida diretamente a partir do conjunto de dados utilizando funções disponíveis no R. A seguir apresenta-se um exemplo de construção dessa tabela utilizando o pacote ‘epiDisplay’.

```
library(epiDisplay)
tab1(factor(dados$Resistencia, levels = c("r", "mr", "ms", "s")))
```

Gráficos para variáveis qualitativas – Colunas

O gráfico de colunas representa as categorias da variável no eixo horizontal e as respectivas frequências no eixo vertical. Cada coluna possui altura proporcional ao número de observações da categoria correspondente.

```
barplot(table(dados$Resistencia)[c("r","mr","ms","s")],  
        xlab="Resistência à ferrugem",ylab="Frequências",col="green4",  
        density=50,ylim=c(0,12))  
abline(h=0)
```




Figura: Resistência à ferrugem de híbridos de milho, para a região de Chapecó, 1987/88

Gráficos para variáveis qualitativas – Barras

O gráfico de barras apresenta a mesma informação do gráfico de colunas, porém com as barras dispostas horizontalmente. Esse tipo de representação pode facilitar a visualização quando os nomes das categorias são longos ou quando se deseja destacar as diferenças entre as frequências.

```
barplot(table(dados$Resistencia)[c("r","mr","ms","s")],  
        ylab="Resistência à ferrugem",xlab="Frequências",col="green4",  
        density=50,xlim=c(0,12),horiz = T)  
abline(v=0)
```




Figura: Resistência à ferrugem de híbridos de milho, para a região de Chapecó, 1987/88

Gráficos para variáveis qualitativas – Setores

No gráfico de setores, também conhecido como gráfico de pizza, cada categoria é representada por um setor do círculo. A área de cada setor é proporcional à frequência ou porcentagem correspondente, permitindo visualizar a participação relativa de cada categoria no total de observações.

```
resis=table(dados$Resistencia)[c("r","mr","ms","s")]
names(resis)=paste(c("resistentes","mod. resistentes","mod. susceptível",
                    "susceptível"),round(100*resis/sum(resis),2),"%")
pie(resis,col=c("green4","blue","white","black"),
    density=c(100,100,80,20),border="black")
```




Figura: Resistência à ferrugem de híbridos de milho, para a região de Chapecó, 1987/88

Os gráficos apresentados ilustram diferentes formas de representar as mesmas informações contidas na tabela de distribuição de frequências. A escolha do tipo de gráfico depende do objetivo da análise e da forma como se deseja destacar as características dos dados.

A seguir são propostos exercícios para a construção de tabelas de distribuição de frequências e de representações gráficas para variáveis qualitativas.

Exercícios

1. Construa uma tabela de distribuição de frequências para a variável “Tipo de grão” de um experimento de competição de híbridos de milho para a região de Chapecó, SC - safra: 1987/1988 (ANDRADE; OGLIARI, 2010, p. 62) e ilustre dois gráficos indicados.

4.2.2 Distribuições de frequências de variáveis quantitativas discretas e representações gráficas

Em experimentos agrônômicos é comum a coleta de variáveis numéricas que assumem valores inteiros e contáveis, como, por exemplo, o número de plantas emergidas por parcela, o número de espigas por planta, o número de grãos por vagem ou o número de insetos por planta. Esse tipo de variável é denominado variável quantitativa discreta, pois seus valores resultam de processos de contagem.

A organização inicial dessas informações pode ser realizada por meio de tabelas de distribuição de frequências, que permitem resumir os dados observados e facilitar sua interpretação. A construção dessas tabelas para variáveis quantitativas discretas é semelhante à realizada para variáveis qualitativas. Nesse caso, cada valor numérico observado da variável corresponde a uma categoria da tabela, sendo apresentadas as respectivas frequências absolutas, frequências relativas e, quando necessário, as frequências acumuladas.

Além da representação tabular, a representação gráfica constitui uma importante ferramenta para a visualização do comportamento dos dados. Para variáveis quantitativas discretas, os gráficos mais utilizados são o gráfico de bastões, o gráfico de barras e o gráfico de colunas, os quais permitem visualizar com facilidade a distribuição das observações entre os diferentes valores da variável estudada.

A seguir é apresentado um exercício baseado em dados de experimentação agrícola, com o objetivo de ilustrar a construção de uma tabela de distribuição de frequências para uma variável quantitativa discreta.

Exemplo: Distribuição de frequências para variável quantitativa discreta

Considere a variável Ciclo (dias) de um experimento de competição de híbridos de milho conduzido na região de Chapecó (SC), na safra 1987/1988 (ANDRADE; OGLIARI, 2010). O ciclo corresponde ao número de dias necessários para que o híbrido complete seu desenvolvimento até a maturidade fisiológica.

Como se trata de uma variável numérica obtida por contagem de dias, ela pode ser tratada como uma variável quantitativa discreta. Para compreender melhor o comportamento dos dados, pode-se organizar as observações em uma tabela de distribuição de frequências, indicando quantas vezes cada valor da variável ocorre no conjunto de dados.

A seguir apresenta-se a construção da tabela de distribuição de frequências utilizando o software R.


```
library(epiDisplay)
tab1(dados$Ciclo)
```

dados\$Ciclo :

	Frequency	Percent	Cum. percent
64	2	6.2	6.2
65	3	9.4	15.6
66	3	9.4	25.0
68	3	9.4	34.4
69	3	9.4	43.8
70	4	12.5	56.2
71	4	12.5	68.8
72	2	6.2	75.0
73	5	15.6	90.6
74	2	6.2	96.9
76	1	3.1	100.0
Total	32	100.0	100.0

A distribuição também pode ser representada graficamente. Para variáveis quantitativas discretas, uma representação bastante utilizada é o gráfico de bastões, no qual cada valor da variável é representado por um bastão cuja altura corresponde à sua frequência.

```
plot(table(dados$Ciclo),las=1,ylab = "Frequência",xlab="Ciclo")
```



4.2.3 Distribuições de frequências de variáveis quantitativas contínuas e representações gráficas

Na experimentação agrônômica, muitas variáveis de interesse não são obtidas por contagem, mas sim por processos de medição, como por exemplo: altura de plantas, produtividade de grãos, massa de matéria seca, diâmetro de colmo ou teor de umidade. Essas variáveis podem assumir qualquer valor dentro de um intervalo de números reais e, por essa razão, são denominadas variáveis quantitativas contínuas.

Quando o número de valores observados é relativamente grande, torna-se pouco prático apresentar cada valor individualmente. Assim, os dados são organizados em classes ou intervalos de valores, permitindo uma visualização mais clara do comportamento da variável.

A construção de uma tabela de distribuição de frequências com classes envolve algumas etapas básicas, apresentadas a seguir.

- Calcular a amplitude total dos dados:

$$A_t = n \text{ do maior} - n \text{ do menor} = x_{max} - x_{min}.$$

- Não existindo um critério “rígido” para estabelecer o número de intervalos, sugere-se não utilizar menos de 5 e não mais de 15 intervalos.

$$k = \sqrt{(n)}, \quad \text{ou} \quad k = \sqrt{(n)} - 1, \quad \text{ou} \quad k = 1 + 3,3\log(n).$$

- O intervalo das classes pode ser obtido dividindo-se a amplitude total pelo número de classes:

$$a_c = \frac{A_t}{k}.$$

A seguir apresenta-se um exemplo envolvendo dados de rendimento médio de híbridos de milho, expressos em kg/ha. A tabela mostra a distribuição de frequências considerando classes de rendimento.

Tabela: Distribuição de frequências dos rendimentos médios, em kg/ha, de 32 híbridos de milho recomendados para o Oeste catarinense, 1987/88

Rendimento médio (kg/ha)	Freq. abs. (n_i)	Freq. acum. (N_i)	Freq. rel. (f_i)	Freq. rel. acum. (F_i)	Porc. %	Porc. acum.
3973 ┤ 4457	1	1	0,031	0,031	3,1	3,1
4457 ┤ 4941	12	13	0,375	0,406	37,5	40,6
4941 ┤ 5425	13	26	0,406	0,812	40,6	81,2
5425 ┤ 5909	3	29	0,094	0,906	9,4	90,6
5909 ┤ 6393	3	32	0,094	1,000	9,4	100,0
TOTAL	32	—	1	—	100	—

```
require(fdth)
tab=fdt(dados$Rendimento,start = 3973,end = 6393,h = 484)
tab
```

Gráficos para variáveis contínuas


Após a construção da tabela de distribuição de frequências, os dados podem ser representados graficamente. Para variáveis quantitativas contínuas organizadas em classes, as representações gráficas mais utilizadas são:

- Histograma
- Polígono de frequências

Esses gráficos permitem visualizar a forma da distribuição dos dados, identificando concentrações de observações em determinadas classes, bem como possíveis assimetrias ou dispersões.


Histograma

```
s=seq(min(dados$Rendimento),6393,484)
hist(dados$Rendimento,breaks=s,xaxt="n",ylim=c(0,14),border="black",
      xlab="Rendimento médio (kg/ha)",density=30, las=1,
      ylab="Densidade de frequências",col="green4",main="")
axis(1,s,line=-.35)
abline(h=0,cex=4)
```



Polígono de frequências

```
tab=hist(dados$Rendimento,breaks=s,plot=F)
pontosmedios=c(3731,tab$mids,6635)
fr=c(0,tab$counts,0)
plot(pontosmedios,fr,type="l",lwd=2,xlab="Rendimento médio (kg/ha)",
      ylab="Densidade de frequência",las=1,bty="l",xaxt="n",axes=F,ylim=c(0,14))
axis(1,pontosmedios,line=-.35)
axis(2,tab$counts,las=1)
abline(h=0)
```



Exercício

2. Construa a tabela de distribuição de frequências para a variável *Altura de plantas* de um experimento de competição de híbridos de milho conduzido na região de Chapecó (SC), safra 1987/1988 (ANDRADE; OGLIARI, 2010, p. 62).

Utilize 6 classes e construa também os gráficos indicados para variáveis quantitativas contínuas.

Resposta - Exercício 2


Tabela: Distribuição de frequências das Altura de plantas de 32 híbridos de milho recomendados para o Oeste catarinense, 1987/88

Altura das plantas	n_i	N_i	f_i	F_i	%	Porc. acumulada	$\bar{x}_i$
235 ┤ 243	7	7	0,21875	0,21875	21,875	21,875	239
243 ┤ 251	7	14	0,21875	0,43750	21,875	43,750	247
251 ┤ 259	6	20	0,18750	0,62500	18,750	62,500	255
259 ┤ 267	7	27	0,21875	0,84375	21,875	84,375	263
267 ┤ 275	3	30	0,09375	0,93750	9,375	93,750	271
275 ┤ 283	2	32	0,06250	1,00000	6,250	100,000	279
Total	32	—	1	—	100	—	—

```
tab=fdt(dados$Altura_planta,start=235,end=283,h = 8)
```

Histograma

```
plot(tab,col="green4",density=50,border="black",xlab = "Altura de Plantas",
      ylab="Freq. Abs.",las=1)
```



4.3 Medidas Descritivas

Nas seções anteriores foram apresentadas formas de organizar e visualizar os dados por meio de tabelas de distribuição de frequências e representações gráficas. Essas ferramentas permitem compreender a forma geral da distribuição e identificar padrões ou concentrações de valores observados em experimentos.

Outra maneira importante de resumir os dados de uma variável quantitativa consiste em apresentá-los por meio de valores numéricos, denominados medidas descritivas. Essas medidas sintetizam as informações do conjunto de dados em poucos números, facilitando a interpretação e a comparação entre diferentes experimentos ou tratamentos.

As medidas descritivas auxiliam na análise do comportamento dos dados, permitindo descrever características como tendência central, variabilidade e dispersão das observações. Dependendo do contexto, esses dados podem ser provenientes de uma população ou de uma amostra.

Quando as medidas são calculadas utilizando todos os elementos de uma população, elas são denominadas parâmetros populacionais. Por outro lado, quando são obtidas a partir de uma amostra, recebem o nome de estatísticas amostrais.

Medidas	Parâmetros	Estatísticas
Nº de elementos	N	n
Média	μ	$\bar{x}$
Variância	σ^2	s^2
Desvio Padrão	σ	s

Nas próximas subseções serão apresentadas algumas das principais medidas descritivas utilizadas na análise de dados experimentais, frequentemente empregadas na interpretação de resultados em experimentos agronômicos.

4.3.1 Medidas de Posição

As medidas de tendência central são assim denominadas por indicarem um ponto em torno do qual se concentram os dados. Esse ponto pode ser interpretado como o centro da distribuição, representando um valor típico do conjunto de observações.

Entre as principais medidas de tendência central destacam-se a média, a mediana e a moda, cada uma delas fornecendo uma forma diferente de representar o comportamento central dos dados.

4.3.1.1 Média Aritmética

A média aritmética ($\bar{x}$) é definida como a soma de todos os valores observados da variável dividida pelo número total de observações. Trata-se da medida de tendência central mais utilizada em Estatística.

Sob uma interpretação geométrica, a média de uma distribuição pode ser vista como o centro de gravidade do conjunto de dados, isto é, o ponto de equilíbrio da distribuição.

Seja $(x_1, x_2, \dots, x_n)$ um conjunto de dados. A média aritmética é dada por

$$\mu = \frac{\sum_{i=1}^N x_i}{N} \quad \text{ou} \quad \bar{x} = \frac{\sum_{i=1}^n x_i}{n}.$$

Em geral, utiliza-se μ para representar a média populacional e $\bar{x}$ para indicar a média calculada a partir de uma amostra.

Caso os dados estejam apresentados segundo uma distribuição de frequências, tem-se

$$\mu = \frac{\sum_{i=1}^k \bar{x}_i n_i}{N} \quad \text{ou} \quad \bar{x} = \frac{\sum_{i=1}^k \bar{x}_i n_i}{n}.$$

Observe que, no caso de dados agrupados, a média é obtida a partir de uma ponderação, em que os pesos são as frequências absolutas de cada classe (n_i) e $\bar{x}_i$ é o ponto médio da classe i .

Observações

1. A média é única para um conjunto de dados e nem sempre coincide com um valor observado.
2. A média é afetada por valores extremos.
3. Quando existem valores discrepantes no conjunto de dados, a média pode não ser a medida mais apropriada para representar o comportamento dos dados.
4. Uma propriedade importante da média é que a soma dos desvios de cada valor observado em relação à média é igual a zero, isto é,

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

Exemplo 1

A seguir apresenta-se um conjunto de dados referentes à resistência de uvas Niágara. Os valores correspondem às medições fornecidas por produtores no ano de 2002.

Com base nesses dados, calcula-se a média aritmética da variável resistência.

Tabela 4.6: Rol de resistência, em N, de uvas Niágara, fornecida por produtores em 2002

0.50	0.52	0.54	0.58	0.59	0.61	0.63	0.64	0.64
0.67	0.69	0.70	0.72	0.73	0.73	0.75	0.75	0.76
0.76	0.76	0.76	0.80	0.82	0.82	0.83	0.84	0.87
0.89	0.92	0.94	0.99	1.00	1.04	1.04	1.10	1.80

A média pode ser obtida diretamente a partir dos dados brutos utilizando o software R.

```
resis=scan(dec=".", text= "
0,92 1,80 1,00 0,94 0,76 0,72 0,50 1,10 0,99 0,70 0,73 0,89 0,64 0,76 0,84
0,63 0,75 0,83 0,82 0,59 0,58 0,54 0,87 0,80 0,82 0,64 0,76 1,04 0,73 1,04
0,67 0,76 0,75 0,61 0,69 0,52")
mean(resis)
```

Exemplo 2 - Dados agrupados em classes

Em muitas situações os dados não estão disponíveis individualmente, sendo apresentados na forma de distribuições de frequências agrupadas em classes. Nesses casos, a média é calculada utilizando-se os pontos médios das classes

Utilizando a tabela abaixo, calcule a média da resistência de uvas Niágara.

Tabela 4.7: Distribuição de frequências das resistências de uvas Niágara

Resistência	Freq. (n_i)	Freq. (f_i)	Freq. (N_i)	Ponto ($\bar{x}_i$)	$n_i\bar{x}_i$
0,50 ┤ 0,72	12	0,33	12	0,61	7,32
0,72 ┤ 0,94	17	0,47	29	0,83	14,11
0,94 ┤ 1,16	6	0,17	35	1,05	6,30
1,16 ┤ 1,38	0	0,00	35	1,27	0,00
1,38 ┤ 1,60	0	0,00	35	1,49	0,00
1,60 ┤ 1,82	1	0,03	36	1,71	1,71
Total	36	1,00	—	—	29,44

O cálculo também pode ser realizado no **R**, utilizando a tabela de frequências obtida a partir dos dados originais.

```
tabres=fdth::fdt(resis,start = .5,h=.22,end=1.82)
tabres
mean(tabres)
```

Exercício

Calcule a média da variável rendimento médio de híbridos de milho utilizando:

1. os **dados brutos**;
2. os **dados agrupados em classes** apresentados na tabela.

Tabela 4.8: Distribuição de frequências dos rendimentos médios, em kg/ha, de 32 híbridos de milho recomendados para o Oeste catarinense, 1987/88

Rendimento médio (kg/ha)	Freq. abs. (n_i)	Freq. rel. (f_i)	Ponto médio ($\bar{x}_i$)
3973 ─ 4457	1	0,031	—
4457 ─ 4941	12	0,375	—
4941 ─ 5425	13	0,406	—
5425 ─ 5909	3	0,094	—
5909 ─ 6393	3	0,094	—
Total	32	1,000	—

4.3.1.2 Moda

A moda (M_o) é definida como o valor que apresenta a maior frequência entre os dados observados. Em outras palavras, é o valor que ocorre com maior repetição em um conjunto de dados.

Para dados não agrupados (valores individuais), a moda pode ser identificada diretamente por meio da contagem da frequência absoluta de cada valor, sendo aquele mais frequente considerado a moda. Essa medida é particularmente útil em situações em que se deseja identificar o valor mais comum ou típico de uma variável.

Quando os dados estão organizados em uma distribuição de frequências com classes, a identificação da moda não é imediata. Nesse caso, utiliza-se uma expressão para estimar a moda dentro da classe modal (classe com maior frequência):

$$M_o = l_i + \frac{\Delta_1}{\Delta_1 + \Delta_2} \cdot a_c$$

em que: l_i = limite inferior da classe modal a_c = amplitude da classe Δ_1 = diferença entre a frequência da classe modal e a frequência da classe anterior Δ_2 = diferença entre a frequência da classe modal e a frequência da classe posterior A utilização dessa fórmula permite obter uma estimativa mais precisa da posição da moda dentro da classe modal. A moda é uma medida de tendência central simples e de rápida interpretação, sendo especialmente útil quando

há interesse em identificar o valor mais frequente. Além disso, não é influenciada por valores extremos (outliers).

Exemplo

Utilizando a tabela a seguir, na qual está apresentada a distribuição de frequências da resistência de uvas niágara, determine a moda dos dados.

Inicialmente, identifica-se a classe modal, ou seja, aquela que apresenta a maior frequência absoluta. Em seguida, aplica-se a expressão da moda para dados agrupados, obtendo uma estimativa do valor mais frequente dentro dessa classe.

Tabela 4.9: Distribuição de frequências das resistências de uvas Niágara

Resistência	Freq. (n_i)	Freq. (f_i)	Freq. (N_i)	Ponto ($\bar{x}_i$)	$n_i\bar{x}_i$
0,50 ┤ 0,72	12	0,33	12	0,61	7,32
0,72 ┤ 0,94	17	0,47	29	0,83	14,11
0,94 ┤ 1,16	6	0,17	35	1,05	6,30
1,16 ┤ 1,38	0	0,00	35	1,27	0,00
1,38 ┤ 1,60	0	0,00	35	1,49	0,00
1,60 ┤ 1,82	1	0,03	36	1,71	1,71
Total	36	1,00	–	–	29,44

Observa-se que a classe modal é (0,72 ┤ 0,94), pois apresenta a maior frequência absoluta ($(n_i = 17)$).

A partir dessa informação, pode-se aplicar a fórmula da moda para dados agrupados, utilizando as frequências das classes adjacentes, o limite inferior da classe modal e a amplitude de classe, obtendo assim uma estimativa da resistência mais frequente das uvas avaliadas.

$$M_o = 0,72 + \frac{5}{5 + 11} \times 0,22 = 0,79$$

Cálculo da moda,no R, utilizando a tabela de frequências

```
fdth::mfv(tabres)
```

```
[1] 0.78875
```

Exercício

Considere os exercícios a seguir, que envolvem a aplicação do conceito de moda em diferentes tipos de variáveis, tanto quantitativas quanto qualitativas, no contexto agrônomo.

No primeiro exercício, calcule a moda da variável **rendimento médio** de um experimento de competição com 32 híbridos de milho, cujos dados estão agrupados em classes.

Tabela 4.10: Distribuição de frequências dos rendimentos médios, em kg/ha, de 32 híbridos de milho recomendados para o Oeste catarinense, 1987/88

Rendimento médio (kg/ha)	Freq. abs. (n_i)	Freq. rel. (f_i)	Ponto médio ($\bar{x}_i$)
3973 – 4457	1	0,031	–
4457 – 4941	12	0,375	–
4941 – 5425	13	0,406	–
5425 – 5909	3	0,094	–
5909 – 6393	3	0,094	–
Total	32	1,000	–

Exercício

Calcule a moda da variável **tipo de grão** em um experimento de competição de híbridos de milho para a região de Chapecó (SC). Nesse caso, por se tratar de uma variável qualitativa, a moda corresponde à categoria mais frequente observada no conjunto de dados.

4.3.1.3 Mediana

A **mediana** (M_d) é o valor que ocupa a posição central de um conjunto de dados ordenados (em rol), dividindo-o em duas partes de mesmo tamanho, isto é, com 50% das observações abaixo e 50% acima desse valor.

Para determinar a mediana, é necessário inicialmente identificar sua posição na série ordenada. Essa posição é dada por:

$$L = \frac{n}{2}$$

em que n representa o número total de observações.

A partir do valor de L , têm-se duas situações:

- Se L não for inteiro (ou seja, for um valor decimal), considera-se o próximo número inteiro superior. Nesse caso, a mediana será o valor que ocupa essa posição na série ordenada:

$$M_d = x_{L+}$$

- Se L for inteiro, a mediana será dada pela média aritmética entre os valores que ocupam as posições L e $L + 1$:

$$M_d = \frac{x_L + x_{L+1}}{2}$$

Esse procedimento garante a correta identificação do valor central da distribuição, independentemente de o número de observações ser par ou ímpar.

Exemplo

Calcule a mediana da variável **resistência de uvas Niágara**.

Inicialmente, os dados devem ser organizados em ordem crescente (rol), pois a mediana depende da posição dos valores no conjunto de dados.

Tabela 4.11: Tabela: Rol de resistência, em N, de uvas Niágara

0,50	0,52	0,54	0,58	0,59	0,61	0,63	0,64	0,64
0,67	0,69	0,70	0,72	0,73	0,73	0,75	0,75	0,76
0,76	0,76	0,76	0,80	0,82	0,82	0,83	0,84	0,87
0,89	0,92	0,94	0,99	1,00	1,04	1,04	1,10	1,80

Como o número de observações é par ($n = 36$), a mediana será dada pela média entre os valores que ocupam as posições centrais.

$$M_d = \frac{x_{18} + x_{19}}{2} = \frac{0,76 + 0,76}{2} = 0,76$$

Utilizando o software R:

```
median(resis)
```

```
[1] 0.76
```

Mediana – Dados agrupados em classes

Quando os dados estão agrupados em classes, a mediana é estimada por meio da seguinte expressão:

$$M_d = l_i + \frac{L - F_{an}}{n_{md}} \cdot a_c$$

em que:

- l_i = limite inferior da classe da mediana
- $L = \frac{n}{2}$ = posição da mediana
- F_{an} = frequência acumulada da classe anterior
- n_{md} = frequência da classe da mediana
- a_c = amplitude da classe

Inicialmente, deve-se identificar a classe da mediana, ou seja, aquela em que a frequência acumulada atinge ou ultrapassa o valor L .

Exemplo

Utilizando a tabela de distribuição de frequências da resistência de uvas Niágara, determine a mediana dos dados.

Tabela 4.12: Distribuição de frequências das resistências de uvas Niágara

Resistência	Freq. (n_i)	Freq. (f_i)	Freq. (N_i)	Ponto ($\bar{x}_i$)	$n_i \bar{x}_i$
0,50 ┤ 0,72	12	0,33	12	0,61	7,32
0,72 ┤ 0,94	17	0,47	29	0,83	14,11
0,94 ┤ 1,16	6	0,17	35	1,05	6,30
1,16 ┤ 1,38	0	0,00	35	1,27	0,00
1,38 ┤ 1,60	0	0,00	35	1,49	0,00
1,60 ┤ 1,82	1	0,03	36	1,71	1,71
Total	36	1,00	—	—	29,44

Inicialmente, calcula-se a posição da mediana ($L = n/2 = 18$). Em seguida, identifica-se a classe cuja frequência acumulada contém essa posição.

A mediana pode então ser obtida aplicando-se a fórmula apresentada anteriormente.

$$M_d = 0,72 + \frac{18 - 12}{17} \cdot 0,22 = 0,798$$

Utilizando o software R:

```
median(tabres)
```

```
[1] 0.7976471
```

Exercício

Calcule a mediana da variável **rendimento médio** de um experimento de competição com 32 híbridos de milho, considerando os dados agrupados em classes.

Tabela 4.13: Distribuição de frequências dos rendimentos médios, em kg/ha, de 32 híbridos de milho recomendados para o Oeste catarinense, 1987/88

Rendimento médio (kg/ha)	Freq. abs. (n_i)	Freq. rel. (f_i)	Ponto médio ($\bar{x}_i$)
3973 ┤ 4457	1	0,031	—
4457 ┤ 4941	12	0,375	—
4941 ┤ 5425	13	0,406	—
5425 ┤ 5909	3	0,094	—
5909 ┤ 6393	3	0,094	—
Total	32	1,000	—

4.3.2 Medidas de Dispersão

Após a apresentação das medidas de posição, como média, mediana e moda, que indicam valores representativos do conjunto de dados, é necessário complementar a análise com medidas que descrevam a variabilidade das observações.

As medidas de dispersão têm como objetivo quantificar o grau de espalhamento dos dados em torno de um valor central, permitindo avaliar o quanto as observações diferem entre si.

Dessa forma, duas distribuições podem apresentar a mesma média ou mediana, mas comportamentos completamente distintos em termos de variabilidade. Por isso, a utilização conjunta de medidas de posição e de dispersão é fundamental para uma descrição estatística mais completa e adequada dos dados.

Em geral, para caracterizar um conjunto de dados, é recomendável utilizar pelo menos uma medida de posição e uma medida de dispersão.

As principais medidas de dispersão são:

- Amplitude
- Desvio médio
- Variância
- Desvio padrão
- Erro padrão
- Coeficiente de variação

4.3.2.1 Amplitude

A amplitude (A_t) é a medida de dispersão mais simples, sendo definida como a diferença entre o maior e o menor valor observado em um conjunto de dados:

$$A_t = x_{max} - x_{min}$$

Essa medida fornece uma indicação rápida da extensão total dos dados, ou seja, do intervalo em que as observações estão distribuídas.

No entanto, a amplitude apresenta limitações importantes, pois considera apenas os valores extremos da distribuição, desconsiderando completamente os valores intermediários. Dessa forma, não fornece informações sobre como os dados estão distribuídos ou concentrados ao longo do intervalo observado.

Além disso, por depender exclusivamente do maior e do menor valor, a amplitude é altamente sensível a valores atípicos (outliers), podendo não representar adequadamente a variabilidade real dos dados.

Apesar dessas limitações, a amplitude pode ser útil em análises exploratórias iniciais, especialmente quando se deseja uma avaliação rápida da variabilidade.

Exemplo: Considere um experimento em que se avaliou a produtividade de milho (kg/ha) em diferentes parcelas, obtendo-se valores mínimo de 4.200 kg/ha e máximo de 6.800 kg/ha. Nesse caso, a amplitude é:

$$A_t = 6800 - 4200 = 2600 \text{ kg/ha}$$

Esse resultado indica que a produtividade variou em 2.600 kg/ha entre as parcelas avaliadas. No entanto, essa medida não informa se a maioria das parcelas apresentou valores próximos entre si ou se houve grande variabilidade ao longo do experimento.

4.3.2.2 Desvio médio

O **desvio médio** (d_m) é uma medida de dispersão que quantifica, em média, o afastamento dos valores observados em relação a uma medida de posição, geralmente a média.

Inicialmente, define-se o **desvio** como a diferença entre cada observação e a média do conjunto de dados, isto é, $(x_i - \mu)$, no caso populacional, ou $(x_i - \bar{x})$, no caso amostral.

Entretanto, a soma desses desvios é sempre igual a zero, o que inviabiliza sua utilização direta como medida de variabilidade. Para contornar esse problema, considera-se o valor absoluto dos desvios, eliminando os sinais negativos.

Assim, o desvio médio é definido como a média dos desvios absolutos:

$$d_m = \frac{\sum_{i=1}^N |x_i - \mu|}{N} \quad \text{ou} \quad d_m = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

Caso os dados estejam apresentados seguindo uma distribuição de frequências, tem-se:

$$d_m = \frac{\sum_{i=1}^k |\bar{x}_i - \mu| n_i}{N}, \quad \text{ou} \quad d_m = \frac{\sum_{i=1}^k |\bar{x}_i - \bar{x}| n_i}{n}$$

Essa medida expressa, portanto, o afastamento médio dos dados em relação à média, sendo de interpretação direta e intuitiva.

Apesar de ser uma medida simples, o desvio médio é menos utilizado em análises estatísticas mais avançadas, pois não apresenta propriedades matemáticas tão convenientes quanto a variância e o desvio padrão.

Exemplo: Considere a produtividade (t/ha) de soja em cinco parcelas experimentais:

$$3,2 \quad 3,5 \quad 3,8 \quad 3,0 \quad 3,5$$

Inicialmente, calcula-se a média:

$$\bar{x} = \frac{3,2 + 3,5 + 3,8 + 3,0 + 3,5}{5} = \frac{17,0}{5} = 3,4$$

Em seguida, determinam-se os desvios absolutos:

$$\begin{aligned} d_m &= \frac{|3,2 - 3,4| + |3,5 - 3,4| + |3,8 - 3,4| + |3,0 - 3,4| + |3,5 - 3,4|}{5} \\ &= \frac{0,2 + 0,1 + 0,4 + 0,4 + 0,1}{5} \\ &= \frac{1,2}{5} \\ &= 0,24 \end{aligned}$$

Portanto, o desvio médio é $d_m = 0,24$ t/ha, indicando que, em média, as produtividades diferem 0,24 t/ha em relação ao valor médio.

4.3.2.3 Variância

A **variância** é a medida de dispersão mais utilizada em estatística, pois considera todos os valores do conjunto de dados e suas distâncias em relação à média.

Diferentemente do desvio médio, em que se utilizam valores absolutos, na variância os desvios são elevados ao quadrado. Esse procedimento elimina sinais negativos e, além disso, atribui maior peso aos valores mais distantes da média, enfatizando a variabilidade dos dados.

Para dados não agrupados, a variância pode ser calculada por:

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N} \quad \text{ou} \quad s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

Alternativamente, pode-se utilizar uma forma computacionalmente mais conveniente:

$$\sigma^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}}{N} \quad \text{ou} \quad s^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}}{n - 1}$$

Quando os dados estão agrupados em classes, a variância é calculada por:

$$\sigma^2 = \frac{\sum_{i=1}^k (\bar{x} * i - \mu)^2 n_i}{N} \quad \text{ou} \quad s^2 = \frac{\sum_{i=1}^k *i = 1^k (\bar{x}_i - \bar{x})^2 n_i}{n - 1}$$

ou, de forma equivalente:

$$\sigma^2 = \frac{\sum_{i=1}^k \bar{x} * i^2 n_i - \frac{(\sum_{i=1}^k *i = 1^k \bar{x} * i n_i)^2}{n}}{N} \quad \text{ou} \quad s^2 = \frac{\sum_{i=1}^k *i = 1^k \bar{x} * i^2 n_i - \frac{(\sum_{i=1}^k *i = 1^k \bar{x}_i n_i)^2}{n}}{n - 1}$$

Uma característica importante da variância é que seu resultado é expresso em unidades ao quadrado da variável original, o que pode dificultar sua interpretação direta. Essa limitação motiva o uso do desvio padrão, que será apresentado posteriormente.

Exemplo: Considere a produtividade (t/ha) de soja em cinco parcelas experimentais:

3,2 3,5 3,8 3,0 3,5

Inicialmente, calcula-se a média:

$$\bar{x} = \frac{3,2 + 3,5 + 3,8 + 3,0 + 3,5}{5} = \frac{17,0}{5} = 3,4$$

Em seguida, calcula-se a variância:

$$\begin{aligned}s^2 &= \frac{(3,2 - 3,4)^2 + (3,5 - 3,4)^2 + (3,8 - 3,4)^2 + (3,0 - 3,4)^2 + (3,5 - 3,4)^2}{5 - 1} \\&= \frac{0,04 + 0,01 + 0,16 + 0,16 + 0,01}{4} \\&= \frac{0,38}{4} \\&= 0,095\end{aligned}$$

Portanto, a variância é $s^2 = 0,095 \text{ (t/ha)}^2$.

Esse resultado indica o grau de variabilidade das produtividades em relação à média. Como os desvios foram elevados ao quadrado, valores mais distantes da média tiveram maior influência no resultado final. Observa-se que a variabilidade entre as parcelas é relativamente baixa, uma vez que os valores estão próximos da média de 3,4 t/ha. Ainda assim, a interpretação direta da variância não é simples devido à unidade ao quadrado, o que justifica a utilização do desvio padrão como medida complementar.

4.3.2.4 Desvio padrão

O **desvio padrão** é uma medida de dispersão amplamente utilizada, definida como a raiz quadrada da variância. Sua principal vantagem em relação à variância é que o resultado é expresso na mesma unidade dos dados originais, o que facilita a interpretação.

Assim, o desvio padrão é dado por:

$$\sigma = \sqrt{\sigma^2} \quad \text{ou} \quad s = \sqrt{s^2}$$

Essa medida indica, em termos médios, o quanto os valores observados se afastam da média. Quanto maior o desvio padrão, maior é a variabilidade dos dados, quanto menor, mais homogêneo é o conjunto de observações.

Exemplo: Considere a produtividade (t/ha) de soja em cinco parcelas experimentais:

$$3,2 \quad 3,5 \quad 3,8 \quad 3,0 \quad 3,5$$

Do exemplo anterior, já foi calculada a variância:

$$s^2 = 0,095$$

Assim, o desvio padrão é:

$$\begin{aligned}s &= \sqrt{0,095} \\ &\approx 0,308\end{aligned}$$

Portanto, o desvio padrão é aproximadamente $s = 0,308$ t/ha.

Esse resultado indica que, em média, as produtividades das parcelas diferem cerca de 0,308 t/ha em relação à média (3,4 t/ha).

4.3.2.5 Erro padrão

Ao se trabalhar com amostras, é importante reconhecer que diferentes amostras retiradas de uma mesma população podem produzir estimativas distintas para um mesmo parâmetro, como a média.

Nesse contexto, o **erro padrão** surge como uma medida da precisão da média amostral, indicando o quanto a média calculada a partir de uma amostra pode variar em relação à média populacional.

O erro padrão da média é definido por:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} \quad \text{ou} \quad s_{\bar{x}} = \frac{s}{\sqrt{n}}$$

em que n representa o tamanho da amostra.

Essa medida está diretamente relacionada ao tamanho da amostra: quanto maior o valor de n , menor será o erro padrão, indicando maior precisão da estimativa da média.

Exemplo: Considere o mesmo conjunto de dados de produtividade (t/ha) de soja:

$$3,2 \quad 3,5 \quad 3,8 \quad 3,0 \quad 3,5$$

Sabendo que o desvio padrão amostral é $s = 0,308$ e que $n = 5$, o erro padrão da média é:

$$\begin{aligned}
s_{\bar{x}} &= \frac{0,308}{\sqrt{5}} \\
&\approx \frac{0,308}{2,236} \\
&\approx 0,138
\end{aligned}$$

Portanto, o erro padrão da média é aproximadamente $s_{\bar{x}} = 0,138$ t/ha.

Esse resultado indica a precisão da média amostral: quanto menor o erro padrão, mais próxima a média da amostra tende a estar da média populacional. Assim, o erro padrão não mede a variabilidade dos dados em si, mas sim a incerteza associada à estimativa da média.

4.3.2.6 Coeficiente de variação

O coeficiente de variação (CV) é uma medida de dispersão relativa que expressa a variabilidade dos dados em relação à média, sendo independente da unidade de medida da variável. Por esse motivo, é amplamente utilizado para comparar a variabilidade entre diferentes conjuntos de dados, mesmo quando apresentam médias distintas ou estão em escalas diferentes.

O coeficiente de variação é definido por:

$$CV = \frac{s}{\bar{x}} \cdot 100$$

em que (s) é o desvio padrão amostral e ($\bar{x}$) é a média dos dados.

Essa medida permite avaliar o grau de dispersão relativa dos dados: quanto maior o valor do coeficiente de variação, maior será a variabilidade em relação à média; por outro lado, valores menores indicam maior homogeneidade do conjunto de dados.

Exemplo: Considere novamente a produtividade (t/ha) de soja em cinco parcelas experimentais:

$$3,2 \quad 3,5 \quad 3,8 \quad 3,0 \quad 3,5$$

Sabendo que a média é ($\bar{x} = 3,4$) e o desvio padrão amostral é ($s = 0,308$), o coeficiente de variação é calculado como:

$$\begin{aligned}
CV &= \frac{0,308}{3,4} \cdot 100 \\
&\approx 0,0906 \cdot 100 \\
&\approx 9,06
\end{aligned}$$

Portanto, o coeficiente de variação é aproximadamente ($CV = 9,06\%$).

Esse resultado indica que a variabilidade dos dados corresponde a cerca de 9,06% da média, caracterizando um conjunto de dados com baixa dispersão relativa e, portanto, relativamente homogêneo, situação bastante desejável em experimentos agronômicos, pois indica maior precisão experimental.

De forma prática, utiliza-se frequentemente a seguinte classificação para interpretação do coeficiente de variação:

- ($CV < 15\%$): baixa variabilidade (alta precisão experimental)
- ($15\% \leq CV < 30\%$): variabilidade média
- ($CV \geq 30\%$): alta variabilidade (baixa precisão experimental)

Essa classificação é amplamente utilizada na experimentação agronômica, conforme apresentado por Pimentel-Gomes (2009), devendo, contudo, ser interpretada com cautela, pois valores aceitáveis de coeficiente de variação dependem da cultura, da variável analisada e das condições experimentais.

4.3.2.7 Exemplo: Cálculo das medidas de dispersão

Considere os dados de resistência, em N, de uvas Niágara, fornecidos por produtores na safra de 2002. A partir desse conjunto de dados, deseja-se calcular as principais medidas de dispersão.

Tabela 4.14: Rol de resistência, em N, de uvas Niágara, fornecida por produtores em 2002

0.50	0.52	0.54	0.58	0.59	0.61	0.63	0.64	0.64
0.67	0.69	0.70	0.72	0.73	0.73	0.75	0.75	0.76
0.76	0.76	0.76	0.80	0.82	0.82	0.83	0.84	0.87
0.89	0.92	0.94	0.99	1.00	1.04	1.04	1.10	1.80

Inicialmente, a partir dos dados observados, obtêm-se as seguintes estatísticas descritivas:

- Número de observações: ($n = 36$)
- Média: ($\bar{x} \approx 0,80$)
- Valor mínimo: ($x_{\min} = 0,50$)
- Valor máximo: ($x_{\max} = 1,80$)

Amplitude total

$$\begin{aligned}
 A_t &= x_{max} - x_{min} \\
 &= 1,80 - 0,50 \\
 &= 1,30
 \end{aligned}$$

Desvio médio

$$\begin{aligned}
 d_m &= \frac{\sum |x_i - \bar{x}|}{n} \\
 &\approx 0,16
 \end{aligned}$$

Variância amostral

$$\begin{aligned}
 s^2 &= \frac{\sum (x_i - \bar{x})^2}{n - 1} \\
 &\approx 0,04
 \end{aligned}$$

Desvio padrão amostral

$$\begin{aligned}
 s &= \sqrt{s^2} \\
 &\approx 0,20
 \end{aligned}$$

Erro padrão da média

$$\begin{aligned}
 s_{\bar{x}} &= \frac{s}{\sqrt{n}} \\
 &= \frac{0,20}{\sqrt{36}} \\
 &= \frac{0,20}{6} \\
 &\approx 0,03
 \end{aligned}$$

Coefficiente de variação

$$\begin{aligned}
 CV &= \frac{s}{\bar{x}} \cdot 100 \\
 &\approx \frac{0,20}{0,80} \cdot 100 \\
 &\approx 25,0
 \end{aligned}$$

De modo geral, observa-se que os dados apresentam uma dispersão moderada. Em particular, o coeficiente de variação de aproximadamente (25%) indica variabilidade média, sugerindo que há uma heterogeneidade considerável entre as resistências observadas.

Comandos no R

A seguir, apresentam-se os comandos utilizados no software R para o cálculo das medidas de dispersão:

```
# Vetor de dados
resis = c(0.92, 1.80, 1.00, 0.94, 0.76, 0.72, 0.50, 1.10, 0.99, 0.70,
          0.73, 0.89, 0.64, 0.76, 0.84, 0.63, 0.75, 0.83, 0.82, 0.59,
          0.58, 0.54, 0.87, 0.80, 0.82, 0.64, 0.76, 1.04, 0.73, 1.04,
          0.67, 0.76, 0.75, 0.61, 0.69, 0.52)

##### Amplitude
max(resis) - min(resis)

##### Desvio médio
sum(abs(resis - mean(resis))) / length(resis)

##### Variância
var(resis)

##### Desvio padrão
sd(resis)

##### Erro padrão
sd(resis) / sqrt(length(resis))
# ou
library(plotrix)
std.error(resis)

##### Coeficiente de variação
(sd(resis) / mean(resis)) * 100
# ou
raster::cv(resis)
```

Esses comandos permitem reproduzir facilmente os cálculos apresentados, sendo fundamentais para a análise de dados em experimentos estatísticos.

4.3.2.8 Exemplo: Medidas de dispersão para dados agrupados em classes

Utilizando a tabela, em que está apresentada a distribuição de frequências da resistência de uvas Niágara, calculam-se as principais medidas de dispersão considerando os dados agrupados.

Tabela 4.15: Distribuição de frequências das resistências de uvas Niágara

Resistência	Freq. (n_i)	Freq. (f_i)	Freq. (N_i)	Ponto ($\bar{x}_i$)	$n_i\bar{x}_i$
0,50 ┤ 0,72	12	0,33	12	0,61	7,32
0,72 ┤ 0,94	17	0,47	29	0,83	14,11
0,94 ┤ 1,16	6	0,17	35	1,05	6,30
1,16 ┤ 1,38	0	0,00	35	1,27	0,00
1,38 ┤ 1,60	0	0,00	35	1,49	0,00
1,60 ┤ 1,82	1	0,03	36	1,71	1,71
Total	36	1,00	—	—	29,44

Para isso, utilizam-se os pontos médios das classes ($\bar{x}_i$) ponderados pelas respectivas frequências (n_i).

Inicialmente, calcula-se a média:

$$\begin{aligned}
 \bar{x} &= \frac{\sum \bar{x}_i n_i}{n} \\
 &= \frac{(0,61 \cdot 12) + (0,83 \cdot 17) + (1,05 \cdot 6) + (1,71 \cdot 1)}{36} \\
 &= \frac{7,32 + 14,11 + 6,30 + 1,71}{36} \\
 &= \frac{29,44}{36} \\
 &\approx 0,82
 \end{aligned}$$

Amplitude total

$$\begin{aligned}
 A_t &= x_{max} - x_{min} \\
 &= 1,82 - 0,50 \\
 &= 1,32
 \end{aligned}$$

Desvio médio

$$\begin{aligned}d_m &= \frac{\sum n_i |\bar{x}_i - \bar{x}|}{n} \\&= \frac{12|0,61 - 0,82| + 17|0,83 - 0,82| + 6|1,05 - 0,82| + 1|1,71 - 0,82|}{36} \\&= \frac{12(0,21) + 17(0,01) + 6(0,23) + 1(0,89)}{36} \\&= \frac{2,52 + 0,17 + 1,38 + 0,89}{36} \\&= \frac{4,96}{36} \\&\approx 0,14\end{aligned}$$

Variância amostral

$$\begin{aligned}s^2 &= \frac{\sum n_i (\bar{x}_i - \bar{x})^2}{n - 1} \\&= \frac{12(0,21^2) + 17(0,01^2) + 6(0,23^2) + 1(0,89^2)}{35} \\&= \frac{12(0,0441) + 17(0,0001) + 6(0,0529) + 1(0,7921)}{35} \\&= \frac{0,5292 + 0,0017 + 0,3174 + 0,7921}{35} \\&= \frac{1,6404}{35} \\&\approx 0,047\end{aligned}$$

Desvio padrão amostral

$$\begin{aligned}s &= \sqrt{s^2} \\&\approx \sqrt{0,047} \\&\approx 0,22\end{aligned}$$

Erro padrão da média

$$\begin{aligned}
s_{\bar{x}} &= \frac{s}{\sqrt{n}} \\
&= \frac{0,22}{\sqrt{36}} \\
&= \frac{0,22}{6} \\
&\approx 0,04
\end{aligned}$$

Coefficiente de variação

$$\begin{aligned}
CV &= \frac{s}{\bar{x}} \cdot 100 \\
&\approx \frac{0,22}{0,82} \cdot 100 \\
&\approx 26,8
\end{aligned}$$

Observa-se que os resultados são bastante próximos daqueles obtidos com os dados originais não agrupados, embora pequenas diferenças sejam esperadas devido ao uso dos pontos médios das classes. O coeficiente de variação indica variabilidade média, sugerindo uma dispersão moderada dos dados.

Comandos no R

```

# Pontos médios
xi <- c(0.61, 0.83, 1.05, 1.27, 1.49, 1.71)

# Frequências
ni <- c(12, 17, 6, 0, 0, 1)

# Tamanho da amostra
n <- sum(ni)

# Média
media <- sum(xi * ni) / n

# Amplitude
1.82 - 0.50

# Desvio médio
sum(ni * abs(xi - media)) / n

```

```

# Variância
sum(ni * (xi - media)^2) / (n - 1)

# Desvio padrão
sqrt(sum(ni * (xi - media)^2) / (n - 1))

# Erro padrão
sqrt(sum(ni * (xi - media)^2) / (n - 1)) / sqrt(n)

# Coeficiente de variação
(sqrt(sum(ni * (xi - media)^2) / (n - 1)) / media) * 100

##### Du pelo pacote fdth
resis = scan(dec = ",", text = "
0,92 1,80 1,00 0,94 0,76 0,72 0,50 1,10 0,99 0,70 0,73 0,89 0,64 0,76 0,84
0,63 0,75 0,83 0,82 0,59 0,58 0,54 0,87 0,80 0,82 0,64 0,76 1,04 0,73 1,04
0,67 0,76 0,75 0,61 0,69 0,52")
library(fdth)
tabres=fdt(resis,start = .5,h=.22,end=1.82)
#### Variância
var(tabres)

#### Desvio padrão
sd(tabres)

#### Coeficiente de variação
100*sd(tabres)/mean(tabres)

```

4.3.2.9 Exercício: Medidas de dispersão para dados agrupados em classes

Calcule a variância, o desvio padrão e o coeficiente de variação do rendimento médio de híbridos de milho, a partir dos dados agrupados em classes.

4.3.2.10 Medidas Separatrizes

As **medidas separatrizes** são estatísticas utilizadas para dividir um conjunto de dados ordenados em partes, de modo que se possa compreender melhor a sua distribuição. Essas medidas permitem identificar valores abaixo ou acima dos quais se encontra uma determinada proporção

Tabela 4.16: Distribuição de frequências dos rendimentos médios, em kg/ha , de 32 híbridos de milho recomendados para o Oeste catarinense, 1987/88

Rendimento médio (kg/ha)	Freq. abs. (n_i)	Freq. rel. (f_i)	Ponto médio ($\bar{x}_i$)
3973 ─ 4457	1	0,031	—
4457 ─ 4941	12	0,375	—
4941 ─ 5425	13	0,406	—
5425 ─ 5909	3	0,094	—
5909 ─ 6393	3	0,094	—
Total	32	1,000	—

das observações, sendo especialmente úteis na análise de variabilidade e na comparação entre conjuntos de dados, situações comuns em experimentos agronômicos.

Dentre as principais medidas separatrizes destacam-se a **mediana**, os **quartis**, os **decis** e os **percentis**. A mediana corresponde ao valor central do conjunto de dados, dividindo-o em duas partes iguais. Os quartis dividem os dados em quatro partes, os decis em dez partes e os percentis em cem partes iguais, proporcionando diferentes níveis de detalhamento da distribuição.

De forma geral, o percentil de ordem $(100p)$, com $(0 < p < 1)$, é definido como o valor abaixo do qual se encontram $(100p\%)$ das observações, enquanto $(100(1 - p)\%)$ das observações estão acima desse valor. Nesse sentido, os percentis constituem uma generalização das demais medidas separatrizes. Por exemplo, o percentil 50 corresponde à mediana, enquanto os percentis 25, 50 e 75 correspondem, respectivamente, ao primeiro, segundo e terceiro quartis.

Na prática, para determinar um percentil, é necessário inicialmente ordenar os dados em ordem crescente. Em seguida, calcula-se a posição do percentil no conjunto de dados por meio da expressão $(L = \frac{i \cdot n}{100})$, em que (i) representa o percentil desejado e (n) o número total de observações. Quando o valor de (L) não é inteiro, considera-se o menor inteiro imediatamente superior; quando (L) é inteiro, o percentil é obtido pela média entre os valores nas posições (L) e $(L + 1)$.

As medidas separatrizes são amplamente utilizadas para avaliar a distribuição de variáveis como produtividade, resistência de frutos, altura de plantas e outros atributos de interesse. Por exemplo, a análise dos quartis pode auxiliar na identificação de parcelas com desempenhos inferiores ou superiores, enquanto percentis mais elevados podem ser utilizados para selecionar materiais com maior potencial produtivo. Dessa forma, essas medidas contribuem significativamente para a interpretação dos dados experimentais e para a tomada de decisão em sistemas de produção agrícola.

Exemplo

Deseja-se calcular os quartis das resistências, em N, de uvas Niágara, fornecidas por produtores na safrinha de 2002.

Tabela 4.17: Rol de resistência, em N, de uvas Niágara, fornecida por produtores em 2002

0.50	0.52	0.54	0.58	0.59	0.61	0.63	0.64	0.64
0.67	0.69	0.70	0.72	0.73	0.73	0.75	0.75	0.76
0.76	0.76	0.76	0.80	0.82	0.82	0.83	0.84	0.87
0.89	0.92	0.94	0.99	1.00	1.04	1.04	1.10	1.80

Inicialmente, os dados devem ser organizados em ordem crescente, conforme apresentado na tabela (rol). O número total de observações é ($n = 36$).

Os quartis são obtidos a partir da posição:

$$L = \frac{i \cdot n}{100}$$

em que (i) representa o percentual correspondente ao quartil desejado.

Cálculo do primeiro quartil ($Q_1 = P_{25}$)

$$L = \frac{25 \cdot 36}{100} = 9$$

Como a posição é um número inteiro, o valor de (Q_1) é dado pela média entre o 9º e o 10º valores da série ordenada:

$$Q_1 = \frac{x_9 + x_{10}}{2} = \frac{0,64 + 0,67}{2} = 0,655$$

Cálculo do segundo quartil ($Q_2 = P_{50}$), mediana

$$L = \frac{50 \cdot 36}{100} = 18$$

$$Q_2 = \frac{x_{18} + x_{19}}{2} = \frac{0,76 + 0,76}{2} = 0,76$$

Cálculo do terceiro quartil ($Q_3 = P_{75}$)

$$L = \frac{75 \cdot 36}{100} = 27$$

$$Q_3 = \frac{x_{27} + x_{28}}{2} = \frac{0,87 + 0,89}{2} = 0,88$$

Os quartis permitem uma análise mais detalhada da distribuição dos dados. Observa-se que 25% das resistências são inferiores a aproximadamente 0,655 N, indicando o limite inferior do conjunto de dados. A mediana, igual a 0,76 N, mostra que metade das observações está abaixo desse valor. Já o terceiro quartil indica que 75% das resistências são inferiores a aproximadamente 0,88 N.

Cálculo no R

Os quartis também podem ser obtidos diretamente no R por meio do comando:

```
quantile(resis, probs = c(0.25, 0.5, 0.75), type = 2)
```

```
25%  50%  75%
0.655 0.760 0.880
```

Percentis para dados agrupados em classes

Quando os dados estão organizados em uma distribuição de frequências em classes, não é possível identificar diretamente os valores individuais. Assim, os percentis são obtidos por meio de uma **interpolação dentro da classe** em que o percentil se encontra.

O percentil de ordem i é calculado pela expressão:

$$P_i = l_i + \frac{L - F_{an}}{n_{P_i}} \cdot a_c$$

em que:

- l_i : limite inferior da classe que contém o percentil;
- F_{an} : frequência acumulada anterior à classe do percentil;
- n_{P_i} : frequência simples da classe do percentil;
- a_c : amplitude da classe;
- $L = \frac{i \cdot n}{100}$: posição do percentil;
- $i = 1, 2, \dots, 99$;
- n : número total de observações.

Procedimento de cálculo

Para determinar um percentil em dados agrupados, seguem-se as etapas:

1. Calcula-se a posição do percentil $L = \frac{i \cdot n}{100}$;
2. Identifica-se a classe na qual essa posição está contida, por meio da frequência acumulada;

3. Aplica-se a fórmula de interpolação dentro da classe correspondente;
4. Obtém-se, assim, uma estimativa do valor do percentil.

O valor obtido para o percentil representa uma aproximação, uma vez que os dados foram agrupados em classes. Ainda assim, essa medida fornece uma boa descrição da distribuição, permitindo identificar limites inferiores, centrais e superiores dos dados.

Exemplo

Considere a distribuição de frequências da resistência (N) de uvas Niágara, obtida a partir de dados coletados junto a produtores na safrinha de 2002. Com base na tabela apresentada, deseja-se calcular os quartis, utilizando o procedimento adequado para dados agrupados em classes.

Tabela 4.18: Distribuição de frequências das resistências de uvas Niágara

Resistência	Freq. (n_i)	Freq. (f_i)	Freq. (N_i)	Ponto ($\bar{x}_i$)	$n_i \bar{x}_i$
0,50 ┤ 0,72	12	0,33	12	0,61	7,32
0,72 ┤ 0,94	17	0,47	29	0,83	14,11
0,94 ┤ 1,16	6	0,17	35	1,05	6,30
1,16 ┤ 1,38	0	0,00	35	1,27	0,00
1,38 ┤ 1,60	0	0,00	35	1,49	0,00
1,60 ┤ 1,82	1	0,03	36	1,71	1,71
Total	36	1,00	–	–	29,44

Inicialmente, observa-se que o número total de observações é $n = 36$. Para determinar os quartis, calcula-se a posição:

$$L = \frac{i \cdot n}{100}$$

Cálculo do primeiro quartil ($Q_1 = P_{25}$)

$$L = \frac{25 \cdot 36}{100} = 9$$

A 9ª observação está contida na **1ª classe** (0,50 ┤ 0,72), cuja frequência acumulada é 12.

Aplicando a fórmula:

$$Q_1 = 0,50 + \frac{9 - 0}{12} \cdot 0,22$$

$$Q_1 = 0,50 + 0,165 = 0,665$$

Cálculo do segundo quartil ($Q_2 = P_{50}$)

$$L = \frac{50 \cdot 36}{100} = 18$$

A 18ª observação está na **2ª classe** ($0,72 \vdash 0,94$).

$$Q_2 = 0,72 + \frac{18 - 12}{17} \cdot 0,22$$

$$Q_2 = 0,72 + 0,078 = 0,798$$

Cálculo do terceiro quartil ($Q_3 = P_{75}$)

$$L = \frac{75 \cdot 36}{100} = 27$$

A 27ª observação também pertence à **2ª classe**.

$$Q_3 = 0,72 + \frac{27 - 12}{17} \cdot 0,22$$

$$Q_3 = 0,72 + 0,194 = 0,914$$

Os valores obtidos são aproximações dos quartis reais, uma vez que os dados foram agrupados em classes. Ainda assim, permitem uma boa descrição da distribuição das resistências. Observa-se que 25% dos valores são inferiores a aproximadamente 0,665 N, 50% são inferiores a 0,798 N e 75% são inferiores a 0,914 N.

Esses resultados indicam que a maior parte das resistências está concentrada em uma faixa relativamente estreita, evidenciando certa homogeneidade dos dados.

Exercício

Considere a distribuição de frequências dos rendimentos médios, em kg/ha, de 32 híbridos de milho recomendados para o Oeste catarinense na safra 1987/88.

Com base nos dados agrupados em classes apresentados na tabela, determine os valores do primeiro quartil (Q_1), da mediana (Q_2) e do terceiro quartil (Q_3), utilizando o método apropriado para dados agrupados.

Interprete os resultados obtidos em termos da distribuição dos rendimentos, destacando a concentração dos valores e possíveis implicações agrônômicas.

Tabela 4.19: Distribuição de frequências dos rendimentos médios, em kg/ha , de 32 híbridos de milho recomendados para o Oeste catarinense, 1987/88

Rendimento médio (kg/ha)	Freq. abs. (n_i)	Freq. rel. (f_i)	Ponto médio ($\bar{x}_i$)
3973 ┤ 4457	1	0,031	—
4457 ┤ 4941	12	0,375	—
4941 ┤ 5425	13	0,406	—
5425 ┤ 5909	3	0,094	—
5909 ┤ 6393	3	0,094	—
Total	32	1,000	—

4.3.2.11 Boxp-plot

O boxplot, ou diagrama de caixa, é uma representação gráfica que resume a distribuição de um conjunto de dados com base nas medidas separatrizes, especialmente os quartis. Essa ferramenta permite visualizar, de forma simples e eficiente, a posição central, a dispersão e possíveis valores discrepantes (outliers).

O boxplot é construído a partir de cinco estatísticas principais: o valor mínimo, o primeiro quartil (Q_1), a mediana (Q_2), o terceiro quartil (Q_3) e o valor máximo. A caixa do gráfico é delimitada por Q_1 e Q_3 , representando os 50% centrais dos dados, enquanto a linha interna indica a mediana.


A diferença entre o terceiro e o primeiro quartil ($Q_3 - Q_1$) é denominada amplitude interquartilica, ou distância interquartilica (DQ), sendo uma medida importante da dispersão dos dados. A partir dessa medida, definem-se os limites inferior (LI) e superior (LS):

$$LI = Q_1 - 1,5 \cdot DQ \quad \text{e} \quad LS = Q_3 + 1,5 \cdot DQ$$

Valores que se encontram fora desses limites são considerados possíveis outliers.

Os segmentos que se estendem da caixa até os valores mínimo e máximo (dentro dos limites estabelecidos) são chamados de “bigodes” do boxplot. Esses elementos permitem identificar a assimetria da distribuição, a variabilidade dos dados e a presença de valores extremos.

No contexto agrônomo, o boxplot é amplamente utilizado para comparar tratamentos, avaliar a uniformidade de experimentos e identificar parcelas com comportamento atípico, sendo uma ferramenta fundamental na análise exploratória de dados.



Exemplo: Boxplot da resistência de uvas Niágara

Considere os dados de resistência (N) de uvas Niágara fornecidos por produtores. A construção do boxplot para esse conjunto de dados permite visualizar a distribuição das resistências de forma resumida.

A partir dos cálculos realizados anteriormente, têm-se aproximadamente:

- $Q_1 \approx 0,655$
- $Q_2 = 0,76$
- $Q_3 \approx 0,88$

Assim, a amplitude interquartílica é:

$$DQ = Q_3 - Q_1 = 0,88 - 0,655 = 0,225$$

Os limites para identificação de valores discrepantes são:

$$LI = 0,655 - 1,5 \cdot 0,225 = 0,3175$$

$$LS = 0,88 + 1,5 \cdot 0,225 = 1,2175$$

Observa-se que todos os valores das resistências estão dentro desses limites, indicando ausência de outliers. Além disso, a proximidade entre os quartis e a mediana sugere uma distribuição relativamente simétrica e com baixa variabilidade.

Esse tipo de análise é bastante útil em experimentos agrônômicos, pois permite avaliar rapidamente a uniformidade dos dados e identificar possíveis valores extremos que possam influenciar a interpretação dos resultados.

Implementação no R

```
# Dados de resistência
resis = c(0.92, 1.80, 1.00, 0.94, 0.76, 0.72, 0.50, 1.10, 0.99, 0.70,
          0.73, 0.89, 0.64, 0.76, 0.84, 0.63, 0.75, 0.83, 0.82, 0.59,
          0.58, 0.54, 0.87, 0.80, 0.82, 0.64, 0.76, 1.04, 0.73, 1.04,
          0.67, 0.76, 0.75, 0.61, 0.69, 0.52)

# Boxplot
boxplot(resis, main = "Boxplot da resistência de uvas Niágara",
        ylab = "Resistência (N)")
```

O gráfico gerado apresenta a mediana próxima ao centro da caixa, com os quartis relativamente próximos entre si, confirmando a baixa dispersão dos dados. Os bigodes se estendem até os valores mínimo e máximo observados, sem indicação de pontos discrepantes, corroborando a análise anterior.

Exercício

Utilizando os dados de rendimento de grãos de milho apresentados anteriormente, construa o boxplot e interprete os resultados.

Apresente:

- Os valores de Q_1 , Q_2 (mediana) e Q_3 ;
- A amplitude interquartílica (DQ);
- Os limites inferior (LI) e superior (LS);
- A identificação de possíveis valores discrepantes (outliers);
- Uma breve interpretação da distribuição dos dados quanto à simetria e variabilidade.

4.3.3 Assimetria

A assimetria descreve o grau de desvio de uma distribuição em relação à sua forma simétrica. Em uma distribuição de frequência, a análise da assimetria permite compreender como os dados estão distribuídos em torno das medidas de tendência central, sendo especialmente útil na interpretação de resultados experimentais.

Uma distribuição é dita **simétrica** quando apresenta equilíbrio em torno do seu centro, ou seja, os valores estão distribuídos de forma semelhante à esquerda e à direita da média. Nesse caso, as principais medidas de posição coincidem, isto é,

$$\bar{x} = Md = Mo.$$

Esse tipo de comportamento é comum em situações ideais ou em dados com baixa influência de valores extremos.

Por outro lado, uma distribuição é considerada **assimétrica à direita** (ou **positiva**) quando apresenta uma cauda mais longa no sentido dos valores maiores. Isso ocorre, por exemplo, quando há poucos valores elevados que “puxam” a média para cima. Nessa situação, observa-se a seguinte relação entre as medidas:

$$\bar{x} > Md > Mo.$$

Já a **assimetria à esquerda** (ou **negativa**) ocorre quando a cauda da distribuição se estende para valores menores. Nesse caso, valores baixos influenciam a média, deslocando-a para a esquerda. A relação entre as medidas é dada por:

$$\bar{x} < Md < Mo$$


.

Em experimentos agronômicos, a identificação da assimetria é importante, pois pode indicar a presença de fatores que afetam de forma desigual os dados, como variabilidade ambiental, falhas experimentais ou ocorrência de valores extremos. Dessa forma, a análise da assimetria complementa a interpretação das medidas descritivas, proporcionando uma visão mais completa do comportamento dos dados.

Exemplo: Assimetria de distribuições

Para ilustrar os diferentes tipos de assimetria, considere três conjuntos de dados simulados. A visualização por meio da densidade permite identificar claramente o comportamento de cada caso.

Densidade das distribuições



No gráfico, cada distribuição é representada por uma cor distinta. As linhas contínuas indicam as médias e as linhas tracejadas indicam as medianas.

Observa-se que:

- Na distribuição **simétrica**, média e mediana praticamente coincidem;
- Na distribuição **assimétrica à direita**, a média está deslocada para a direita da mediana;
- Na distribuição **assimétrica à esquerda**, a média está deslocada para a esquerda da mediana.

A moda pode ser identificada aproximadamente pelo ponto de maior altura de cada curva de densidade.

5 Variáveis Aleatórias

Em experimentos agronômicos, frequentemente lidamos com resultados que apresentam variabilidade, mesmo quando as condições são controladas. Quantidades associadas aos possíveis resultados de um experimento aleatório são denominadas variáveis aleatórias.

De maneira mais formal, uma variável aleatória pode ser definida como uma função que associa, a cada elemento do espaço amostral, um único número real. Em outras palavras, trata-se de uma forma de representar numericamente os resultados de um experimento.

No contexto da agronomia, diversos exemplos de variáveis aleatórias podem ser observados na prática. Entre eles, destacam-se:

- o número de plantas sadias colhidas na área útil de uma parcela;
- o número de insetos capturados em uma armadilha;
- o número de dias da emergência à floração;
- o rendimento de grãos de híbridos de milho;
- a altura de plantas.

Essas variáveis podem assumir diferentes naturezas, o que leva a uma classificação importante. Quando os valores possíveis podem ser enumerados (ou seja, podem ser contados), a variável é denominada discreta, como no caso do número de plantas ou de insetos. Por outro lado, quando a variável pode assumir qualquer valor dentro de um intervalo da reta real, ela é denominada contínua, como ocorre com altura de plantas ou rendimento de grãos.

5.1 Distribuição de probabilidade de variáveis aleatórias discretas

Para variáveis aleatórias discretas, além de identificar os possíveis valores que podem ser assumidos, é fundamental conhecer as probabilidades associadas a cada um desses valores. Esse conjunto de valores e suas respectivas probabilidades é denominado **distribuição de probabilidade**.

Formalmente, a distribuição de probabilidade de uma variável aleatória discreta X , definida em um espaço amostral Ω , pode ser representada como uma tabela que associa a cada valor possível de X a sua probabilidade de ocorrência.

Para ilustrar esse conceito, considere o seguinte exemplo.

Exemplo: Três sementes são retiradas de uma nova produção de híbridos. Cada semente pode ser classificada como boa (B), se germinar, ou defeituosa (D), se não germinar. Seja Y a variável aleatória que representa o número de sementes defeituosas entre as três selecionadas. Suponha que a proporção de sementes boas seja 0,9 e que as retiradas são independentes entre si.

Como a probabilidade de uma semente ser defeituosa é 0,1, e considerando a independência, podemos obter a distribuição de probabilidade de Y , que pode assumir os valores 0, 1, 2 ou 3.

- $P(Y = 0)$: nenhuma defeituosa $\rightarrow 0,9^3 = 0,729$
- $P(Y = 1)$: exatamente uma defeituosa $\rightarrow 3 \times 0,1 \times 0,9^2 = 0,243$
- $P(Y = 2)$: exatamente duas defeituosas $\rightarrow 3 \cdot 0,1^2 \cdot 0,9 = 0,027$
- $P(Y = 3)$: três defeituosas $\rightarrow 0,1^3 = 0,001$

Assim, a distribuição de probabilidade de Y pode ser apresentada na forma de tabela:

y	$P(Y = y)$
0	0,729
1	0,243
2	0,027
3	0,001
Total	1

Observe que a soma das probabilidades é igual a 1, como esperado.

De modo geral, a distribuição de probabilidade de uma variável aleatória discreta pode ser descrita por meio de sua **função de probabilidade**, definida como

$$p(x_i) = P(X = x_i), i = 1, 2, \dots$$

em que cada valor possível x_i está associado à sua respectiva probabilidade p_i . Essas probabilidades devem satisfazer duas condições: assumir valores entre 0 e 1 e ter soma total igual a 1.

Uma vez conhecida a distribuição de probabilidade, é possível obter medidas que resumem o comportamento da variável aleatória. A principal delas é o valor médio, ou **esperança matemática**, definido por

$$E(X) = \sum_{i=1}^n x_i P(X = x_i)$$

que representa o valor médio esperado da variável em repetições do experimento.

Outra medida importante é a **variância**, que quantifica a dispersão dos valores em torno da média:

$$Var(X) = \sum_{i=1}^n [x_i - E(X)]^2 P(X = x_i)$$

ou, de forma equivalente,

$$Var(X) = E(X^2) - [E(X)]^2.$$

O **desvio padrão** é definido como a raiz quadrada positiva da variância e possui a mesma unidade da variável, o que facilita sua interpretação.

Por fim, podemos definir a **função de distribuição acumulada**, que fornece a probabilidade da variável assumir valores menores ou iguais a um determinado valor:

$$F(x) = P(X \leq x).$$

Essa função está definida para todos os números reais e assume valores no intervalo $[0, 1]$.

5.2 Alguns modelos probabilísticos para variáveis aleatórias discretas

Em diversas situações práticas, certas variáveis aleatórias discretas apresentam comportamentos que podem ser bem descritos por modelos probabilísticos específicos. Esses modelos permitem representar fenômenos reais por meio de distribuições conhecidas, facilitando a análise e a interpretação dos dados.

De modo geral, esses modelos dependem de um ou mais parâmetros que caracterizam o comportamento da variável. A seguir, são apresentados alguns dos principais modelos utilizados:

- Distribuição uniforme discreta
- Distribuição de Bernoulli
- Distribuição binomial
- Distribuição hipergeométrica
- Distribuição geométrica
- Distribuição de Poisson
- Distribuição binomial negativa

Neste momento, será detalhado apenas o caso mais simples, que serve de base para outros modelos mais gerais.

5.2.1 Distribuição de Bernoulli

Nos chamados experimentos de Bernoulli, o espaço amostral é composto por apenas dois resultados possíveis, geralmente interpretados como sucesso ou fracasso.

Esse tipo de experimento aparece com frequência em problemas agronômicos, como a germinação de uma semente (germina ou não) ou a classificação de uma planta (apresenta ou não determinada característica).

Formalmente, uma variável aleatória X que assume apenas os valores 0 e 1 é denominada variável de Bernoulli, sendo definida por:

$$P(X = 0) = 1 - p \text{ e } P(X = 1) = p$$

em que p representa a probabilidade de sucesso. Utiliza-se a notação $X \sim Be(p)$.

A função de probabilidade pode ser escrita de forma compacta como:

$$P(X = x) = p^x(1 - p)^{1-x}, x = 0 \text{ ou } 1.$$

Exemplo

Uma semente é escolhida ao acaso e semeada. Seja X a variável aleatória que indica se a semente germina (sucesso) ou não (fracasso), com probabilidade de germinação igual a 0,95.

Assim, temos:

$$P(X = 1) = 0,95 \text{ e } P(X = 0) = 0,05$$

Vamos calcular a esperança e a variância de X .

Como X assume apenas os valores 0 e 1, a esperança é dada por:

$$E(X) = 0 \cdot 0,05 + 1 \cdot 0,95 = 0,95$$

Ou seja, o valor esperado coincide com a probabilidade de sucesso.

A variância é:

$$Var(X) = (0 - 0,95)^2 \times 0,05 + (1 - 0,95)^2 \times 0,95$$

Calculando:

$$Var(X) = (0,9025)(0,05) + (0,0025)(0,95) = 0,045125 + 0,002375 = 0,0475$$

Portanto,

$$Var(X) = 0,0475$$

A distribuição de Bernoulli representa um único ensaio com dois possíveis resultados. A partir dela, é possível construir modelos mais gerais que consideram a repetição de experimentos sob as mesmas condições.

5.2.2 Distribuição Binomial

A distribuição binomial é uma extensão natural da distribuição de Bernoulli, sendo utilizada quando o experimento é repetido várias vezes sob as mesmas condições.

Dizemos que um experimento é binomial quando:

1. consiste em n ensaios de Bernoulli;
2. os ensaios são independentes;
3. a probabilidade de sucesso em cada ensaio é constante, igual a p , com $0 < p < 1$.

Seja X a variável aleatória que representa o número de sucessos em n ensaios. Utiliza-se a notação:

$$X \sim b(n, p)$$

A função de probabilidade da distribuição binomial é dada por:

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}, \quad x = 0, 1, \dots, n.$$

Exemplo

Dez sementes são extraídas ao acaso de um lote, sabendo-se que 10% das sementes não germinam. Qual é a probabilidade de que todas germinem?

Neste caso, a probabilidade de germinação é $p = 0,9$, e $n = 10$. Assim, a probabilidade de todas germinarem é:

$$P(X = 10) = \binom{10}{10} (0,9)^{10} (0,1)^0 = 0,9^{10}$$

Exercício

Um tratamento aumenta o poder germinativo de sementes de uma espécie arbórea para 70%. Vinte sementes são tratadas e semeadas. Qual é a probabilidade de que pelo menos 80% dessas sementes germinem?

(Dica: traduzir o problema para $X \sim b(20, 0,7)$ e calcular $P(X \geq 16)$).

Enquanto a distribuição binomial descreve o número de sucessos em um número fixo de ensaios, há situações em que o interesse está na contagem de ocorrências em um intervalo contínuo, como tempo ou área. Nesses casos, utiliza-se a distribuição de Poisson.

5.2.3 Distribuição de Poisson

A distribuição de Poisson é empregada para modelar o número de ocorrências de um determinado evento em um intervalo contínuo, que pode ser de tempo, espaço, área ou volume.

Esse modelo é bastante útil em aplicações agronômicas. Alguns exemplos são:

- número de árvores de uma determinada espécie em uma área;
- número de insetos capturados em um intervalo de tempo;
- número de falhas em uma linha de plantio.

Seja X uma variável aleatória com distribuição de Poisson. Utiliza-se a notação:

$$X \sim Pois(\lambda)$$

em que $\lambda > 0$ representa o número médio de ocorrências no intervalo considerado.

A função de probabilidade é dada por:

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

Observação:

Na distribuição de Poisson, o parâmetro λ representa tanto a média quanto a variância da variável aleatória, o que a torna particularmente simples do ponto de vista analítico.

Exemplo

Em uma lavoura, observa-se que, em média, são capturados 3 insetos por armadilha a cada hora. Suponha que o número de insetos capturados siga uma distribuição de Poisson.

Qual é a probabilidade de serem capturados exatamente 2 insetos em uma hora?

Neste caso, temos $X \sim Pois(\lambda = 3)$. Assim,

$$P(X = 2) = \frac{e^{-3} \times 3^2}{2!}$$

Calculando:

$$P(X = 2) = \frac{e^{-3} \times 9}{2} \approx \frac{0,0498 \times 9}{2} \approx 0,224$$

Portanto, a probabilidade de capturar exatamente 2 insetos em uma hora é aproximadamente 0,224.

Exercício

Em uma área de cultivo, o número médio de plantas daninhas por metro quadrado é igual a 2. Supondo que essa variável siga uma distribuição de Poisson, qual é a probabilidade de que, em um metro quadrado escolhido ao acaso, sejam observadas:

- a) exatamente 1 planta daninha?
- b) nenhuma planta daninha?
- c) pelo menos 3 plantas daninhas?

(Dica: utilizar $X \sim Pois(2)$ e lembrar que $P(X \geq 3) = 1 - P(X \leq 2)$).

5.3 Distribuição de probabilidade de variáveis aleatórias contínuas

Até o momento, foram consideradas variáveis aleatórias que assumem valores discretos. Em muitas situações práticas, no entanto, as variáveis de interesse podem assumir qualquer valor dentro de um intervalo, como altura de plantas ou produtividade. Esses casos são tratados por meio das variáveis aleatórias contínuas.

Formalmente, uma variável aleatória X , definida sobre o espaço amostral Ω e que assume valores em um intervalo dos números reais, é chamada de variável aleatória contínua.

Alguns exemplos típicos são:

- rendimento de grãos de híbridos de milho;
- altura de plantas;
- teor de umidade do solo;
- massa de matéria seca por planta.

Função densidade de probabilidade

No caso contínuo, as probabilidades não são associadas a valores pontuais, mas sim a intervalos. Para isso, utiliza-se a chamada função densidade de probabilidade (fdp).

Uma função $f(x)$ é dita fdp de uma variável aleatória contínua se satisfaz:

- $f(x) \geq 0$, para todo $x \in R$;
- a área total sob a curva é igual a 1:

$$\int_{-\infty}^{\infty} f(x)dx = 1.$$

A probabilidade de X assumir valores em um intervalo $[x_1, x_2]$, com $x_1 < x_2$, é dada por:

$$P(x_1 \leq X \leq x_2) = \int_{x_1}^{x_2} f(x)dx.$$

Esperança e Variância

De forma análoga ao caso discreto, também podemos definir medidas resumo para variáveis contínuas.

A **esperança matemática* é dada por:

$$E(X) = \int_{-\infty}^{\infty} xf(x)dx$$

A **variância** é definida como:

$$Var(X) = E(X^2) - [E(X)]^2$$

Função de distribuição acumulada

A função de distribuição acumulada (f.d.a.) de uma variável contínua é definida por:

$$F(x) = P(X \leq x), \quad -\infty < x < \infty$$

No caso contínuo, ela pode ser obtida a partir da fdp:

$$F(x) = \int_{-\infty}^x f(t)dt$$

Em muitos experimentos agronômicos, ao coletarmos dados de variáveis contínuas, como altura de plantas ou produtividade, e representarmos esses dados por meio de um histograma, observa-se frequentemente um padrão característico: os valores tendem a se concentrar em torno de uma média, formando uma distribuição aproximadamente simétrica.

Esse comportamento é comum em diversos fenômenos naturais e experimentais, especialmente quando há influência de múltiplos fatores (solo, clima, manejo, genética, entre outros). Nessas situações, a distribuição dos dados pode ser bem aproximada pela chamada distribuição normal.

Por exemplo, ao medir a altura de plantas em uma parcela experimental e construir um histograma, é comum observar um formato em “sino”, indicando maior frequência de valores próximos à média e menor frequência nas extremidades.

Esse tipo de comportamento motiva o estudo da distribuição normal, que é um dos modelos probabilísticos mais importantes para variáveis aleatórias contínuas.

5.3.1 Distribuição Normal

A distribuição normal é a mais importante entre as distribuições de variáveis aleatórias contínuas, sendo amplamente utilizada na análise de dados experimentais em agronomia.

Em muitos experimentos, como avaliações de produtividade, altura de plantas ou massa de matéria seca, observa-se que os dados tendem a se concentrar em torno de um valor médio, com menor frequência de valores extremos. Esse comportamento pode ser bem descrito pela distribuição normal.

A função densidade de probabilidade de uma variável aleatória contínua X , com distribuição normal, é dada por:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

em que:

- μ representa a média dos dados;
- σ^2 representa a variância, associada à variabilidade do experimento.

Notação: $X \sim N(\mu, \sigma^2)$

Propriedades da distribuição normal

A distribuição normal apresenta características importantes para a interpretação de dados experimentais:

- É simétrica em torno da média μ , indicando que valores acima e abaixo da média ocorrem com a mesma frequência;
- O ponto de maior concentração de dados ocorre em $x = \mu$, onde média, mediana e moda coincidem;
- A área total sob a curva é igual a 1, representando a totalidade dos resultados possíveis;
- Valores próximos à média são mais frequentes, enquanto valores muito altos ou muito baixos são menos comuns.

Cálculo de probabilidades

Em aplicações práticas, frequentemente é necessário calcular probabilidades associadas a intervalos de valores, como:

- a probabilidade de a produtividade ser superior a um determinado valor;
- a probabilidade de a altura de plantas estar dentro de uma faixa específica.

No entanto, o cálculo direto dessas probabilidades envolve integrais de difícil resolução. Por isso, utiliza-se uma estratégia baseada na padronização da variável.

Distribuição Normal Padrão

Qualquer variável aleatória $X \sim N(\mu, \sigma^2)$ pode ser transformada em uma variável padronizada Z , por meio da expressão:

$$z = \frac{x - \mu}{\sigma}$$

Essa transformação elimina a unidade de medida e permite trabalhar com uma distribuição única, chamada distribuição normal padrão, com média 0 e variância 1: $Z \sim N(0, 1)$

Uso de tabela da normal padrão

Após a padronização, as probabilidades podem ser obtidas por meio de tabelas da distribuição normal padrão, que fornecem áreas sob a curva normal.

Essas áreas representam probabilidades e são geralmente apresentadas na forma:

$$P(0 < Z < z)$$

Na prática, isso permite calcular probabilidades para diferentes situações experimentais de forma simples e padronizada.

A seguir, apresenta-se uma tabela da distribuição normal padrão para consulta:

[Distribuição Normal Padrão](#)

A distribuição normal desempenha papel fundamental na análise de experimentos agrônômicos, pois serve de base para diversos procedimentos estatísticos, como a construção de intervalos de confiança e a realização de testes de hipóteses.

Exemplo

A distribuição da altura de plantas de *Amaranthus hybridus*, X , pode ser aproximada por uma distribuição normal com média $\mu = 29,5$ cm e desvio padrão $\sigma = 2,7$ cm, isto é, $X \sim N(29,5, 2,7^2)$.

- a. Probabilidade de a altura estar entre 29,7 e 32,0 cm

Inicialmente, padronizamos os valores:

$$z_1 = \frac{29,7 - 29,5}{2,7} \approx 0,07 \quad \text{e} \quad z_2 = \frac{32,0 - 29,5}{2,7} \approx 0,93$$

Logo,

$$\begin{aligned}
P(29,7 \leq X \leq 32,0) &= P(0,07 \leq Z \leq 0,93) \\
&= P(0 \leq Z \leq 0,93) - P(0 \leq Z \leq 0,07) \\
&= 0,32381 - 0,02790 \\
&= 0,29591
\end{aligned}$$

No R

```
install.packages("BSDA")
BSDA::normarea(29.7,32,29.5,2.7)

# Calculando diretamente
pnorm(32,29.5,2.7) - pnorm(29.7,29.5,2.7)

# Usando a normal padrão
pnorm(0.93) - pnorm(0.07)
```

b. Probabilidade de a altura ser maior que 32,0 cm

Padronizando:

$$z = \frac{32,0 - 29,5}{2,7} \approx 0,93$$

Logo,

$$\begin{aligned}
P(X > 32,0) &= P(Z > 0,93) \\
&= 0,5 - P(0 < Z < 0,93) \\
&= 0,5 - 0,32381 \\
&= 0,17619
\end{aligned}$$

No R:

```
BSDA::normarea(32,Inf,m=29.5,sig=2.7)

# Calculando
pnorm(32,29.5,2.7, lower.tail = FALSE)

# Normal padrão
pnorm(0.93, lower.tail = FALSE)
```

c. Probabilidade de a altura estar entre 27,0 e 32,0 cm

Padronizando:

$$z_1 = \frac{27,0 - 29,5}{2,7} \approx -0,93 \text{ e } z_2 \approx 0,93$$

Logo,

$$\begin{aligned} P(27,0 < X < 32,0) &= P(-0,93 < Z < 0,93) \\ &= 2 \times P(0 < Z < 0,93) \\ &= 2 \times 0,32381 \\ &= 0,64762 \end{aligned}$$

No R:

```
No R:  
BSDA::normarea(27,32,29.5,2.7)  
  
# Calculando  
pnorm(32,29.5,2.7) - pnorm(27,29.5,2.7)  
  
# Normal padrão  
pnorm(0.93) - pnorm(-0.93)
```

d. Probabilidade de a altura estar entre 25,0 e 27,0 cm

Padronizando:

$$z_1 = \frac{25,0 - 29,5}{2,7} \approx -1,67 \text{ e } z_2 \approx -0,93$$

Logo,

$$\begin{aligned} P(25,0 < X < 27,0) &= P(-1,67 < Z < -0,93) \\ &= P(0 < Z < 1,67) - P(0 < Z < 0,93) \\ &= 0,45254 - 0,32381 \\ &= 0,12873 \end{aligned}$$

No R:

```
BSDA::normarea(25,27,29.5,2.7)

# Calculando
pnorm(27,29.5,2.7) - pnorm(25,29.5,2.7)

# Normal padrão
pnorm(-0.93) - pnorm(-1.67)
```

Exercício

Sabendo-se que $Z \sim N(0,1)$ e utilizando a tabela da distribuição normal padrão, determine z tal que:

- (a) $P(0 < Z < z_t) = 0,475$
- (b) $P(-z_t < Z < 0) = 0,35314$
- (c) $P(-z_t < Z < z_t) = 0,95$
- (d) $P(Z < z_t) = 0,36693$
- (e) $P(Z < z_t) = 0,82121$
- (f) $P(Z < z_t) = 0,30153$
- (g) $P(Z > z_t) = 0,95254$
- (h) $P(Z > z_t) = 0,07493$

Utilize inicialmente a tabela da normal padrão para resolver os exercícios. Em seguida, utilize o R para conferir os resultados.

```
# a)
qnorm(0.975)
# b)
qnorm(0.5-0.35314)
# c)
qnorm(0.975)
# d)
qnorm(0.36693)
# e)
qnorm(0.82121)
# f)
qnorm(0.30153)
# g)
qnorm(0.95254,lower.tail = FALSE)
```

```
# h)
qnorm(0.07493, lower.tail = FALSE)
```

Seja $Y \sim N(4, 1)$. Determine:

- (a) $P(Y \leq 4)$
- (b) $P(4 < Y < 5)$
- (c) $P(2 < Y < 5)$
- (d) $P(5 < Y < 7)$
- (e) $P(Y \leq 1)$
- (f) $P(0 \leq Y \leq 2)$

Utilize inicialmente a tabela da normal padrão para resolver os exercícios. Em seguida, utilize o R para conferir os resultados.

```
# a)
pnorm(4, 4, 1)
# b)
pnorm(5, 4, 1) - pnorm(4, 4, 1)
# c)
pnorm(5, 4, 1) - pnorm(2, 4, 1)
# d)
pnorm(7, 4, 1) - pnorm(5, 4, 1)
# e)
pnorm(1, 4, 1)
# f)
pnorm(2, 4, 1) - pnorm(0, 4, 1)
```

O diâmetro (X) de certa espécie de árvore segue $X \sim N(50, 6)$. Se o diâmetro diferir da média em mais de 10 cm, a árvore é vendida por 10 u.m.; caso contrário, é vendida por 20 u.m. Determine o preço médio de venda de cada árvore.

Utilize inicialmente a tabela da normal padrão para resolver os exercícios. Em seguida, utilize o R para conferir os resultados.

```
pv20=pnorm(60, 50, 6) - pnorm(40, 50, 6)
pv10=1-pv20
(ValorMedioVenda=10*pv10+20*pv20)
```

6 Distribuições Amostrais

Até o momento, a análise estatística foi conduzida a partir de dados observados em uma única amostra, o que permite descrever e resumir as informações coletadas em experimentos. Entretanto, em técnicas experimentais aplicadas à agronomia, o objetivo central raramente se limita à amostra em si, mas sim à compreensão de características da população da qual essa amostra foi retirada, por exemplo, o comportamento produtivo de uma cultura sob determinadas condições de manejo ou ambiente.

Nesse contexto, surge uma questão fundamental: se diferentes amostras forem coletadas da mesma população, os resultados obtidos serão sempre os mesmos? A resposta é negativa, pois existe a chamada variabilidade amostral. Mesmo sob condições controladas, diferentes amostras podem produzir estimativas distintas para uma mesma medida, como a média de produtividade ou a altura de plantas.

É justamente para compreender e quantificar essa variabilidade que se introduz o conceito de distribuição amostral. Essa distribuição descreve como uma estatística, como a média, a proporção ou a variância, se comporta ao considerar todas as possíveis amostras de mesmo tamanho extraídas de uma população. Assim, ela permite avaliar o grau de variação esperado entre diferentes amostras e fornece uma base teórica sólida para a inferência estatística.

A compreensão das distribuições amostrais é, portanto, essencial, pois sustenta os principais procedimentos inferenciais utilizados em experimentação agrônoma, como a estimação de parâmetros populacionais, a construção de intervalos de confiança e a realização de testes de hipóteses. Esses instrumentos permitem que conclusões obtidas a partir de amostras sejam generalizadas, de forma rigorosa, para a população de interesse.

Distribuição Amostral

A distribuição amostral pode ser definida como a distribuição de uma estatística, como a média, a proporção ou a variância, obtida a partir de todas as possíveis amostras de mesmo tamanho extraídas de uma população. Em outras palavras, em vez de observarmos apenas um único valor da estatística calculado a partir de uma amostra, passamos a considerar todos os valores que essa estatística poderia assumir, dependendo da amostra selecionada.

Para ilustrar esse conceito, considere a população formada pelos valores $\{2, 4, 6, 8\}$. Suponha que sejam retiradas todas as possíveis amostras de tamanho 2, sem reposição. Para cada amostra, calcula-se a média amostral. As amostras possíveis e suas respectivas médias são apresentadas na Tabela 6.1.

Tabela 6.1: Amostras de tamanho 2 e suas respectivas médias

Amostra	Média
(2, 4)	3
(2, 6)	4
(2, 8)	5
(4, 6)	5
(4, 8)	6
(6, 8)	7

Assim, a distribuição amostral da média é dada pelos valores $\{3, 4, 5, 5, 6, 7\}$. Esse resultado evidencia que a média amostral não assume um único valor, mas pode variar de acordo com a amostra considerada, mesmo quando todas são retiradas da mesma população. É justamente essa variabilidade que a distribuição amostral busca descrever.

A importância desse conceito é central na inferência estatística, pois permite quantificar o erro amostral, isto é, a diferença esperada entre a estatística obtida na amostra e o verdadeiro parâmetro populacional. Além disso, as distribuições amostrais constituem a base para a construção de intervalos de confiança e para a realização de testes de hipóteses, ferramentas fundamentais na análise de experimentos agronômicos.

Simulação da distribuição amostral da média

Uma forma prática de compreender o comportamento da distribuição amostral da média é por meio de simulação computacional. A seguir, apresenta-se um exemplo utilizando o software R.

```
set.seed(123)

populacao <- rnorm(10000, mean = 50, sd = 10)


n <- 30
repeticoes <- 1000

medias <- replicate(repeticoes, mean(sample(populacao, n)))

hist(medias, breaks = 30,
     main = "Distribuição Amostral das Médias",
     ylab = "Frequência",
     xlab = "Médias")

abline(v = mean(medias), lwd = 2)
```

Distribuição Amostral das Médias



No código apresentado, inicialmente é gerada uma população com 10.000 observações, seguindo uma distribuição normal com média 50 e desvio padrão 10. Em seguida, são retiradas 1.000 amostras de tamanho $n = 30$, e para cada amostra calcula-se a média amostral. Os valores dessas médias são então utilizados para construir o histograma.

Observa-se que a distribuição das médias amostrais tende a apresentar formato aproximadamente normal, concentrando-se em torno da média populacional. Esse comportamento evidencia que a média amostral é um estimador não viesado do parâmetro populacional e antecipa um resultado fundamental da estatística inferencial, que será formalizado pelo Teorema Central do Limite.

6.1 Distribuição amostral da média

A distribuição amostral da média possui propriedades fundamentais que permitem compreender o comportamento das estimativas obtidas a partir de amostras.

Caso em que a população é normal

Seja X uma variável aleatória com distribuição normal, isto é, $X \sim N(\mu, \sigma^2)$. Nesse caso, a média amostral $\bar{X}$, obtida a partir de uma amostra de tamanho n , também terá distribuição normal:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Isso implica que: - a média das médias amostrais é igual à média populacional, isto é, $E(\bar{X}) = \mu$;
- a variância da média amostral é $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$.

Portanto, mesmo para amostras pequenas, a normalidade da população garante a normalidade da média amostral.

Caso geral: Teorema Central do Limite

Quando a população não segue uma distribuição normal, o comportamento da média amostral pode ser descrito pelo Teorema Central do Limite.

Para uma população qualquer, com média μ e variância σ^2 , a distribuição da média amostral $\bar{X}$ tende a uma distribuição normal à medida que o tamanho da amostra aumenta:

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{para } n \text{ grande}$$

Na prática, considera-se que, para amostras com tamanho $n > 30$, essa aproximação já é adequada em muitas situações.

Esse resultado é de grande importância, pois permite utilizar métodos baseados na distribuição normal, como intervalos de confiança e testes de hipóteses, mesmo quando a distribuição da população original é desconhecida, situação comum em experimentos agrônômicos.

Exemplo

Considere que a produtividade de uma cultura apresenta média populacional $\mu = 6000$ kg/ha e desvio padrão $\sigma = 900$ kg/ha. Sejam retiradas amostras de tamanho $n = 36$.

Deseja-se:

- a) determinar a distribuição da média amostral;
- b) calcular a probabilidade de a média amostral ser inferior a 5800 kg/ha.

A média da distribuição amostral é igual à média populacional:

$$E(\bar{X}) = \mu = 6000$$

O erro padrão da média é dado por:

$$\text{EP}(\bar{X}) = \frac{\sigma}{\sqrt{n}} = \frac{900}{\sqrt{36}} = 150$$

Logo, a distribuição da média amostral é:

$$\bar{X} \sim N(6000, 150^2)$$

b) Probabilidade

Deseja-se calcular:

$$P(\bar{X} < 5800)$$

Padronizando a variável:

$$Z = \frac{5800 - 6000}{150} = -1,33$$

Assim,

$$P(\bar{X} < 5800) = P(Z < -1,33)$$

Esse valor pode ser obtido por meio da tabela da normal padrão ou diretamente no R:

```
pnorm(5800, mean = 6000, sd = 150)
```

```
[1] 0.09121122
```

A distribuição amostral da média evidencia que diferentes amostras produzem diferentes estimativas para a média populacional. Essa variabilidade é inerente ao processo amostral e precisa ser considerada na análise de dados.

Dessa forma, surge a necessidade de:

- quantificar a variabilidade das estimativas;
- construir inferências confiáveis sobre o parâmetro populacional.

Esses objetivos são alcançados por meio da estimação, que pode ser classificada em:

- estimação pontual;
- estimação intervalar.

7 Estimação dos parâmetros

Em estudos agronômicos, raramente é possível observar todos os elementos de uma população, como todas as plantas de uma lavoura ou todas as parcelas de uma área experimental. Por esse motivo, utiliza-se uma amostra, a partir da qual se deseja obter informações sobre parâmetros populacionais desconhecidos.

A **estimação** é o processo estatístico que utiliza os dados amostrais para avaliar esses parâmetros.

Por exemplo, pode-se utilizar uma amostra de plantas para estimar:

- a produtividade média de uma cultura (μ);
- a proporção de plantas doentes em uma lavoura (π);
- a variabilidade da produção entre parcelas (σ^2).

Os principais parâmetros de interesse são:

- média (μ)
- proporção (π)
- variância (σ^2)

7.1 Estimação Pontual

Um **estimador** é uma estatística calculada a partir dos dados da amostra e utilizada para estimar um parâmetro populacional desconhecido.

Quando um valor específico é obtido para esse estimador, tem-se uma estimativa pontual.

Em estudos agronômicos, por exemplo, a partir de dados coletados em parcelas experimentais, pode-se obter estimativas para características de interesse da cultura.

Os principais estimadores são:

- $\bar{x}$ é o estimador da média populacional μ
- $\hat{p}$ é o estimador da proporção populacional π
- s^2 é o estimador da variância populacional σ^2

Propriedades dos Estimadores

Para que um estimador seja considerado adequado, ele deve apresentar algumas propriedades importantes:

- **Não viesado** (não tendencioso):

Um estimador é dito não viesado quando seu valor esperado coincide com o parâmetro populacional, ou seja:

$$E(\hat{\theta}) = \theta$$

Isso significa que, em média, o estimador acerta o verdadeiro valor do parâmetro.

- **Preciso:**

Refere-se à baixa variabilidade do estimador entre diferentes amostras.

Quanto menor a variância do estimador, maior sua precisão. Estimadores precisos produzem valores próximos entre si, mesmo que não estejam exatamente no valor verdadeiro do parâmetro.

- **Acurado:**

Um estimador é acurado quando produz estimativas próximas do verdadeiro parâmetro populacional. A acurácia depende simultaneamente de baixo viés e alta precisão.

Exemplo 1 — Estimação Pontual

Uma amostra aleatória simples de dez isolados de fungos ectomicorrízicos *P. tinctorius*, cultivados *in vitro*, apresentou os seguintes valores de biomassa (em gramas):

0,034	0,033	0,029	0,034	0,027
0,034	0,029	0,035	0,032	0,028

Objetivo: obter estimativas para a média e o desvio padrão populacional.

Solução

A média amostral é dada por:

$$\bar{x} = \frac{0,315}{10} = 0,0315 \text{ g} \approx 0,032 \text{ g}$$

O desvio padrão amostral é:

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}} \approx 0,003 \text{ g}$$

Assim, as estimativas pontuais para μ e σ são, respectivamente, **0,032 g** e **0,003 g**.

No R

```
dados <- c(0.034,0.033,0.029,0.034,0.027,
           0.034,0.029,0.035,0.032,0.028)

mean(dados)
sd(dados)
```

Observa-se que os valores obtidos são **estimativas pontuais**, ou seja, valores únicos calculados a partir da amostra. No entanto, diferentes amostras da mesma população podem produzir resultados distintos.

O principal problema da estimação pontual é que ela não fornece uma medida da incerteza associada à estimativa, isto é, não indica o quanto o valor estimado pode estar distante do verdadeiro parâmetro populacional.

Dessa forma, surge a necessidade de quantificar essa incerteza. Isso é feito por meio da **estimação por intervalo**.

7.2 Estimação por Intervalo

Na estimação por intervalo, constrói-se um intervalo de valores plausíveis para o parâmetro, combinando o estimador pontual com uma medida do erro amostral.

Esse procedimento permite avaliar a possível magnitude do erro cometido na estimação.

Os **intervalos de confiança** são construídos com base nas distribuições dos estimadores amostrais.

A estimação por intervalo consiste em determinar um intervalo de valores que, com um determinado nível de confiança, contenha o verdadeiro valor do parâmetro populacional.

$$P(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2) = \gamma$$

em que $\gamma = 1 - \alpha$ é o nível de confiança.

Interpretação

O nível de confiança γ representa a proporção de intervalos que conteriam o verdadeiro valor do parâmetro se o processo de amostragem fosse repetido um grande número de vezes.

Notação

Denotamos o intervalo de confiança para um parâmetro θ por:

$$IC(\theta, \gamma)$$

Exemplos

- $IC(\mu, 0,95)$
- $IC(\pi, 0,99)$

7.2.1 Intervalo de Confiança para a Média (σ conhecido ou n grande)

O intervalo de confiança para a média populacional, quando o desvio padrão σ é conhecido ou o tamanho da amostra é grande, é dado por:

$$IC(\mu, \gamma) = \left[\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}; \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Exemplo — Peso de sementes

A distribuição dos pesos de pacotes de sementes de milho, enchidos automaticamente por uma certa máquina, é normal, com desvio padrão (σ) conhecido e igual a 0,20 kg. Uma amostra de 15 pacotes retirada ao acaso apresentou os seguintes pesos, em kg:

20,05	20,10	20,25	19,78	19,69	19,90	20,20	19,89
19,70	20,30	19,93	20,25	20,18	20,01	20,09	

Objetivo: construir $IC(\mu, 0,95)$.

Solução

Calcula-se inicialmente a média amostral $\bar{x}$:

$$\bar{x} \approx 20,02 \text{ kg}$$

Em seguida, determina-se o erro padrão:

$$EP = \frac{\sigma}{\sqrt{n}} = \frac{0,20}{\sqrt{15}} \approx 0,0516$$

Para 95% de confiança, utiliza-se $z_{0,025} = 1,96$.

O erro máximo é:

$$E = 1,96 \cdot EP \approx 0,101$$

Assim, o intervalo de confiança é:

$$IC(\mu, 0,95) = [20,02 - 0,101; 20,02 + 0,101]$$

$$IC(\mu, 0,95) \approx [19,92; 20,12]$$

Verificação no R

```
dados <- c(20.05,20.10,20.25,19.78,19.69,19.90,20.20,19.89,
          19.70,20.30,19.93,20.25,20.18,20.01,20.09)

mean(dados)

erro <- 1.96*(0.20/sqrt(15))

mean(dados)-erro
mean(dados)+erro
## Ou
LearningStats::Mean.CI(dados,sigma = 0.2,conf.level = .95)
```

7.2.2 Intervalo de Confiança para a Média (σ desconhecido)

Quando o desvio padrão populacional σ é desconhecido, utiliza-se a distribuição t de Student. O intervalo de confiança para a média é dado por:

$$IC(\mu, \gamma) = \left[\bar{x} - t_{(n-1, \alpha/2)} \frac{s}{\sqrt{n}}; \bar{x} + t_{(n-1, \alpha/2)} \frac{s}{\sqrt{n}} \right]$$

Exemplo

O peso médio ao nascer e o desvio padrão de bezerros da raça Ibagé, examinada uma amostra de 20 partos, foram de 26 kg e 2 kg, respectivamente. Dê a estimativa por intervalo do verdadeiro peso médio, utilizando grau de confiança de 95%.

Objetivo: determinar $IC(\mu, 0, 95)$.

Solução

Utiliza-se a distribuição t de Student com $n - 1 = 19$ graus de liberdade.

O erro padrão é:

$$EP = \frac{s}{\sqrt{n}} = \frac{2}{\sqrt{20}} \approx 0,447$$

Para 95% de confiança:

$$t_{(19,0,025)} \approx 2,093$$

O erro máximo é:

$$E = t \cdot EP \approx 2,093 \cdot 0,447 \approx 0,935$$

Assim, o intervalo de confiança é:

$$IC(\mu, 0, 95) = [26 - 0,935, ; 26 + 0,935]$$

$$IC(\mu, 0, 95) \approx [25,06, ; 26,94]$$

Verificação no R

```
media <- 26
s <- 2
n <- 20

erro <- qt(0.975, df=19)*(s/sqrt(n))

media-erro
media+erro
## Ou
LearningStats::Mean.CI(26,sc=2,n=20,conf.level = 0.95)
```

Exercício

As medidas da eficiência térmica de $n=15$ máquinas a diesel fabricadas por uma empresa renomada são as seguintes:

30,7; 35,0; 34,9; 33,6; 28,7; 32,1; 29,0; 31,4; 31,7; 31,8; 33,6; 29,7; 33,4; 28,2; 31,6

Determine um intervalo de 99% de confiança para a eficiência térmica média de tais máquinas a diesel.

```
dados <- c(30.7,35.0,34.9,33.6,28.7,32.1,29.0,  
          31.4,31.7,31.8,33.6,29.7,33.4,28.2,31.6)  
LearningStats::Mean.CI(dados,conf.level = 0.99)
```

7.2.3 Intervalo de confiança para diferença entre duas médias

Em muitas situações experimentais na agronomia, o interesse do pesquisador não está apenas em estimar um parâmetro isolado, mas em comparar dois tratamentos distintos. Essa comparação é essencial, por exemplo, na avaliação de diferentes cultivares, fontes de adubação ou práticas de manejo, permitindo inferir qual alternativa apresenta melhor desempenho médio.

Do ponto de vista estatístico, essa análise é conduzida por meio da diferença entre duas médias populacionais, representada por $\mu_1 - \mu_2$. Como esses parâmetros são desconhecidos, utiliza-se a informação proveniente de amostras para construir inferências. A estimativa pontual dessa diferença é dada por $\bar{x}_1 - \bar{x}_2$, ou seja, a diferença entre as médias observadas nos dois tratamentos.

Entretanto, assim como ocorre em outros contextos inferenciais, essa estimativa está sujeita à variabilidade amostral. Dessa forma, torna-se mais informativo trabalhar com intervalos de confiança, que fornecem uma faixa de valores plausíveis para a verdadeira diferença entre as médias populacionais. Esse procedimento permite avaliar não apenas a magnitude da diferença, mas também a precisão da estimativa obtida.

Para a construção do intervalo de confiança para a diferença de médias, considera-se a seguinte notação: para o tratamento 1, $\bar{x}_1$ representa a média amostral, s_1 o desvio padrão amostral e n_1 o tamanho da amostra; de forma análoga, para o tratamento 2, utilizam-se $\bar{x}_2$, s_2 e n_2 . A partir desses elementos, é possível desenvolver os intervalos sob diferentes pressupostos, como independência entre amostras e hipóteses sobre as variâncias populacionais.

7.2.3.1 Amostras grandes ou variâncias conhecidas

Em situações em que se deseja comparar dois tratamentos com base em amostras independentes, e quando os tamanhos amostrais são grandes ($n_1, n_2 > 30$) ou as variâncias populacionais são conhecidas, pode-se utilizar a aproximação normal para a construção do intervalo de confiança da diferença entre médias. Nessas condições, a distribuição da diferença entre as médias amostrais pode ser aproximada por uma normal, o que permite utilizar o quantil da distribuição normal padrão na construção do intervalo. O intervalo de confiança para $\mu_1 - \mu_2$, com nível de confiança $\gamma = 1 - \alpha$, é dado por:

$$IC(\mu_1 - \mu_2, \gamma) = \left[(\bar{x}_1 - \bar{x}_2) \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$$

em que $z_{\alpha/2}$ é o valor crítico da distribuição normal padrão, σ_1^2 e σ_2^2 são as variâncias populacionais, e n_1 e n_2 são os tamanhos das amostras.

Exemplo

Um pesquisador em agronomia conduziu um experimento para comparar a produtividade de soja (t/ha) utilizando dois tipos de fertilizantes comerciais, A e B, em áreas experimentais semelhantes. Para o fertilizante A, obteve-se média amostral de 8,2 t/ha, desvio padrão populacional de 1,5 t/ha, com amostra de tamanho $n_1 = 40$. Para o fertilizante B, a média amostral foi de 7,4 t/ha, com desvio padrão populacional de 1,2 t/ha e tamanho amostral $n_2 = 35$. Assumindo independência entre as amostras e distribuição aproximadamente normal, deseja-se construir o intervalo de confiança de 95% para $(\mu_1 - \mu_2)$.

Solução Diferença entre as médias:

$$\bar{x}_1 - \bar{x}_2 = 8,2 - 7,4 = 0,8$$

Erro padrão:

$$EP = \sqrt{\frac{1,5^2}{40} + \frac{1,2^2}{35}} = \sqrt{\frac{2,25}{40} + \frac{1,44}{35}} = \sqrt{0,05625 + 0,04114} = \sqrt{0,09739} \approx 0,312$$

Valor crítico:

$$z_{0,025} = 1,96$$

Intervalo de confiança:

$$IC = [0,8 \pm 1,96 \cdot 0,312] = [0,8 \pm 0,611] = [0,189; 1,411]$$

Como o intervalo não contém o valor zero, há evidências de que os fertilizantes apresentam produtividades médias diferentes.

```
require(LearningStats)
diffmean.CI(x1=8.2,x2=7.4,sigma1=1.5,sigma2=1.2,n1=40,n2=35,conf.level=.95)
```

Exercício

Estão sendo estudados dois processos para conservar alimentos, cuja principal variável de interesse é o tempo de duração. No processo A, o tempo X segue a distribuição $N(\mu_1, 100)$, e no processo B o tempo Y segue $N(\mu_2, 100)$.

Sorteiam-se duas amostras independentes:

Processo A: $n_1 = 16$, média $\bar{x}_1 = 50$

Processo B: $n_2 = 25$, média $\bar{x}_2 = 60$

- (a) Construa intervalos de confiança para μ_1 e μ_2 , separadamente.
- (b) Construa um intervalo de confiança para $\mu_1 - \mu_2$. Com base no resultado, avalie se há evidência de igualdade entre os processos.

```
require(LearningStats)
Mean.CI(x=50,sigma=10,n=16,conf.level=.95)
Mean.CI(x=60,sigma=10,n=25,conf.level=.95)
diffmean.CI(x1=50,x2=60,sigma1=10,sigma2=10,n1=16,n2=25,conf.level=.95)
```

7.2.3.2 Variâncias desconhecidas e supostamente iguais

Na prática agronômica, raramente se conhece a variância populacional dos tratamentos avaliados. Em experimentos de campo ou em casa de vegetação, a variabilidade das respostas é influenciada por fatores como heterogeneidade do solo, variações microclimáticas e diferenças no manejo. Dessa forma, o pesquisador dispõe, em geral, apenas das variâncias amostrais.

Quando as amostras são pequenas ($n_1, n_2 \leq 30$) e as variâncias populacionais são desconhecidas, a inferência sobre a diferença entre médias passa a utilizar a distribuição t de Student, que incorpora a incerteza associada à estimação da variância.

Em situações nas quais é razoável assumir que as variâncias populacionais são iguais ($\sigma_1^2 = \sigma_2^2$), utiliza-se uma estimativa combinada da variância, denominada *variância combinada*, que resulta em maior precisão na estimação da variabilidade comum.

$$S_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

O intervalo de confiança para a diferença entre médias é dado por:

$$IC(\mu_1 - \mu_2, \gamma) = \left[(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2, n_1+n_2-2} \cdot S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$$

Exemplo

Dois cultivares de milho foram comparados quanto à altura de plantas (cm) em condições experimentais semelhantes. As seguintes observações foram obtidas:

Foram coletadas duas amostras independentes, com os seguintes resultados:

Cultivar A: 82, 88, 85, 87, 90, 84, 83, 86, 89, 81, 85, 88

Cultivar B: 78, 82, 79, 81, 77, 80, 83, 76, 84, 79

Construa um intervalo de confiança de 95% para a diferença entre as médias $(\mu_A - \mu_B)$, assumindo variâncias desconhecidas e iguais.

Solução

1. Estatísticas amostrais

Para a Cultivar A:

$$n_1 = 12$$

$$\bar{x}_1 = 85,67$$

$$s_1 \approx 2,87$$

Para a Cultivar B:

$$n_2 = 10$$

$$\bar{x}_2 = 79,90$$

$$s_2 \approx 2,60$$

2. Diferença entre médias

$$\bar{x}_1 - \bar{x}_2 = 85,67 - 79,90 = 5,77$$

3. Variância combinada

$$S_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

$$S_p = \sqrt{\frac{11(2,87^2) + 9(2,60^2)}{20}}$$

$$S_p = \sqrt{\frac{90,64 + 60,84}{20}} = \sqrt{7,57} \approx 2,75$$

4. Erro padrão

$$EP = S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

$$EP = 2,75 \sqrt{0,1833} \approx 1,18$$

5. Valor crítico

$$gl = 20$$

$$t_{0,025,20} \approx 2,086$$

6. Intervalo de confiança

$$IC = 5,77 \pm 2,086 \cdot 1,18$$

$$IC = 5,77 \pm 2,46$$

$$IC = [3,31, 8,23]$$

O intervalo de confiança não contém o valor zero, indicando que há evidência estatística, ao nível de 95% de confiança, de diferença entre as cultivares.

```
cultivarA=c(82, 88, 85, 87, 90, 84, 83, 86, 89, 81, 85, 88)
cultivarB=c(78, 82, 79, 81, 77, 80, 83, 76, 84, 79)

diffmean.CI(cultivarA,cultivarB,var.equal = T,conf.level = .95)
```

Exercício

Dois tratamentos de adubação foram aplicados em parcelas experimentais, e a produção (kg/parcela) foi registrada para cada tratamento.

Os dados observados foram:

Tratamento A: 52, 55, 50, 53, 54, 51, 56, 52

Tratamento B: 48, 47, 50, 49, 46, 45, 48, 47

Assumindo amostras independentes, variâncias desconhecidas e iguais, construa um intervalo de confiança de 95% para a diferença entre as médias:

$$IC(\mu_1 - \mu_2, 0,95)$$

Interprete o resultado obtido no contexto do experimento, discutindo se há evidência de diferença entre os tratamentos.

```
A=c(52, 55, 50, 53, 54, 51, 56, 52)
B=c(48, 47, 50, 49, 46, 45, 48, 47)

diffmean.CI(A,B,var.equal = T,conf.level = .95)
```

7.2.3.3 Variâncias desconhecidas e supostamente desiguais

Na prática experimental, especialmente em estudos agrônômicos, nem sempre é razoável assumir que os tratamentos apresentam a mesma variabilidade. Diferenças na resposta podem ocorrer devido a fatores como interação com o solo, eficiência de absorção de nutrientes ou condições ambientais, levando a variâncias distintas entre os grupos.

Quando não se pode assumir homogeneidade de variâncias ($\sigma_1^2 \neq \sigma_2^2$), utiliza-se o procedimento de **Welch**, que ajusta tanto o erro padrão quanto os graus de liberdade da distribuição t .

Considerando duas amostras aleatórias e independentes, a estatística é dada por:

$$T = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

Os graus de liberdade são aproximados por:

$$\nu \approx \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{\left(\frac{S_1^2}{n_1}\right)^2}{n_1-1} + \frac{\left(\frac{S_2^2}{n_2}\right)^2}{n_2-1}}$$

Intervalo de confiança

O intervalo de confiança para a diferença entre médias, sem assumir variâncias iguais, é dado por:

$$IC(\mu_1 - \mu_2, \gamma) = \left[(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2, \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \right]$$

em que ν é o número de graus de liberdade aproximado pela expressão de Welch.

Exemplo

Em um experimento com trigo, dois manejos de adubação foram comparados quanto à produtividade (t/ha).

Os resultados amostrais foram:

- Manejo A: $\bar{x}_1 = 6,8$, $s_1^2 = 1,44$, $n_1 = 15$
- Manejo B: $\bar{x}_2 = 5,9$, $s_2^2 = 2,25$, $n_2 = 12$

Admitindo variâncias populacionais desconhecidas e desiguais, construa um intervalo de confiança de 95% para a diferença entre as médias ($\mu_1 - \mu_2$).

Solução

1. Diferença entre médias

$$\bar{x}_1 - \bar{x}_2 = 6,8 - 5,9 = 0,9$$

2. Erro padrão

$$EP = \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$$

$$EP = \sqrt{\frac{1,44}{15} + \frac{2,25}{12}} = \sqrt{0,096 + 0,1875}$$

$$EP = \sqrt{0,2835} \approx 0,532$$

3. Graus de liberdade (aproximação de Welch)

$$\nu \approx \frac{(0,096 + 0,1875)^2}{\frac{(0,096)^2}{15-1} + \frac{(0,1875)^2}{12-1}}$$

$$\nu \approx \frac{(0,2835)^2}{\frac{0,009216}{14} + \frac{0,035156}{11}}$$

$$\nu \approx \frac{0,0804}{0,000658 + 0,003196} = \frac{0,0804}{0,003854} \approx 20,86$$

Assim, utilizamos aproximadamente:

$$\nu \approx 21$$

4. Valor crítico

Para 95% de confiança:

$$t_{0,025, 21} \approx 2,080$$

5. Intervalo de confiança

$$IC = 0,9 \pm 2,080 \cdot 0,532$$

$$IC = 0,9 \pm 1,11$$

$$IC = [-0,21, 2,01]$$

```
diffmean.CI(6.8,5.9,sc1=sqrt(1.44),sc2=sqrt(2.25),n1=15,n2=12,conf.level = .95)
```

O intervalo de confiança contém o valor zero, indicando que **não há evidência estatística, ao nível de 95% de confiança, de diferença significativa entre os manejos de adubação** quanto à produtividade.

Exercício

Dois sistemas de manejo de solo foram avaliados quanto à produtividade de milho (kg/parcela).

Os dados observados foram:

Sistema A: 62, 65, 60, 64, 66, 63, 61, 67

Sistema B: 58, 55, 57, 56, 54, 59, 53

Assumindo amostras independentes e variâncias populacionais desconhecidas e desiguais, construa um intervalo de confiança de 95% para a diferença entre as médias populacionais:

$$IC(\mu_A - \mu_B, 0,95)$$

Interprete o resultado no contexto do experimento.

```
A <- c(62, 65, 60, 64, 66, 63, 61, 67)
B <- c(58, 55, 57, 56, 54, 59, 53)

diffmean.CI(A,B,conf.level = .95)
```

7.3 Intervalo de confiança para proporção

Até o momento, os intervalos de confiança foram construídos para parâmetros relacionados a médias. No entanto, em muitos problemas agronômicos, o interesse do pesquisador está em **proporções**, isto é, na frequência de ocorrência de determinado evento.

Por exemplo, pode-se ter interesse em estimar: - a proporção de plantas que germinaram; - a proporção de plantas com determinada doença; - a proporção de frutos comercializáveis; - a taxa de sobrevivência de mudas.

Nesses casos, o parâmetro de interesse é a **proporção populacional**, denotada por π .

7.3.1 Intervalo de confiança para uma proporção

Considere uma amostra aleatória de tamanho n , na qual se observa uma proporção amostral $\hat{p}$ de indivíduos com determinada característica de interesse.

Para amostras suficientemente grandes, a distribuição amostral de $\hat{p}$ pode ser aproximada por uma distribuição normal, com:

$$E(\hat{p}) = \pi \quad \text{e} \quad Var(\hat{p}) = \frac{\pi(1-\pi)}{n}$$

Como π é desconhecido, utiliza-se $\hat{p}$ como estimativa, resultando no seguinte intervalo de confiança:

$$IC(\pi, \gamma) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

A aproximação normal é adequada quando:

$$n\hat{p} \geq 5 \quad \text{e} \quad n(1-\hat{p}) \geq 5$$

Essas condições garantem que a distribuição amostral da proporção seja aproximadamente normal.

O intervalo de confiança fornece um conjunto de valores plausíveis para a proporção populacional π .

Por exemplo, um intervalo de 95% de confiança indica que, em repetições do processo amostral, aproximadamente 95% dos intervalos construídos conteriam o verdadeiro valor da proporção populacional.

Esse intervalo é conhecido como **intervalo aproximado normal (ou intervalo de Wald)**, sendo amplamente utilizado pela sua simplicidade, embora existam alternativas mais precisas para amostras pequenas.

Exemplo

Em um lago, uma amostra aleatória de 1000 peixes indicou a presença de 290 tilápias.

Deseja-se construir um intervalo de confiança de 95% para a verdadeira proporção de tilápias na população do lago.

1. Proporção amostral

$$\hat{p} = \frac{290}{1000} = 0,29$$

2. Erro padrão

$$EP = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

$$EP = \sqrt{\frac{0,29 \cdot 0,71}{1000}} = \sqrt{0,0002059} \approx 0,0144$$

3. Intervalo de confiança

Para 95% de confiança, $z_{0,025} = 1,96$.

$$IC(\pi, 0,95) = [\hat{p} - 1,96 \cdot EP, \hat{p} + 1,96 \cdot EP]$$

$$IC = 0,29 \pm 1,96 \cdot 0,0144$$

$$IC = 0,29 \pm 0,0282$$

$$IC = [0,2618, 0,3182]$$

Com 95% de confiança, a proporção de tilápias na população do lago está entre aproximadamente 26,2% e 31,8%.

```
proportion.CI(x=290,n=1000,conf.level = 0.95)
```

Exercício

Em um experimento, observou-se que 320 de 400 sementes germinaram.

Construa um intervalo de confiança de 99% para a verdadeira proporção de sementes que germinam na população:

$$IC(\pi, 0,99)$$

Interprete o resultado no contexto do experimento.

```
proportion.CI(x=320,n=400,conf.level = 0.99)
```

7.3.2 Intervalo de confiança para a diferença entre duas proporções

Em experimentos agronômicos, é comum o interesse em comparar proporções entre dois grupos. Por exemplo:

- proporção de plantas doentes sob diferentes tratamentos;
- taxa de germinação entre cultivares;
- proporção de sucesso de manejos distintos.

Sejam:

π_1 : proporção populacional do grupo 1

π_2 : proporção populacional do grupo 2

O objetivo é estimar a diferença entre essas proporções:

$$\pi_1 - \pi_2$$

As proporções amostrais são dadas por:

$$p_1 = \frac{x_1}{n_1}, \quad p_2 = \frac{x_2}{n_2}$$

A estimativa pontual da diferença é:

$$p_1 - p_2$$

Para amostras suficientemente grandes, o intervalo de confiança para a diferença entre duas proporções é dado por:

$$IC(\pi_1 - \pi_2, \gamma) = \left[(p_1 - p_2) \pm z_{\alpha/2} \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}} \right]$$

Exemplo

Um pesquisador deseja comparar dois tratamentos para controle de uma doença em plantas de soja.

- Tratamento A: 18 plantas doentes em 100 avaliadas

- Tratamento B: 30 plantas doentes em 120 avaliadas

Construa um intervalo de confiança de 95% para a diferença entre as proporções de plantas doentes.

1. Estimativas

$$p_1 = \frac{18}{100} = 0,18$$

$$p_2 = \frac{30}{120} = 0,25$$

2. Diferença entre proporções

$$p_1 - p_2 = 0,18 - 0,25 = -0,07$$

3. Erro padrão

$$EP = \sqrt{\frac{0,18 \cdot 0,82}{100} + \frac{0,25 \cdot 0,75}{120}}$$

$$EP \approx \sqrt{0,001476 + 0,001563} = \sqrt{0,003039} \approx 0,055$$

4. Valor crítico

Para 95% de confiança:

$$z_{0,025} = 1,96$$

5. Intervalo de confiança

$$IC = -0,07 \pm 1,96 \cdot 0,055$$

$$IC = -0,07 \pm 0,108$$

$$IC \approx [-0,178, 0,038]$$

O intervalo de confiança contém valores negativos e positivos, indicando que:

- o tratamento A pode apresentar menor incidência da doença;
- o tratamento B também pode apresentar menor incidência;
- ou pode não haver diferença relevante entre os tratamentos.

Portanto, **não há evidência estatística, ao nível de 95% de confiança, de diferença entre os tratamentos** quanto à incidência da doença.

```
x1 =18; n1 = 100
x2 =30; n2 = 120

p1 =x1/n1
p2 =x2/n2

z =qnorm(0.975)

EP = sqrt((p1*(1-p1))/n1 + (p2*(1-p2))/n2)

IC_inf = (p1 - p2) - z*EP
IC_sup = (p1 - p2) + z*EP
```

Exercício

Em um experimento com milho, avaliou-se a proporção de plantas com deficiência nutricional sob dois manejos de adubação:

- Manejo 1: 22 plantas com deficiência em 90 avaliadas
- Manejo 2: 15 plantas com deficiência em 80 avaliadas

Construa um intervalo de confiança de 99% para a diferença entre as proporções populacionais ($\pi_1 - \pi_2$) e interprete o resultado.

```
x1 <- 22; n1 <- 90
x2 <- 15; n2 <- 80

p1 <- x1/n1
p2 <- x2/n2

z <- qnorm(0.995)

EP <- sqrt((p1*(1-p1))/n1 + (p2*(1-p2))/n2)

IC_inf <- (p1 - p2) - z*EP
```



```
IC_sup <- (p1 - p2) + z*EP
```

```
IC_inf
```

```
IC_sup
```

A estimação por intervalos permite ir além das estimativas pontuais, incorporando a incerteza associada aos dados amostrais. Em vez de fornecer um único valor, essa abordagem apresenta uma faixa de valores plausíveis para o parâmetro populacional, com um nível de confiança previamente estabelecido.

Ao longo desta seção, foram construídos intervalos de confiança para médias, proporções e suas respectivas diferenças, sempre com o objetivo de avaliar não apenas o valor estimado, mas também a sua precisão.

Em experimentos agrônômicos, essa abordagem é fundamental, pois possibilita:

- quantificar a variabilidade dos resultados;
- comparar tratamentos de forma mais informada;
- interpretar os dados considerando a incerteza inerente aos sistemas biológicos.

Dessa forma, a estimação por intervalos constitui uma ferramenta essencial na análise de experimentos e fornece a base conceitual para os métodos de inferência que serão apresentados na sequência.

8 Testes de Hipóteses

Introdução

Em muitas situações práticas, o pesquisador deseja verificar a veracidade de uma afirmação sobre parâmetros populacionais ou sobre o comportamento de uma variável aleatória. Para isso, formula-se uma hipótese e utiliza-se a informação proveniente de uma amostra para tomar uma decisão.

Alguns exemplos:

- Verificar se a produtividade média de milho no Paraná é de 5000 kg/ha;
- Avaliar se as proporções de fixação de fitoplâncton em dois tipos de solo são iguais;
- Comparar as produções médias de duas cultivares de soja;
- Investigar se a distribuição de uma espécie vegetal em um habitat ocorre de forma aleatória.

Hipóteses

Todo teste de hipóteses é construído a partir de uma hipótese nula, denotada por H_0 . É sempre sobre ela que a decisão estatística é tomada.

A hipótese nula representa a afirmação inicial (ou padrão), enquanto a hipótese alternativa, denotada por H_1 , representa uma afirmação contrária.

De forma geral:

- H_0 : envolve igualdade;
- H_1 : envolve desigualdade ($\neq$, $<$ ou $>$).

Erros em testes de hipóteses

Ao tomar decisões com base em dados amostrais, existe a possibilidade de erro. Os dois tipos principais são:

- **Erro tipo I:** rejeitar H_0 quando ela é verdadeira;
- **Erro tipo II:** não rejeitar H_0 quando ela é falsa.

As probabilidades associadas são:

- α : probabilidade de erro tipo I (nível de significância);
- β : probabilidade de erro tipo II.

A relação entre decisões e a realidade pode ser resumida na tabela abaixo:

Situação real	Decisão	
	Aceitar H_0	Rejeitar H_0
H_0 verdadeira	Decisão correta ($1 - \alpha$)	Erro tipo I (probab. α)
H_0 falsa	Erro tipo II (probab. β)	Decisão correta (probab. $1 - \beta$)

Além disso, dois conceitos são importantes:

- **Nível de confiança:** $1 - \alpha$, associado à decisão correta quando H_0 é verdadeira;
- **Poder do teste:** $1 - \beta$, que representa a capacidade do teste detectar diferenças reais.

Em geral, existe uma relação inversa entre α e β : para um tamanho de amostra fixo, a redução da probabilidade de um tipo de erro tende a aumentar a do outro. Na prática, fixa-se α antecipadamente, controlando o erro tipo I, enquanto o erro tipo II depende, entre outros fatores, do tamanho da amostra e da magnitude do efeito a ser detectado.

Etapas de um teste de hipóteses

A realização de um teste segue um procedimento sistemático:

1. Enunciar as hipóteses H_0 e H_1 ;
2. Fixar o nível de significância (α) e identificar a estatística de teste;
3. Determinar a região crítica;
4. Calcular a estatística de teste com os dados amostrais;
5. Tomar a decisão:
 - Se o valor calculado estiver na região crítica, rejeita-se H_0 ;
 - Caso contrário, não se rejeita H_0 .

8.1 Teste de hipótese para a média (σ^2 conhecida)

Considere uma amostra aleatória simples de tamanho n , retirada de uma população com média μ e variância conhecida σ^2 .

Sabe-se que a distribuição amostral da média $\bar{X}$ é dada por:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Assim, sob a hipótese nula $H_0 : \mu = \mu_0$, a estatística de teste

$$Z = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

segue uma distribuição normal padrão:

$$Z \sim N(0, 1)$$

8.1.1 Exemplo

Admite-se que o tempo médio de reação de seres vivos a um determinado estímulo segue distribuição normal com:

- média $\mu = 8$ s
- desvio padrão $\sigma = 2$ s

Um pesquisador suspeita que uma substância altera esse tempo médio. Para investigar, foi realizado um experimento com 10 cobaias, obtendo-se:

9,1 9,3 7,2 7,5 13,3 10,9 7,2 9,9 8,0 8,6.

Verifique se a desconfiança do pesquisador procede, ao nível de 5% de significância.}

Etapas do teste de hipóteses

As etapas para a realização do teste são descritas a seguir.

1) Hipóteses

De forma geral:

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_1 : \begin{cases} \mu < \mu_0 \\ \mu \neq \mu_0 \\ \mu > \mu_0 \end{cases}$$

Como o pesquisador desconfia que o tempo médio sofre alteração, mas não especifica a direção, utiliza-se um teste bilateral:

$$H_0 : \mu = 8 \text{ s} \quad \text{vs} \quad H_1 : \mu \neq 8 \text{ s}$$

2) Estatística de teste

Como a variância populacional é conhecida, utiliza-se a estatística:

$$Z = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

3) Região crítica

Adotando $\alpha = 5\%$ (teste bilateral), os valores críticos são:


$$z_{0.025} = \pm 1.96$$

```
curve(dnorm(x), from = -4, to = 4,
      main = expression("Regiões críticas (" * alpha == 5 * "%)"),
      xlab = "Z", ylab = "Densidade")

abline(v = c(-1.96, 1.96), lty = 2)

# sombreando com base R (forma simples)
polygon(c(-4, seq(-4, -1.96, length=100), -1.96),
        c(0, dnorm(seq(-4, -1.96, length=100)), 0),
        density = 20)

polygon(c(1.96, seq(1.96, 4, length=100), 4),
        c(0, dnorm(seq(1.96, 4, length=100)), 0),
        density = 20)
```



Assim, a região crítica é dada por:

$$Z < -1.96 \quad \text{ou} \quad Z > 1.96$$

4) Cálculo da estatística

Com base nos dados amostrais:

- $\bar{x} = 9.1 \text{ s}$
- $\sigma = 2 \text{ s}$
- $n = 10$

Tem-se:

$$Z = \frac{9.1 - 8}{\frac{2}{\sqrt{10}}} = 1.7392$$

5) Decisão

Como:

$$-1.96 < 1.7392 < 1.96$$

não rejeitamos H_0 ao nível de 5% de significância.

Conclusão

Não há evidências estatísticas de que a substância influencie o tempo médio de reação ao estímulo elétrico.

p-valor

Uma forma alternativa, e mais utilizada na prática, para tomar decisões em testes de hipóteses é por meio do **p-valor**.

O p-valor pode ser definido como:

A probabilidade de obter um resultado tão extremo quanto o observado (ou mais extremo), supondo que a hipótese nula H_0 seja verdadeira.

Em outras palavras, o p-valor mede o quanto os dados observados são compatíveis com H_0 .

Regra de decisão

A decisão no teste de hipóteses pode ser tomada da seguinte forma:

- Se **p-valor** $\leq \alpha \rightarrow$ rejeita-se H_0 ;
- Se **p-valor** $> \alpha \rightarrow$ não se rejeita H_0 .

Interpretação

- p-valor pequeno $\rightarrow$ evidência contra H_0 ;
- p-valor grande $\rightarrow$ dados compatíveis com H_0 .

Aplicação ao exemplo

No exemplo do tempo de reação, foi obtido:

$$Z = 1.7392$$

Como o teste é bilateral, o p-valor é dado por:

```
z <- 1.7392
2 * pnorm(z,lower.tail=F)
```

```
[1] 0.08199959
```

O valor obtido representa a probabilidade de observar uma média amostral tão distante de 8 (ou mais), assumindo que o verdadeiro valor médio seja $\mu = 8$. Comparando com $\alpha = 5$:

- Se o p-valor for maior que 0,05 $\rightarrow$ não rejeitamos H_0 ;
- Se fosse menor $\rightarrow$ rejeitaríamos H_0 .

Conclusão

Como o p-valor é maior que 0,05, não há evidências suficientes para rejeitar H_0 . Ou seja, os dados não indicam que a substância altera o tempo médio de reação.

Observação importante


A decisão baseada no p-valor é equivalente à decisão baseada na região crítica. A diferença é que o p-valor fornece uma medida contínua da evidência contra H_0 , enquanto a região crítica leva a uma decisão mais direta (rejeitar ou não rejeitar).

Resolução do exemplo utilizando o R:

```
tempo=c(9.1,9.3,7.2,7.5,13.3,10.9,7.2,9.9,8.0,8.6)

LearningStats::Mean.test(x=tempo,mu0 = 8,sigma=2)
```

T follows $N(0,1)$



Test for the mean of a Normal population with known variance

```
H: = 8 units
H: 8 units
T = (bar.x - ) / ( / sqrt(n))
T ~ N(0,1)
alpha = 0.05
T_obs = 1.73925
RR = (-inf, -1.95996] U [1.95996, +inf)
p-value = 0.08199
```


Exercício

Uma balança utilizada para encher pacotes de sementes está programada para produzir pacotes com peso médio de 20 kg e desvio padrão de 0,20 kg.

Periodicamente, realiza-se uma inspeção para verificar se o peso médio está sob controle. Para isso, foi selecionada uma amostra de oito pacotes, cujos pesos (em kg) foram:

20,3 19,8 20,3 19,7 19,8 19,7 19,8 19,8

Teste a hipótese de que a balança se desregulou e está produzindo um peso médio **inferior a 20 kg**, ao nível de significância de 5%.

```
peso = c(20.3, 19.8, 20.3, 19.7, 19.8, 19.7, 19.8, 19.8)
LearningStats::Mean.test(peso,mu0 = 20,alternative = "less",sigma = 0.2)
```

8.2 Teste de hipótese para a média (σ desconhecida)

Na prática, é mais comum não se conhecer a variância populacional. Nesses casos, utiliza-se a variância amostral como estimativa da variância populacional.

Assim, a estatística de teste passa a ser dada por:

$$T = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}}$$

em que s é o desvio padrão amostral.

Sob a hipótese nula, essa estatística segue uma distribuição t de Student com $n - 1$ graus de liberdade:

$$T \sim t_{(n-1)}$$

8.2.1 Exemplo

Um agrônomo afirma que a produtividade média do feijão, em lavouras de agricultores familiares em determinado ano, é de 800 kg/ha.

Para verificar essa afirmação, foi selecionada uma amostra de 9 lavouras, obtendo-se as seguintes produtividades (kg/ha):

767,8 764,1 716,8 750,2 756,0 692,5 736,1 746,1 731,4

- (a) Qual a conclusão ao nível de significância de 5%?
- (b) Caso a afirmação do agrônomo não seja verdadeira, dê uma estimativa da média populacional, com grau de confiança de 95%.

1) Hipóteses

Como o objetivo é verificar se a produtividade média difere de 800 kg/ha, tem-se um teste bilateral:

$$H_0 : \mu = 800 \quad \text{vs} \quad H_1 : \mu \neq 800$$

2) Estatística de teste

Como a variância populacional é desconhecida, utiliza-se a estatística t de Student:

$$T = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}} \sim t_{(n-1)}$$

com $n = 9$ e, portanto, $gl = 8$.


3) Região crítica

Adotando $\alpha = 5\%$ e considerando um teste bilateral:

$$t_{0,025;8} = 2,306$$

Logo, a região crítica é:

Distribuição t (gl = 8, $\alpha = 0.05$)



4) Cálculo da estatística

A partir dos dados amostrais, obtém-se:

$$\bar{X} = 740,1 \quad ; \quad s = 24,07 \quad ; \quad n = 9$$

Substituindo na estatística de teste:

$$T = \frac{740,1 - 800}{\frac{24,07}{\sqrt{9}}} = \frac{-59,9}{8,02} = -7,47$$

5) Decisão

Comparando o valor calculado com os valores críticos:

$$-7,47 < -2,306$$

Portanto, o valor da estatística pertence à região crítica.

Decisão: rejeita-se H_0 ao nível de 5%.

Conclusão

Há evidências estatísticas de que a produtividade média do feijão é diferente de 800 kg/ha. Observando o sinal da estatística ($T < 0$), conclui-se que a média é **inferior** a 800 kg/ha.

(b) Intervalo de confiança (95%)

O intervalo de confiança para a média é dado por:

$$IC(\mu, 95\%) = \bar{X} \pm t_{0,025;8} \cdot \frac{s}{\sqrt{n}}$$

$$IC(\mu, 95\%) = 740,1 \pm 2,306 \cdot 8,02$$

$$IC(\mu, 95\%) = 740,1 \pm 18,49$$

$$IC(\mu, 95\%) = (721,61 ; 758,59)$$

Interpretação

Com 95% de confiança, a produtividade média populacional está entre 721,61 kg/ha e 758,59 kg/ha.

Como o valor 800 kg/ha não pertence a esse intervalo, o resultado é consistente com a rejeição da hipótese nula.

```
prod=c(767.8, 764.1, 716.8, 750.2, 756.0, 692.5, 736.1, 746.1, 731.4)

# Verificando se os dados da amostra provém de uma população com distribuição normal.
shapiro.test(prod)

t.test(prod,mu = 800)
```

Exercício

Foi retirada uma amostra de 10 bezerros da raça Nelore, aos 210 dias de idade, com o objetivo de verificar se o peso médio desses animais atingiu ou não 186 kg.

Os valores observados (em kg) foram:

178 199 182 186 188 191 189 185 174 158

Teste as hipóteses:

$$H_0 : \mu = 186 \quad \text{vs} \quad H_1 : \mu < 186$$

ao nível de significância de 5%.

```
peso <- c(178, 199, 182, 186, 188, 191, 189, 185, 174, 158)

shapiro.test(peso)

t.test(peso, mu = 186, alternative = "less")
```

8.3 Teste de hipótese para proporção

Para testar hipóteses sobre a proporção populacional, utiliza-se a seguinte estatística:

$$Z = \frac{\hat{p} - \pi_0}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}}$$

em que:

- $\hat{p}$: proporção amostral
- π_0 : proporção sob hipótese nula
- n : tamanho da amostra

Sob a hipótese nula, essa estatística segue aproximadamente uma distribuição normal padrão:

$$Z \sim N(0, 1)$$

Os testes de hipótese para proporção são sempre construídos a partir da hipótese nula, que assume um valor específico para a proporção populacional.

As hipóteses podem ser formuladas de três formas:

$$H_0 : \pi = \pi_0 \quad \text{vs} \quad H_1 : \begin{cases} \pi < \pi_0 & (\text{teste unilateral à esquerda}) \\ \pi \neq \pi_0 & (\text{teste bilateral}) \\ \pi > \pi_0 & (\text{teste unilateral à direita}) \end{cases}$$

A escolha da hipótese alternativa depende do problema em estudo e da suspeita do pesquisador.

8.3.1 Exemplo

Um produtor precisa decidir pela compra ou não de sementes de milho fornecidas por um distribuidor, que afirma que a proporção de germinação das sementes é $\pi = 0,94$. Para tanto ele observou a proporção de germinação de uma amostra aleatória simples de 100 sementes e encontrou o valor $\hat{p} = 0,91$. Com base nesse resultado o produtor deveria discordar do distribuidor? Use $\alpha = 0,05$.

1) Hipóteses

Como deseja-se verificar se a proporção difere do valor informado:

$$H_0 : \pi = 0,94 \quad \text{vs} \quad H_1 : \pi < 0,94$$

2) Estatística de teste

$$Z = \frac{\hat{p} - \pi_0}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}} \sim N(0,1)$$

3) Região crítica

Para $\alpha = 5\%$ (teste unilateral):

$$Z < -1,64$$

4) Cálculo da estatística

$$\hat{p} = 0,91 \quad ; \quad \pi_0 = 0,94 \quad ; \quad n = 100$$

$$Z = \frac{0,91 - 0,94}{\sqrt{\frac{0,94(1-0,94)}{100}}} = \frac{-0,03}{\sqrt{0,000564}} = \frac{-0,03}{0,0238} = -1,26$$

5) Decisão

Como:

$$-1,64 < -1,26$$

o valor da estatística **não pertence à região crítica**.

Decisão: não se rejeita H_0 ao nível de 5%.

Conclusão

Não há evidências estatísticas suficientes para discordar da afirmação do fornecedor.

```
LearningStats::proportion.test(x=0.91,n = 100,p0 = 0.94,alternative = "less")
```

Exercício

Um biólogo, com base em conhecimentos teóricos e práticos afirma que a proporção (π) de forófitos sem bromélias, no estádio arbóreo pioneiro da Floresta Ombrófila, na Ilha de Santa Catarina, é igual a 0,47. Em uma amostra de 35 forófitos, 24 não apresentaram bromélias. Teste a afirmativa do biólogo ao nível de significância de 5%.

```
LearningStats::proportion.test(x=24,n = 35,p0 = 0.47,alternative = "two.sided")
```

8.4 Inferência para duas médias

Até o momento, o foco esteve na inferência sobre um único parâmetro populacional, em particular a média μ . Nessa situação, o interesse é verificar se uma média populacional assume um determinado valor de referência.

Em muitas aplicações experimentais, no entanto, o interesse recai sobre a **comparação entre dois tratamentos**, o que leva naturalmente à análise de **duas médias populacionais**, μ_1 e μ_2 .

Nesse contexto, o problema deixa de ser a avaliação de um valor específico e passa a ser a investigação da **diferença entre médias**. Assim, o parâmetro de interesse torna-se:

$$\mu_1 - \mu_2$$

A partir disso, o teste de hipótese é formulado, em geral, como:

$$H_0 : \mu_1 = \mu_2 \quad \Longleftrightarrow \quad H_0 : \mu_1 - \mu_2 = 0$$

As hipóteses alternativas podem assumir três formas, dependendo do objetivo do estudo:

$$H_1 : \begin{cases} \mu_1 < \mu_2 & \text{(unilateral à esquerda)} \\ \mu_1 \neq \mu_2 & \text{(bilateral)} \\ \mu_1 > \mu_2 & \text{(unilateral à direita)} \end{cases}$$

Tipos de amostras

Ao comparar duas médias, é fundamental identificar a natureza das amostras, pois isso determina a forma da análise. Existem dois casos principais:

- **Amostras independentes:** as observações de um grupo não possuem relação com as do outro grupo.
- **Amostras dependentes (pareadas):** existe uma correspondência natural entre as observações dos dois grupos.

8.5 Teste para duas médias - Amostras pareadas

No caso de amostras dependentes, cada observação de um grupo está diretamente relacionada a uma observação do outro grupo. Esse tipo de situação é comum em experimentos do tipo “antes e depois” ou quando unidades experimentais são avaliadas sob duas condições.

Nesses casos, não se analisa diretamente μ_1 e μ_2 , mas sim a **diferença entre os pares de observações**. Define-se, para cada unidade:

$$D_i = A_i - B_i$$

Assim, o problema é reduzido a um teste sobre a média das diferenças, μ_D .

Hipóteses para dados pareados

O teste passa a ser formulado como:

$$H_0 : \mu_D = 0$$

com as alternativas:

$$H_1 : \begin{cases} \mu_D < 0 & \text{(unilateral à esquerda)} \\ \mu_D \neq 0 & \text{(bilateral)} \\ \mu_D > 0 & \text{(unilateral à direita)} \end{cases}$$

Estatística do teste

Considerando uma amostra de tamanho n das diferenças, a estatística de teste é dada por:

$$t = \frac{\bar{D} - 0}{\frac{S_D}{\sqrt{n}}} \sim t(n-1)$$

Ou seja, o problema retorna a uma estrutura análoga ao teste para uma única média, porém aplicado às diferenças.

8.5.1 Exemplo

Com o objetivo de verificar a influência de um fungicida no progresso da ferrugem em soja, foi conduzido um experimento no qual se avaliou a incidência foliar (IF) em plantas doentes antes e após a aplicação do fungicida.

Os dados observados foram:

Planta	1	2	3	4	5	6	7	8	9
Antes	32	33	31	32	35	37	35	31	36
Depois	31	30	28	28	31	30	31	26	33
D = A - B	1	3	3	4	4	7	4	5	3

Deseja-se verificar se houve redução na incidência foliar após a aplicação do fungicida.

Como as observações são feitas nas mesmas plantas, trata-se de um caso de **amostras pareadas**. Define-se, para cada planta:

$$D_i = \text{Antes}_i - \text{Depois}_i$$

Assim, o problema é reduzido a testar a média das diferenças, μ_D .

1) Hipóteses

Como o interesse é verificar se houve redução da IF após o tratamento:

$$H_0 : \mu_D = 0 \quad \text{vs} \quad H_1 : \mu_D > 0$$

2) Estatística de teste

Calculando:

$$\bar{D} = \frac{1 + 3 + 3 + 4 + 4 + 7 + 4 + 5 + 3}{9} = \frac{34}{9} \approx 3,78$$

O desvio padrão amostral das diferenças é:

$$S_D \approx 1,64$$

Logo, a estatística de teste é:

$$t = \frac{\bar{D} - 0}{S_D / \sqrt{n}} = \frac{3,78}{1,64 / \sqrt{9}} = \frac{3,78}{0,547} \approx 6,9$$

com $gl = n - 1 = 8$.

3) Região crítica ou p-valor

Para $\alpha = 0,05$ e teste unilateral à direita:

$$t_{0,05,8} \approx 1,86$$

Como:

$$t_{calc} = 6,60 > 1,86$$

equivalentemente, o p-valor é muito menor que 0,05.

4) Decisão

Rejeita-se H_0 ao nível de 5%.

5) Conclusão

Há evidências estatísticas de que a incidência foliar diminui após a aplicação do fungicida.

Uma suposição importante do teste t pareado é que as diferenças D_i sigam, aproximadamente, uma distribuição normal. Isso pode ser avaliado pelo teste de Shapiro-Wilk.

```
antes=c(32,33,31,32,35,37,35,31,36)
depois=c(31, 30, 28, 28, 31, 30, 31, 26, 33)

shapiro.test(antes-depois)

t.test(antes,depois,paired = T,alternative = "greater")
```

Exercício

Foi conduzido um experimento com o objetivo de avaliar o efeito da aplicação de niacina no conteúdo de hemoglobina no sangue de suínos com deficiência dessa vitamina.

Em oito suínos, foram administrados 20 mg de niacina, e os níveis de hemoglobina foram mensurados antes e após a aplicação.

Os dados observados foram:

Suínos	1	2	3	4	5	6	7	8
Antes	13,6	13,6	14,7	12,1	12,3	13,2	11,0	12,4
Depois	11,4	12,5	14,6	13,0	11,7	10,3	9,8	10,4
An-De	2,2	1,1	0,1	-0,9	0,6	2,9	1,2	2,0

Considerando um nível de significância de 5%, teste se o conteúdo de hemoglobina no sangue diminuiu após a aplicação de niacina.

```

antes=c(13.6, 13.6, 14.7, 12.1, 12.3, 13.2, 11.0, 12.4)
depois=c(11.4, 12.5, 14.6, 13.0, 11.7, 10.3, 9.8, 10.4)

shapiro.test(antes-depois)

t.test(antes,depois,paired = T,alternative = "greater")

```

8.6 Teste para duas Médias - Amostras independentes

Até aqui, consideramos situações em que as observações estavam relacionadas dois a dois (dados pareados). No entanto, em muitos experimentos, as amostras são obtidas de forma independente.

Nesse caso, as observações de um grupo não possuem qualquer correspondência com as do outro grupo.

- **Amostras independentes:** não há relação entre as observações dos dois grupos;
- Deve haver independência **dentro** e **entre** as amostras;
- Cada amostra é proveniente de uma população com média μ_1 e μ_2 .

O interesse está em comparar as médias populacionais, isto é, testar:

$$\mu_1 - \mu_2$$

Consideram-se duas amostras independentes:

$$X_1, \dots, X_{n_1} \sim N(\mu_1, \sigma_1^2), \quad Y_1, \dots, Y_{n_2} \sim N(\mu_2, \sigma_2^2)$$

A formulação do teste é:

$$H_0 : \mu_1 = \mu_2$$

com alternativas:

$$H_1 : \begin{cases} \mu_1 < \mu_2 \\ \mu_1 \neq \mu_2 \\ \mu_1 > \mu_2 \end{cases}$$

O teste depende de uma suposição adicional:

- **Variâncias iguais:** $\sigma_1^2 = \sigma_2^2$ (teste t clássico com variância combinada)
- **Variâncias diferentes:** $\sigma_1^2 \neq \sigma_2^2$ (teste t de Welch)

8.6.1 Teste para duas Médias - Variâncias Iguais

Quando se assume que as variâncias populacionais são iguais ($\sigma_1^2 = \sigma_2^2$), utiliza-se a variância combinada (ou variância pooled), dada por:

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

A estatística do teste é:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

Sob a hipótese nula ($H_0 : \mu_1 = \mu_2$), a estatística se reduz a:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

e segue uma distribuição t de Student com:

$$gl = n_1 + n_2 - 2$$

8.6.2 Exemplo

Com o objetivo de comparar as produções médias (t/ha) de duas variedades de milho, foram avaliadas cinco unidades experimentais para cada variedade:

Variedade A	1,3	1,4	1,1	1,4	1,5
Variedade B	1,8	1,6	1,9	1,9	1,8

Ao nível de significância de 5%, deseja-se verificar se as variedades apresentam produções médias diferentes.

1) Hipóteses

Deseja-se verificar se há diferença entre as médias das duas variedades:

$$H_0 : \mu_1 = \mu_2 \quad \text{vs} \quad H_1 : \mu_1 \neq \mu_2$$

2) Estatísticas amostrais

Para a variedade A:

$$\bar{X}_1 = \frac{1,3 + 1,4 + 1,1 + 1,4 + 1,5}{5} = 1,34$$

$$S_1^2 = 0,023 \Rightarrow S_1 \approx 0,152$$

Para a variedade B:

$$\bar{X}_2 = \frac{1,8 + 1,6 + 1,9 + 1,9 + 1,8}{5} = 1,80$$

$$S_2^2 = 0,015 \Rightarrow S_2 \approx 0,122$$

3) Estatística de teste

Assumindo variâncias iguais, calcula-se a variância combinada:

$$S_p^2 = \frac{(5-1)0,023 + (5-1)0,015}{5+5-2} = \frac{0,092 + 0,060}{8} = 0,019$$

$$S_p = \sqrt{0,019} \approx 0,138$$

A estatística do teste é:

$$t = \frac{1,34 - 1,80}{0,138 \sqrt{\frac{1}{5} + \frac{1}{5}}} = \frac{-0,46}{0,138 \times 0,632} = \frac{-0,46}{0,087} \approx -5,29$$

com graus de liberdade:

$$gl = 5 + 5 - 2 = 8$$

4) Região crítica

Para $\alpha = 0,05$ (teste bilateral) e $gl = 8$:

$$t_{0,025,8} \approx 2,306$$

Região crítica:

$$|t| > 2,306$$

Como:

$$|t_{calc}| = 5,29 > 2,306$$

5) Decisão e conclusão

Rejeita-se H_0 ao nível de 5%.

Conclui-se que há evidências estatísticas de que as produções médias das duas variedades de milho são diferentes.

```
A=c(1.3,1.4,1.1,1.4,1.5)
B=c(1.8,1.6,1.9,1.9,1.8)

shapiro.test(A)
shapiro.test(B)

t.test(A,B,var.equal = T)
```

Exercício

Foi realizado um experimento com o objetivo de comparar os tempos gastos, em minutos, na manobra com os arados Fuçador e Erechim, ambos de tração animal.

Foram realizadas 11 repetições para cada arado, obtendo-se os seguintes dados:

Fu	0,20	0,22	0,18	0,23	0,12	0,20	0,13	0,12	0,13	0,22	0,17
Ere	0,36	0,48	0,33	0,43	0,40	0,43	0,33	0,36	0,35	0,40	0,35

Ao nível de significância de 5%, teste a hipótese de que o tempo médio gasto com o arado Fuçador é menor do que o tempo médio com o arado Erechim.

```
fu=c(0.20, 0.22, 0.18, 0.23, 0.12, 0.20, 0.13, 0.12, 0.13, 0.22, 0.17)
ere=c(0.36, 0.48, 0.33, 0.43, 0.40, 0.43, 0.33, 0.36, 0.35, 0.40, 0.35)

shapiro.test(fu)
shapiro.test(ere)

t.test(fu,ere,var.equal=T,alternative="less")
```

8.6.3 Teste para duas médias com variâncias desiguais

Quando não se pode assumir que as variâncias populacionais são iguais, utiliza-se o teste t para variâncias desiguais, também conhecido como **teste de Welch**.

Sejam duas amostras independentes:

$$X_1, \dots, X_{n_1} \sim N(\mu_1, \sigma_1^2), \quad Y_1, \dots, Y_{n_2} \sim N(\mu_2, \sigma_2^2)$$

A estatística do teste é dada por:

$$t = \frac{(\bar{X}_1 - \bar{X}_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

que segue aproximadamente uma distribuição t de Student com:

$$\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{\left(\frac{S_1^2}{n_1}\right)^2}{n_1-1} + \frac{\left(\frac{S_2^2}{n_2}\right)^2}{n_2-1}}$$

Na prática, quando ν não é inteiro, pode-se utilizar diretamente seu valor ou, de forma conservadora, arredondá-lo para baixo.

8.6.4 Exemplo

Para avaliar o efeito de um fertilizante na produção de trigo, foram utilizadas 24 parcelas, sendo 12 com fertilizante e 12 sem fertilizante (controle).

As estatísticas amostrais observadas foram:

- Sem fertilizante: $\bar{X}_1 = 1260$, $S_1 = 730$, $n_1 = 12$
- Com fertilizante: $\bar{X}_2 = 1710$, $S_2 = 280$, $n_2 = 12$

Ao nível de significância de 5%, deseja-se verificar se houve aumento na produção devido ao uso do fertilizante.

1) Hipóteses

$$H_0 : \mu_1 = \mu_2 \quad \text{vs} \quad H_1 : \mu_1 < \mu_2$$

2) Estatística de teste

$$\begin{aligned} t &= \frac{1260 - 1710}{\sqrt{\frac{730^2}{12} + \frac{280^2}{12}}} \\ &= \frac{-450}{\sqrt{\frac{532900}{12} + \frac{78400}{12}}} = \frac{-450}{\sqrt{44408,33 + 6533,33}} \\ &= \frac{-450}{\sqrt{50941,66}} = \frac{-450}{225,7} \approx -1,99 \end{aligned}$$

Graus de liberdade

$$\nu = \frac{(44408,33 + 6533,33)^2}{\frac{(44408,33)^2}{11} + \frac{(6533,33)^2}{11}} \approx 14,5$$

Adotando $\nu \approx 14$.

3) Região crítica

Para $\alpha = 0,05$ (unilateral à esquerda) e $gl = 14$:

$$t_{0,05,14} \approx -1,761$$

4) Decisão

Como:

$$t_{calc} = -1,99 < -1,761$$

Rejeita-se H_0 .

5) Conclusão

Há evidências estatísticas de que a produção média com fertilizante é superior à produção sem fertilizante, ao nível de 5% de significância.

```
LearningStats::diffmean.test(x1=1260,x2=1710,sc1=730,sc2=280,n1=12,n2=12,
var.equal = F,alternative = "less")
```

Exercício

Em um estudo com machos de peixes *Periplaneta*, foram obtidas medidas da atividade da enzima *Cytochrome oxidase* (em mm^3 por 10 minutos por miligrama), com o objetivo de comparar dois tratamentos: grupo controle e grupo avaliado 24 horas após a aplicação de methoxyclor.

Tratamento	Tamanho da amostra	Média	Desvio padrão	Variância
24 horas	5	24,8	0,9	0,81
Controle	3	19,7	2,8	7,84

Ao nível de significância de 5%, teste se há evidência de efeito do methoxyclor sobre a média da atividade de *Cytochrome oxidase*.

8.7 Teste para duas proporções

Em muitos estudos, deseja-se comparar duas proporções populacionais associadas a uma característica de interesse em dois grupos independentes.

Sejam π_1 e π_2 as proporções populacionais dos grupos 1 e 2, respectivamente. O interesse está em testar hipóteses sobre a diferença $\pi_1 - \pi_2$.

As proporções amostrais são dadas por:

$$p_1 = \frac{x_1}{n_1}, \quad p_2 = \frac{x_2}{n_2}.$$

Sob a hipótese nula $H_0 : \pi_1 = \pi_2$, utiliza-se a proporção combinada:

$$p_p = \frac{x_1 + x_2}{n_1 + n_2}.$$

A estatística do teste é:

$$Z = \frac{p_1 - p_2}{\sqrt{p_p(1 - p_p) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim N(0, 1).$$

As hipóteses podem ser formuladas como:

$$H_0 : \pi_1 = \pi_2 \quad \text{vs} \quad H_1 : \begin{cases} \pi_1 < \pi_2 \\ \pi_1 \neq \pi_2 \\ \pi_1 > \pi_2 \end{cases}$$

8.7.1 Exemplo

Um método de semeadura foi bem-sucedido em 57 dentre 150 tentativas, enquanto outro método foi eficaz em 33 dentre 100 tentativas.

Ao nível de significância de 5%, teste se o primeiro método apresenta proporção de sucesso maior que o segundo.

1) Hipóteses

$$H_0 : \pi_1 = \pi_2 \quad \text{vs} \quad H_1 : \pi_1 > \pi_2$$

2) Nível de significância

$$\alpha = 0,05$$

3) Estatística do teste

Proporções amostrais:

$$p_1 = \frac{57}{150} = 0,38, \quad p_2 = \frac{33}{100} = 0,33$$

Proporção combinada:

$$p_p = \frac{57 + 33}{150 + 100} = \frac{90}{250} = 0,36$$

Erro padrão:

$$EP = \sqrt{0,36 \cdot 0,64 \cdot \left(\frac{1}{150} + \frac{1}{100} \right)}$$

$$EP \approx \sqrt{0,2304 \cdot 0,01667} \approx 0,062$$

Estatística do teste:

$$Z = \frac{0,38 - 0,33}{0,062} \approx 0,81$$

4) Região crítica

Teste unilateral à direita:

$$Z_{0,05} = 1,645$$

Região crítica:

$$(1,645, +\infty)$$

5) Decisão

Como $Z_{calc} = 0,81 < 1,645$, não rejeitamos H_0 .

Conclusão

Ao nível de 5% de significância, não há evidência suficiente para afirmar que o primeiro método apresenta proporção de sucesso maior que o segundo.

```
LearningStats::diffproportion.test(x1=57,x2=33,n1=150,n2=100,alternative = "greater")
```

Exercício Um pesquisador deseja comparar as proporções de germinação de dois híbridos de milho. Para isso, foram selecionadas aleatoriamente 100 sementes de cada híbrido, obtendo-se as seguintes proporções amostrais de germinação:

$$\hat{p}_1 = 0,93 \quad (\text{Híbrido A}) \quad \text{e} \quad \hat{p}_2 = 0,90 \quad (\text{Híbrido B}).$$

Ao nível de significância de 5%, verifique se há evidência de diferença entre as proporções de germinação dos dois híbridos.

```
LearningStats::diffproportion.test(x1=0.93,x2=0.90,n1=100,n2=100)
```

8.8 Teste para igualdade de duas variâncias

Em estudos envolvendo comparação de duas médias populacionais, é comum a necessidade de verificar previamente se as variâncias das populações podem ser consideradas iguais.

Para isso, utiliza-se o teste F para comparação de variâncias, considerando duas amostras independentes provenientes de populações com distribuição normal.

Hipóteses

As hipóteses do teste podem ser formuladas como:

$$H_0 : \sigma_1^2 = \sigma_2^2 \quad \text{vs} \quad H_1 : \sigma_1^2 > \sigma_2^2$$

em que σ_1^2 e σ_2^2 representam as variâncias populacionais dos grupos 1 e 2, respectivamente.

Estatística do teste

A estatística utilizada é dada por:

$$F = \frac{S_1^2}{S_2^2}$$

em que S_1^2 e S_2^2 são as variâncias amostrais.

Adota-se, por convenção, S_1^2 como a maior variância amostral, garantindo que $F \geq 1$.

Distribuição da estatística


Sob a hipótese nula e assumindo normalidade, a estatística F segue uma distribuição F com:

$$gl_1 = n_1 - 1 \quad (\text{numerador}) \quad \text{e} \quad gl_2 = n_2 - 1 \quad (\text{denominador}).$$

Regra de decisão

Para um teste unilateral à direita, rejeita-se H_0 se:

$$F_{obs} > F_{gl_1, gl_2; \alpha}$$



8.8.1 Exemplo

Com o objetivo de comparar as produções médias, em t/ha, de duas variedades de milho, foram observadas cinco unidades experimentais para cada uma:

Variedade A	1,3	1,4	1,1	1,4	1,5
Variedade B	1,8	1,6	1,9	1,9	1,8

Antes de verificar as produções médias, deve-se testar se as variâncias são iguais. Com base nestes resultados, qual é sua conclusão sobre a igualdade das variâncias? Utilizar $\alpha = 0,05$.

Hipóteses

$$H_0 : \sigma_A^2 = \sigma_B^2$$

$$H_1 : \sigma_A^2 > \sigma_B^2$$

Estatísticas amostrais

Médias:

$$\bar{x}_A = 1,34 \quad ; \quad \bar{x}_B = 1,80$$

Variâncias amostrais:

$$s_A^2 = 0,023 \quad ; \quad s_B^2 = 0,015$$

Estatística do teste

Como $s_A^2 > s_B^2$, temos:

$$F_{calc} = \frac{s_A^2}{s_B^2} = \frac{0,023}{0,015} = 1,53$$

Região crítica

Graus de liberdade:

$$gl_1 = 5 - 1 = 4 \quad ; \quad gl_2 = 5 - 1 = 4$$

Para $\alpha = 0,05$:

$$F_{sup} = F_{0,95}(4, 4) \approx 6,39$$

Região crítica:

$$F > 6,39$$

Decisão

$$1,53 < 6,39$$

Portanto, a estatística do teste não pertence à região crítica.

Conclusão

Não se rejeita H_0 ao nível de 5% de significância. Assim, não há evidências de que as variâncias sejam diferentes, podendo-se assumir homogeneidade de variâncias.

```

A=c(1.3,1.4,1.1,1.4,1.5)
B=c(1.8,1.6,1.9,1.9,1.8)

shapiro.test(A)
shapiro.test(B)
var(A)
var(B)
var.test(A,B,alternative = "greater")

```

Exercício

Foi realizado um experimento com o objetivo de comparar os tempos gastos (em minutos) na execução de manobras com dois arados de tração animal: Fuçador (Fu) e Erechim (Ere). Para cada arado, foram observadas 11 repetições, cujos resultados são apresentados a seguir:

Fu	0,20	0,22	0,18	0,23	0,12	0,20	0,13	0,12	0,13	0,22	0,17
Ere	0,36	0,48	0,33	0,43	0,40	0,43	0,33	0,36	0,35	0,40	0,35

Verifique, ao nível de significância de 5%, se as variâncias dos tempos de execução dos dois arados podem ser consideradas iguais.

```

fu=c(0.20, 0.22, 0.18, 0.23, 0.12, 0.20, 0.13, 0.12, 0.13, 0.22, 0.17)
ere=c(0.36, 0.48, 0.33, 0.43, 0.40, 0.43, 0.33, 0.36, 0.35, 0.40, 0.35)

shapiro.test(fu)
shapiro.test(ere)

var.test(ere,fu,alternative="greater")

```

Exercício 2

As seguintes medidas da enzima *Cytochrome oxidase* foram obtidas em machos de peixes do gênero *Periplaneta*, em um estudo cujo objetivo foi comparar dois tratamentos: controle e 24 horas após a aplicação de methoxyclor. Os dados resumidos são apresentados a seguir:

Tratamento	Tamanho da amostra	Média	Desvio padrão	Variância
24 horas	5	24,8	0,9	0,81
Controle	3	19,7	2,8	7,84

Ao nível de significância de 5%, verifique se há evidências de que a variabilidade da atividade de *Cytochrome oxidase* diminui após a aplicação de methoxyclor.

```
LearningStats::diffvariance.test(sc1=2.8,sc2=0.9,n1=3,n2=5,alternative = "greater")
```

9 Planejamento de Experimentos

9.1 Introdução à experimentação.

A experimentação tem como objetivo planejar, conduzir, analisar e interpretar experimentos, de modo a gerar conclusões confiáveis sobre o fenômeno em estudo. Nesse contexto, a qualidade dos resultados não depende apenas das técnicas de análise, mas principalmente da forma como o experimento é estruturado.

Dessa forma, maior ênfase deve ser dada ao **planejamento experimental** e à interpretação dos resultados, pois são essas etapas que garantem a validade das inferências realizadas. Uma análise estatística adequada não corrige falhas de planejamento, enquanto um experimento bem planejado permite extrair informações consistentes e relevantes, mesmo com métodos analíticos mais simples.

Dados experimentais são aqueles obtidos a partir de estudos conduzidos de forma planejada, em condições previamente definidas, com o objetivo de investigar um fenômeno específico. Diferentemente de dados observacionais, esses dados resultam de intervenções deliberadas do pesquisador.

Nesse contexto, um experimento (ou ensaio) pode ser definido como um estudo previamente planejado, que segue princípios básicos da experimentação e no qual se realiza a comparação entre tratamentos. Essa comparação é essencial para avaliar os efeitos dos fatores de interesse, permitindo estabelecer conclusões com base em evidências controladas.

Em experimentação, **tratamento** é o termo genérico utilizado para designar o método, material, condição ou intervenção cujo efeito se deseja avaliar ou comparar. Os tratamentos correspondem aos diferentes níveis ou combinações dos fatores em estudo e constituem a base das comparações realizadas no experimento. Como exemplos, podem-se citar: variedades de cana-de-açúcar, cultivares de soja, tipos de recipientes para produção de mudas de espécies florestais, entre outros.

A **unidade experimental**, também chamada de **parcela**, é a menor unidade à qual um tratamento é aplicado de forma independente e que fornece os dados utilizados na análise. É fundamental que as unidades experimentais sejam definidas de modo que possam refletir adequadamente o efeito dos tratamentos. Dependendo do experimento, uma unidade experimental pode ser, por exemplo, uma planta, um conjunto de plantas, uma área de terreno cultivada, um vaso com plantas, uma amostra de solo ou um lote de sementes.

O **delineamento experimental** corresponde ao plano de condução do experimento, definindo como os tratamentos serão atribuídos às unidades experimentais e como as fontes de variação serão controladas. Envolve, portanto, a escolha da estrutura do experimento, o número de repetições, a forma de alocação dos tratamentos (como a aleatorização e o uso de blocos) e o planejamento das análises estatísticas a serem realizadas. Um delineamento bem definido é fundamental para garantir a validade das inferências obtidas.

Mesmo em experimentos bem planejados, as observações estão sujeitas a variações decorrentes de fatores não controláveis, como pequenas diferenças ambientais ou biológicas entre as unidades experimentais. Essa variabilidade é denominada **variação do acaso** (ou erro experimental) e está presente em todas as medições. Sua existência justifica o uso de métodos estatísticos, que permitem avaliar se as diferenças observadas entre tratamentos são reais ou podem ser atribuídas a essa variabilidade aleatória.

O pesquisador deve planejar o experimento de forma a minimizar a variação do acaso, buscando controlar, sempre que possível, as fontes de variação conhecidas. O objetivo é isolar o efeito dos tratamentos, garantindo que as diferenças observadas sejam atribuídas aos fatores de interesse, e não a influências externas.

Fatores não controláveis, ou de difícil controle, contribuem para a variabilidade experimental e devem ser considerados no planejamento. Exemplos incluem:

- Diferenças na fertilidade do solo
- Variações ambientais (umidade, temperatura, luminosidade)
- Diferenças biológicas entre unidades experimentais

Por outro lado, existem fatores que devem ser controlados para reduzir a variabilidade desnecessária. Entre eles, destacam-se:

- Manter uniforme o espaçamento entre linhas
- Padronizar a profundidade de semeadura
- Utilizar a mesma pessoa ou equipe treinada na aplicação dos tratamentos
- Garantir a calibração e uniformidade dos equipamentos utilizados

O controle adequado dessas fontes de variação contribui para aumentar a precisão experimental e a confiabilidade dos resultados.

O **tamanho da parcela** deve ser definido de forma a proporcionar maior precisão experimental, isto é, minimizar a variabilidade entre parcelas dentro de um mesmo bloco. Em geral, busca-se um equilíbrio entre parcelas suficientemente grandes para representar bem o fenômeno estudado e suficientemente pequenas para permitir maior número de repetições.

A definição do tamanho e da forma das parcelas depende de diversos fatores, entre os quais se destacam:

- Material experimental (espécie, cultura, variabilidade biológica)

- Número de tratamentos
- Área disponível
- Custos e tempo de execução do experimento
- Presença de bordadura (distinção entre área total e área útil)
- Condições experimentais (campo, casa de vegetação ou laboratório)

No que se refere à forma das parcelas, estudos conduzidos com diferentes culturas indicam que, para aumentar a precisão experimental, parcelas mais compridas e estreitas tendem a ser mais eficientes, especialmente em condições de campo, pois permitem melhor controle de gradientes ambientais. Para parcelas de tamanho reduzido, no entanto, o efeito da forma sobre a precisão é geralmente pouco relevante.

Em alguns experimentos, é necessário o uso de **bordaduras** para evitar que os tratamentos aplicados em parcelas vizinhas influenciem as unidades experimentais, o que poderia comprometer a avaliação dos efeitos dos tratamentos.

Quando se utilizam bordaduras, distingue-se a área total da parcela da sua área útil. A área total inclui toda a parcela experimental, enquanto a área útil corresponde à porção central, livre de interferências externas, de onde são coletados os dados.

Para fins de análise estatística, devem ser considerados apenas os dados provenientes da área útil, pois são esses que melhor refletem o efeito dos tratamentos sob condições controladas.

Em ensaios conduzidos em laboratório, uma única amostra do material experimental pode constituir a unidade experimental (parcela). Em algumas situações, podem ser utilizadas amostras compostas, sendo a média das determinações adotada como valor representativo da parcela.

É importante não confundir repetições experimentais com determinações realizadas sobre a mesma amostra. Múltiplas medições em uma mesma unidade experimental não configuram repetições, mas sim subamostragens, não contribuindo para o aumento do número de graus de liberdade do erro experimental.

Em experimentos conduzidos em casa de vegetação, a unidade experimental pode ser constituída por um único vaso ou por um conjunto de vasos, dependendo do objetivo do estudo. Em alguns casos, um vaso contendo duas ou três plantas pode ser considerado uma unidade experimental, desde que o tratamento seja aplicado de forma uniforme a esse conjunto.

9.2 Princípios básicos da experimentação

Para a condução adequada de experimentos, é necessário atender a alguns princípios básicos, de modo que as conclusões obtidas sejam válidas e confiáveis. Esses princípios estão diretamente relacionados ao controle da variabilidade experimental e à garantia da independência das observações.

Os principais princípios da experimentação são:

- Repetição
- Casualização (aleatorização)
- Controle local

Cada um desses princípios atua de forma complementar, contribuindo para a redução do erro experimental e para o aumento da precisão das comparações entre tratamentos.


9.2.1 Princípio da Repetição

O princípio da repetição consiste na aplicação de um mesmo tratamento em várias unidades experimentais independentes, isto é, na utilização de várias parcelas para cada tratamento.

A repetição pode ser entendida como a reprodução do experimento básico e tem como principal finalidade possibilitar a estimação do erro experimental, isto é, da variabilidade associada à variação do acaso. Essa estimativa é essencial para a realização de testes de hipóteses e construção de intervalos de confiança.

Além disso, o aumento do número de repetições contribui para:

- Maior precisão na comparação entre tratamentos
- Redução da influência de fatores não controlados
- Aumento da confiabilidade das conclusões



Aviso

Pseudorreplicação e o uso de “repetição” e “réplica”

É importante distinguir os conceitos de repetição e réplica em experimentação.

- Repetição: corresponde à aplicação independente de um mesmo tratamento em diferentes unidades experimentais. É a verdadeira repetição experimental e permite estimar o erro experimental.
- Réplica: refere-se a múltiplas observações realizadas dentro da mesma unidade experimental, ou seja, medições que não são independentes entre si.

A pseudorreplicação ocorre quando réplicas são tratadas, incorretamente, como se fossem

repetições, inflando o número de observações independentes e comprometendo a validade da análise estatística. Deve-se ter atenção à terminologia em inglês: “replication” corresponde à repetição (no sentido correto, com independência), enquanto termos como “repetition” ou medições múltiplas podem se referir a réplicas, dependendo do contexto.

9.2.2 Princípio da Casualização


O princípio da casualização (aleatorização) consiste na distribuição dos tratamentos às unidades experimentais por meio de um processo aleatório, como sorteios ou uso de algoritmos de randomização.

Com a casualização, garante-se que todos os tratamentos tenham a mesma probabilidade de serem atribuídos a qualquer parcela, evitando vieses sistemáticos na condução do experimento. Esse procedimento é fundamental para assegurar a independência dos erros e a validade das inferências estatísticas.

A principal finalidade da casualização é garantir que a variabilidade não controlada (variação do acaso) seja distribuída de forma aleatória entre os tratamentos, permitindo uma estimativa não viesada do erro experimental.

Além disso, a casualização contribui para:

- Evitar tendências associadas à posição das parcelas
- Reduzir a influência de fatores não controlados
- Justificar o uso dos métodos estatísticos inferenciais




9.2.3 Princípio do Controle Local

O princípio do controle local consiste em reduzir a variabilidade experimental por meio da formação de grupos homogêneos de unidades experimentais. Idealmente, os experimentos devem ser conduzidos em áreas uniformes; no entanto, quando a área experimental apresenta heterogeneidade, torna-se necessário adotar estratégias para controlá-la.

Uma forma clássica de controle local é a divisão da área experimental em blocos, de modo que cada bloco seja o mais homogêneo possível internamente. As diferenças existentes entre blocos (por exemplo, gradientes de solo, umidade ou relevo) são, assim, isoladas do erro experimental.

Dentro de cada bloco, os tratamentos devem ser alocados, preferencialmente, em igual número e de forma casualizada. Dessa maneira, a comparação entre tratamentos é realizada sob condições mais homogêneas.

A principal finalidade do controle local é aumentar a eficiência do experimento, por meio da redução do erro experimental, o que resulta em maior precisão na comparação entre tratamentos.



9.2.4 Condução do experimento

A condução adequada do experimento é fundamental para garantir a qualidade dos dados obtidos. Não se deve permitir que falhas na execução comprometam os resultados, tornando a técnica experimental a principal fonte de variação do erro experimental.

Nesse sentido, todas as etapas devem ser realizadas com o máximo de rigor possível. Isso inclui a pesagem de materiais, a calibração de equipamentos e a realização das medições, sempre buscando precisão e padronização.


Uma falha comum na condução experimental é a aplicação não uniforme dos tratamentos entre as repetições. Por exemplo, ao utilizar equipamentos para aplicação de fertilizantes, a falta de limpeza adequada entre aplicações pode gerar diferenças que não são devidas aos tratamentos em si, mas sim à quantidade efetivamente aplicada em cada parcela.

Outro ponto crítico refere-se à participação de diferentes operadores. Quando mais de uma pessoa está envolvida na aplicação dos tratamentos, deve-se garantir que possíveis variações entre elas não sejam confundidas com os efeitos dos tratamentos. Uma forma de contornar esse problema é planejar o experimento de modo que todos os operadores atuem sobre todos os tratamentos, distribuindo esse efeito de maneira equilibrada.

9.2.5 Planejamento do Experimento

Antes da instalação do experimento, é fundamental realizar um planejamento cuidadoso, no qual são definidas todas as etapas e componentes essenciais do estudo. Um planejamento adequado é decisivo para garantir a qualidade dos dados e a validade das conclusões.

Para que o experimento seja corretamente planejado, devem ser definidos:



- **Os tratamentos a serem comparados**

Especificação clara dos fatores e seus níveis, que serão objeto de estudo.

- **A área experimental e a unidade experimental**

Definição do local de condução e da menor unidade que receberá os tratamentos.

- **A forma de designação dos tratamentos às unidades experimentais**

Estabelecimento do processo de casualização e, quando necessário, do uso de blocos.

- **A variável resposta e a forma de mensuração**

Definição da característica a ser avaliada, bem como dos métodos e instrumentos de medição.

- **O delineamento experimental**

Escolha do tipo de delineamento mais adequado às condições do experimento e aos objetivos do estudo.

Um planejamento bem estruturado permite controlar fontes de variação, aumentar a precisão experimental e garantir que a análise estatística produza inferências confiáveis.

9.2.6 Análise dos dados experimentais

Uma vez realizado o planejamento e a condução adequada do experimento, a etapa seguinte consiste na análise dos dados obtidos. Essa análise deve estar em consonância com o delineamento experimental adotado, de modo a permitir inferências válidas sobre os efeitos dos tratamentos.

Nesse contexto, a principal ferramenta estatística utilizada é a análise de variância (ANOVA).

A ideia básica da análise de variância é decompor a variabilidade total observada nos dados em componentes associados a causas conhecidas e independentes, como os efeitos dos tratamentos e, quando for o caso, dos blocos, e uma parte residual, de origem desconhecida, atribuída à variação do acaso.

Nota

Ideia básica da ANOVA

A ideia básica da análise de variância é decompor a variabilidade total observada nos dados em partes atribuídas a causas conhecidas e independentes e uma parte residual, de origem desconhecida e de natureza aleatória.

Essa decomposição permite avaliar se as diferenças observadas entre tratamentos são significativas ou se podem ser explicadas pela variabilidade aleatória presente no experimento.

A forma como essa decomposição é realizada depende diretamente do delineamento experimental adotado, que define as fontes de variação a serem consideradas no modelo estatístico.

9.3 Principais delineamentos Experimentais

9.3.1 Delineamento Inteiramente Casualizado (DIC)

O delineamento inteiramente casualizado (DIC) é o mais simples entre os delineamentos experimentais. Nesse delineamento, os tratamentos são atribuídos às unidades experimentais de forma completamente aleatória, sendo indicado para situações em que a área experimental é homogênea.

O DIC considera apenas os princípios da repetição e da casualização, não incorporando controle local (blocos).

Esse delineamento é amplamente utilizado em condições experimentais mais controladas, como:

- Laboratórios - Casas de vegetação - Viveiros

Nessas situações, a variabilidade entre unidades experimentais tende a ser menor, o que justifica a ausência de blocos.

Exemplo: DIC com 5 tratamentos e 4 repetições

Avaliar o efeito de diferentes herbicidas no controle de plantas daninhas na cultura da soja.

Os tratamentos são:

- A: Herbicida 1
- B: Herbicida 2
- C: Herbicida 3
- D: Herbicida 4
- E: Testemunha (sem aplicação)

Cada tratamento é repetido 4 vezes, totalizando 20 parcelas, distribuídas de forma inteiramente casualizada na área experimental.

Croqui do ensaio considerando 5 tratamentos (A, B, C, D, E) com 4 repetições cada:

A	C	B	E	D
D	A	E	C	B
B	D	A	B	C
E	B	C	D	A

Utilizando o R para realizar o sorteio aleatório dos tratamentos nas parcelas e gerar o croqui do experimento.

```
tratamento=LETTERS[1:5]  
AgroR::sketch(tratamento,r=4)
```

i Nota

Esboço da ANOVA para o DIC

Causa de variação	Graus de liberdade
Tratamentos	$I - 1 = 4$
Erro	$I(J - 1) = 15$
Total	$IJ - 1 = 19$

em que

$$I = 5 \text{ tratamentos} \quad J = 4 \text{ repetições}$$

9.3.2 Delineamento Casualizado em Blocos (DBC)

O delineamento casualizado em blocos (DBC) é utilizado quando a área experimental apresenta heterogeneidade, sendo necessário aplicar o princípio do controle local.

Nesse delineamento, a área experimental é dividida em grupos mais homogêneos, denominados blocos. Cada bloco deve reunir unidades experimentais com características semelhantes, de modo a isolar a variabilidade entre blocos do erro experimental.

Situações comuns que justificam o uso de blocos incluem:

- Diferenças de solo em áreas extensas
- Uso de diferentes equipamentos ou operadores
- Variações entre indivíduos
- Avaliações realizadas em diferentes dias

Na forma mais simples, cada bloco contém todos os tratamentos, caracterizando um bloco completo. Dentro de cada bloco, os tratamentos são distribuídos de forma casualizada.

Quando não é possível alocar todos os tratamentos em cada bloco, tem-se os blocos incompletos, que exigem abordagens específicas de análise.

Exemplo: DBC com 5 tratamentos e 4 blocos

Avaliar o desempenho de cinco cultivares de soja em uma área com variação de fertilidade no sentido do terreno.

Os tratamentos são:

- A: Cultivar 1
- B: Cultivar 2
- C: Cultivar 3
- D: Cultivar 4
- E: Cultivar 5

A área experimental é dividida em 4 blocos, de forma a controlar a variabilidade existente. Cada bloco é considerado homogêneo internamente e contém todos os tratamentos.

Dentro de cada bloco, os tratamentos são distribuídos de forma casualizada.

Cada bloco contém todos os tratamentos, distribuídos de forma casualizada.

B1	A	C	B	E	D
B2	D	A	E	C	B
B3	B	D	A	B	C
B4	E	B	C	D	A

Utilizando o R para realizar o sorteio aleatório dos tratamentos nas parcelas e gerar o croqui do experimento.

```
tratamento=LETTERS[1:5]
AgroR::sketch(tratamento,r=4,design = "DBC")
```

i Nota

Esboço da ANOVA para o DBC

Causa de variação	Graus de liberdade
Tratamentos	$I - 1 = 4$
Blocos	$J - 1 = 3$
Erro	$(I - 1)(J - 1) = 12$
Total	$IJ - 1 = 19$

No DBC, parte da variabilidade que, no DIC, seria incorporada ao erro experimental, passa a ser explicada pelos blocos, aumentando a precisão das comparações entre tratamentos.

9.3.3 Delineamento em Quadrado Latino (DQL)

O delineamento em quadrado latino (DQL) é utilizado quando a área experimental apresenta heterogeneidade em duas direções, sendo necessário aplicar o princípio do controle local em dois sentidos.

Diferentemente do delineamento em blocos casualizados, onde o controle é realizado em apenas um sentido, no DQL o controle ocorre:

- nas linhas
- nas colunas

Nesse caso, os blocos em um sentido são chamados de linhas e, no outro, de colunas.

Uma característica fundamental desse delineamento é que: - o número de linhas = colunas = tratamentos

Além disso: - Cada tratamento aparece uma única vez em cada linha e uma única vez em cada coluna.

Exemplo: Quadrado Latino com 5 tratamentos

Avaliar o efeito de cinco dietas sobre o consumo alimentar de bovinos.

Os tratamentos são:

- A: Dieta 1
- B: Dieta 2
- C: Dieta 3
- D: Dieta 4
- E: Dieta 5

O experimento é conduzido com 5 animais e 5 períodos experimentais, controlando duas fontes de variação:

- Linhas: animais (diferenças individuais)
- Colunas: períodos (efeito do tempo)

Cada dieta é fornecida uma única vez para cada animal e em cada período.

Assim, cada tratamento aparece exatamente uma vez em cada linha e uma vez em cada coluna.

Cada tratamento aparece exatamente uma vez em cada linha e uma vez em cada coluna.

	C1	C2	C3	C4	C5
L1	C	A	E	B	D
L2	A	D	B	E	C
L3	E	B	D	C	A
L4	B	C	A	D	E
L5	D	E	C	A	B

Utilizando o R para realizar o sorteio aleatório dos tratamentos nas parcelas e gerar o croqui do experimento.

```
tratamento=LETTERS[1:5]
AgroR::sketch(tratamento,r=5,design = "DQL")
```

i Nota

Esboço da ANOVA para o DQL

Causa de variação	Graus de liberdade
Tratamentos	$p - 1 = 4$
Linhas	$p - 1 = 4$
Colunas	$p - 1 = 4$
Erro	$(p - 1)(p - 2) = 12$
Total	$p^2 - 1 = 24$

No quadrado latino, a variabilidade é controlada simultaneamente em duas direções, aumentando a precisão experimental quando há duas fontes sistemáticas de heterogeneidade.

9.3.4 Experimentos Fatoriais

Os experimentos fatoriais são utilizados quando dois ou mais fatores são estudados simultaneamente.

Cada subdivisão de um fator é denominada nível do fator, e os tratamentos consistem de todas as combinações possíveis entre os fatores, considerando seus diferentes níveis.

Diferentemente dos delineamentos experimentais (DIC, DBC, DQL), os experimentos fatoriais não constituem um delineamento, mas sim um esquema de arranjo dos tratamentos, que devem ser alocados em um delineamento apropriado.

Esse tipo de experimento permite: - avaliar efeitos principais dos fatores - avaliar a interação entre fatores

Assim, os experimentos fatoriais são mais eficientes e possibilitam conclusões mais amplas.

Exemplo: Fatorial 2×3 em DBC com 4 blocos

Avaliar o efeito de dois fatores sobre o desenvolvimento de uma cultura agrícola.

Os fatores são:

- Fator A: duas cultivares (a_1, a_2)

- Fator B: três níveis de adubação (b_1, b_2, b_3)

Os tratamentos são formados por todas as combinações entre os fatores, totalizando 6 tratamentos: ($a_1b_1, a_1b_2, a_1b_3, a_2b_1, a_2b_2, a_2b_3$).

O experimento é conduzido em delineamento em blocos casualizados, com 4 blocos, utilizados para controlar a variabilidade da área experimental (por exemplo, diferenças de fertilidade do solo).

Cada bloco contém todos os tratamentos, distribuídos de forma casualizada, constituindo uma repetição completa do experimento.

Croqui do ensaio considerando 6 tratamentos em 4 blocos.

B1	a1b3	a1b1	a2b3	a2b1	a1b2	a2b2
B2	a2b2	a1b2	a2b1	a1b1	a2b3	a1b3
B3	a1b2	a2b3	a1b1	a2b2	a1b3	a2b1
B4	a2b1	a1b3	a2b2	a1b2	a1b1	a2b3

Utilizando o R para realizar o sorteio aleatório dos tratamentos nas parcelas e gerar o croqui do experimento.

```
AgroR:::sketch(trat=c("a1","a2"),trat1 = c("b1","b2","b3"),r=4,design = "FAT2DBC")
```

i Nota

Esboço da ANOVA para o fatorial 2×3 em DBC

Causa de variação	Graus de liberdade
Fator A	$a - 1 = 1$
Fator B	$b - 1 = 2$
A x B	$(a - 1)(b - 1) = 2$
Tratamentos	$ab - 1 = 5$
Blocos	$n - 1 = 3$
Erro	$(ab - 1)(n - 1) = 15$
Total	$abn - 1 = 23$

No experimento fatorial, além dos efeitos principais, avalia-se a interação entre fatores.

- Quando a interação é significativa, a interpretação deve ser feita por meio do desdobramento.
- Caso contrário, analisam-se apenas os efeitos principais.

9.3.5 Experimentos em Parcelas Subdivididas

Os experimentos em parcelas subdivididas (split-plot) também são utilizados quando dois ou mais fatores são estudados simultaneamente, porém em condições experimentais diferentes daquelas dos experimentos fatoriais.

Nesses experimentos, cada parcela é dividida em subparcelas.

A principal diferença em relação ao esquema fatorial está na casualização dos tratamentos: - o fator aplicado nas parcelas é casualizado primeiro - dentro de cada parcela, realiza-se a casualização do segundo fator

Assim, cada parcela funciona como um “bloco” para o segundo fator.

Define-se: - Fator A (parcelas): tratamentos primários ou principais - Fator B (subparcelas): tratamentos secundários ou subtratamentos

Exemplo: Parcelas subdivididas (2×3) em DBC com 4 blocos

Avaliar o efeito de dois fatores sobre o desenvolvimento de uma cultura agrícola.

Os fatores são:

- Fator A: duas formas de preparo do solo (a_1, a_2) — aplicadas nas parcelas
- Fator B: três níveis de adubação (b_1, b_2, b_3) — aplicados nas subparcelas

O experimento é conduzido em delineamento em blocos casualizados, com 4 blocos, para controlar a variabilidade da área experimental.

Dentro de cada bloco:

- As parcelas recebem os níveis do fator A
- Cada parcela é subdividida, recebendo os níveis do fator B

i Nota

Por que não usar um fatorial em DBC simples?

O fator A (preparo do solo) exige operações em área maior, sendo difícil, custoso e operacionalmente inviável aplicar de forma independente em parcelas pequenas.

Já o fator B (adubação) é de fácil aplicação e pode ser conduzido em unidades menores.

Assim, utiliza-se parcelas subdivididas para:

- facilitar a condução do experimento

- reduzir custo e esforço operacional
- respeitar a natureza dos fatores

Cada bloco contém todas as parcelas (níveis de A), e dentro de cada parcela estão presentes todas as subparcelas (níveis de B).

Croqui do ensaio considerando 2 níveis de A nas parcelas e 3 níveis de B nas subparcelas, em 4 blocos.

Bl 1	a2 b1	a2 b2	a2 b3	a1 b2	a1 b3	a1 b1
Bl 2	a1 b2	a1 b1	a1 b3	a2 b1	a2 b3	a2 b2
Bl 3	a1 b3	a1 b2	a1 b1	a2 b2	a2 b1	a2 b3
Bl 4	a2 b1	a2 b3	a2 b2	a1 b3	a1 b2	a1 b1

Utilizando o R para realizar o sorteio aleatório dos tratamentos nas parcelas e gerar o croqui do experimento.

```
AgroR::sketch(trat=c("a1","a2"),trat1=c("b1","b2","b3"),r=4,design="PSUBDBC")
```

i Nota

Esboço da ANOVA para o fatorial 2×3 em DBC

Causa de variação	Graus de liberdade
Blocos	$n - 1 = 3$
Fator A	$a - 1 = 1$
Resíduo (a)	$(a - 1)(n - 1) = 3$
Parcelas	$an - 1 = 7$
Fator B	$b - 1 = 2$
A x B	$(a - 1)(b - 1) = 2$
Resíduo (b)	$a(b - 1)(n - 1) = 12$
Total	$abn - 1 = 23$

Nos experimentos fatoriais e em parcelas subdivididas, ambos permitem estudar dois ou mais fatores simultaneamente e avaliar interações. No entanto, diferem fundamentalmente na forma de casualização e na precisão experimental. No esquema fatorial, todos os tratamentos são casualizados da mesma forma, e o experimento possui um único erro experimental, garantindo a mesma precisão para todos os efeitos avaliados.

Já nos experimentos em parcelas subdivididas, a casualização ocorre em duas etapas: primeiro para o fator das parcelas (A) e depois, dentro destas, para o fator das subparcelas (B). Como consequência, surgem dois erros experimentais, sendo o fator A estimado com menor precisão e o fator B (e a interação) com maior precisão.

Assim, enquanto o fatorial é mais simples e estatisticamente mais eficiente quando aplicável, o delineamento em parcelas subdivididas é preferido quando há restrições práticas, como dificuldade de aplicação, custo elevado ou necessidade de áreas maiores para um dos fatores.

References

- ANDRADE, P. J., D. O.; OGLIARI. 2017. *Estatística para as Ciências Agrárias e Biológicas: com Noções de Experimentação*. 3. Florianópolis: Ed da UFSC.
- Pimentel-Gomes, Frederico. 2009. *Curso de Estatística Experimental*. 15.^a ed. Piracicaba: FEALQ.